

# **Stochastik SS 2019**

Dozent: Prof. Dr. ANITA BEHME

29. Juli 2019

# Inhaltsverzeichnis

<b>I</b>	<b>Grundbegriffe der Wahrscheinlichkeitstheorie</b>	<b>3</b>
1	Wahrscheinlichkeitsräume . . . . .	3
2	Zufallsvariablen . . . . .	7
<b>II</b>	<b>Erste Standardmodelle der Wahrscheinlichkeitstheorie</b>	<b>12</b>
1	Diskrete Gleichverteilungen . . . . .	12
2	Urnenmodelle . . . . .	12
2.1	Urnenmodell mit Zurücklegen: Multinomial-Verteilung . . . . .	13
2.2	Urnenmodell ohne Zurücklegen: Hypergeometrische Verteilung . . . . .	15
3	Poisson-Approximation und POISSON-Verteilung . . . . .	15
<b>III</b>	<b>Bedingte Wkeiten und (Un-)abhängigkeit</b>	<b>17</b>
1	Bedingte Wahrscheinlichkeiten . . . . .	17
2	(Un)abhängigkeit . . . . .	22
2.1	Konstruktion unabhängiger Zufallsvariablen . . . . .	27
2.2	Faltungen . . . . .	29
<b>IV</b>	<b>Weitere Standardmodelle der Wahrscheinlichkeitstheorie</b>	<b>33</b>
1	Stetige Gleichverteilung . . . . .	33
2	Wartezeitverteilungen . . . . .	33
2.1	Exponential- und Gammaverteilung . . . . .	34
<b>V</b>	<b>Erwartungswerte &amp; Varianz</b>	<b>37</b>
1	Der Erwartungswert . . . . .	37
2	Varianz und höhere Momente . . . . .	41
3	Wahrscheinlichkeitserzeugende Funktionen . . . . .	44
<b>VI</b>	<b>Bedingte Verteilungen und bedingte Erwartungswerte</b>	<b>48</b>
1	Bedingte Verteilungen . . . . .	48
2	Bedingte Erwartungswerte . . . . .	54
2.1	Der bedingte Erwartungswert als Zufallsvariable . . . . .	57
2.2	Bedingen auf beliebige $\sigma$ -Algebren . . . . .	57
<b>VII</b>	<b>Die Normalverteilung</b>	<b>64</b>
<b>VIII</b>	<b>Momenterzeugende &amp; charakteristische Funktionen</b>	<b>66</b>
<b>IX</b>	<b>Konvergenzbegriffe und Gesetze der großen Zahlen</b>	<b>73</b>
1	Schwaches Gesetz der großen Zahlen . . . . .	73
2	Das starke Gesetz der großen Zahlen . . . . .	77
3	Der Satz von GLIVENKO-CANTELLI . . . . .	81

4	$\mathcal{L}^p$ -Konvergenz . . . . .	84
<b>X</b>	<b>Verteilungskonvergenz und der zentrale Grenzwertsatz</b>	<b>86</b>
1	Die Verteilungskonvergenz . . . . .	86
2	Der Zentrale Grenzwertsatz . . . . .	95
<b>XI</b>	<b>Diskrete Martingale</b>	<b>99</b>
	<b>Anhang</b>	<b>105</b>
	<b>Index</b>	<b>106</b>

# *Vorwort*

# *Was ist Stochastik?*

Altgriechisch Stochastikos ( $\sigma\tau\omicron\chi\alpha\sigma\tau\iota\kappa\acute{o}\varsigma$ ) und bedeutet sinngemäß “scharfsinnig in Vermuten”.

Fragestellung insbesondere aus Glücksspiel, Versicherungs-/Finanzmathematik, überall da wo Zufall/Risiko / Chance auftauchen.

Was ist Stochastik?

- Beschreibt zufällige Phänomene in einer exakten Sprache!  
Beispiel: “Beim Würfeln erscheint jedes sechste Mal (im Schnitt) eine 6.”  $\rightarrow$  Gesetz der großen Zahlen ( $\nearrow$  später)
- Lässt sich mathematische Stochastik in zwei Teilgebiete unterteilen  
Wahrscheinlichkeitstheorie (Wahrscheinlichkeitstheorie) & Statistik
  - *Wahrscheinlichkeitstheorie*: Beschreibt und untersucht konkret gegebene Zufallssituationen.
  - *Statistik*: Zieht Schlussfolgerungen aus Beobachtungen.

Statistik benötigt Modelle der Wahrscheinlichkeitstheorie. Wahrscheinlichkeitstheorie benötigt die Bestätigung der Modelle durch Statistik.

In diesem Semester konzentrieren wir uns nur auf die Wahrscheinlichkeitstheorie!

## Kapitel I

# *Grundbegriffe der Wahrscheinlichkeitstheorie*

## 1. Wahrscheinlichkeitsräume

### Ergebnisraum

Welche der möglichen Ausgänge eines zufälligen Geschehens interessieren uns?

Würfeln? Augenzahl, nicht die Lage und die Fallhöhe

#### **Definition I.1 (Ergebnisraum)**

Die Menge der relevanten Ergebnisse eines Zufallsgeschehens nennen wir Ergebnisraum und bezeichnen diesen mit  $\Omega$ .

#### ■ Beispiel

- Würfeln:  $\Omega = \{1, 2, \dots, 6\}$
- Wartezeiten:  $\Omega = \mathbb{R}_+ = [0, \infty)$  (überabzählbar!)

### Ereignisse

Oft interessieren wir uns gar nicht für das konkrete Ergebnis des Zufallsexperiments, sondern nur für das Eintreten gewisser Ereignisse.

#### ■ Beispiel

- Würfeln: Zahl ist  $\geq 3$
- Wartezeit: Wartezeit  $\leq 5$  Minuten

→ Teilmenge des Ereignisraums, also Element der Potenzmenge  $\mathcal{P}(\Omega)$ , denen eine Wahrscheinlichkeit zugeordnet werden kann, d.h. welche messbar (mb) sind.

#### **Definition I.2 (Ereignisraum, messbarer Raum)**

Sei  $\Omega \neq \emptyset$  ein Ergebnisraum und  $\mathcal{F}$  eine  $\sigma$ -Algebra auf  $\Omega$ , d.h. eine Familie von Teilmenge von  $\Omega$ , sodass

1.  $\Omega \in \mathcal{F}$
2.  $A \in \mathcal{F} \Rightarrow A^C \in \mathcal{F}$
3.  $A_1, A_2, \dots \in \mathcal{F} \Rightarrow \bigcup_{i \geq 1} A_i \in \mathcal{F}$

Dann heißt  $(\Omega, \mathcal{F})$  Ereignisraum bzw. messbarer Raum.

### Wahrscheinlichkeiten

Ordne Ereignissen Wahrscheinlichkeiten zu mittels der Abbildung

$$\mathbb{P} : \mathcal{F} \rightarrow [0, 1]$$

sodass

$$\text{Normierung } \mathbb{P}(\Omega) = 1 \quad (\text{N})$$

$$\sigma\text{-Additivität für paarweise disjunkte Ereignisse } A_1, A_2, \dots \in \mathcal{F} \Rightarrow \mathbb{P}\left(\bigcup_{i \geq 1} A_i\right) = \sum_{i \geq 1} \mathbb{P}(A_i) \quad (\text{A})$$

(N), (A) und die Nichtnegativität von  $\mathbb{P}$  werden als KOLMOGOROVsche Axiome bezeichnet (nach Kolmogorov: Grundbegriffe der Wahrscheinlichkeitstheorie, 1933)

**Definition I.3 (Wahrscheinlichkeitsmaß, Wahrscheinlichkeitsverteilung)**

Sei  $(\Omega, \mathcal{F})$  ein Ereignisraum und  $\mathbb{P} : \mathcal{F} \rightarrow [0, 1]$  eine Abbildung mit Eigenschaften (N) und (A).

Dann heißt  $\mathbb{P}$  Wahrscheinlichkeitsmaß oder auch Wahrscheinlichkeitsverteilung.

Aus der Definition folgen direkt:

**Satz I.4 (Rechenregeln für W-Maße)**

Sei  $\mathbb{P}$  ein W-Maß, Ereignisse  $(\Omega, \mathcal{F}), A, B, A_1, A_2, \dots \in \mathcal{F}$ . Dann gelten:

1.  $\mathbb{P}(\emptyset) = 0$
2. Monotonie:  $A \subseteq B \Rightarrow \mathbb{P}(A) \leq \mathbb{P}(B)$
3. endliche  $\sigma$ -Additivität:  $\mathbb{P}(A \cup B) + \mathbb{P}(A \cap B) = \mathbb{P}(A) + \mathbb{P}(B)$   
und insbesondere  $\mathbb{P}(A) + \mathbb{P}(A^C) = 1$
4.  $\sigma$ -Subadditivität:

$$\mathbb{P}\left(\bigcup_{i \geq 1} A_i\right) \leq \sum_{i \geq 1} \mathbb{P}(A_i)$$

5.  $\sigma$ -Stetigkeit: Wenn  $A_n \uparrow A$  (d.h.  $A_1 \subseteq A_2 \subseteq \dots$  und  $A = \bigcup_{i=1}^{\infty} (A_i)$ ) oder  $A_n \downarrow A$ , so gilt:

$$\mathbb{P}(A_n) \xrightarrow{n \rightarrow \infty} \mathbb{P}(A)$$

*Beweis.* In der Vorlesung wurde auf Schilling MINT Satz 3.3 verwiesen. Ausserdem gab es dazu Präsenzübung 1.3. Der folgende Beweis wurde ergänzt.

Beweise erst Aussage:  $A \cap B = \emptyset \Rightarrow \mathbb{P}(A \uplus B) = \mathbb{P}(A) + \mathbb{P}(B)$ .

Es kann  $\sigma$ -Additivität verwendet werden, indem "fehlende" Mengen durch  $\emptyset$  ergänzt werden:

$$\mathbb{P}(A \uplus B) = \mathbb{P}(A \uplus B \uplus \emptyset \uplus \emptyset \dots) = \mathbb{P}(A) + \mathbb{P}(B) + \mathbb{P}(\emptyset) + \dots = \mathbb{P}(A) + \mathbb{P}(B),$$

wobei Maßeigenschaften verwendet werden.

1. Definition des Maßes.

2. Da  $A \subseteq B$  ist auch  $B = A \uplus (B \setminus A) = A \uplus (B \setminus (A \cap B))$ . Wende wieder Aussage von oben an, damit folgt

$$\mathbb{P}(B) = \mathbb{P}(A \uplus (B \setminus A)) = \mathbb{P}(A) + \mathbb{P}(B \setminus A) \geq \mathbb{P}(A) \quad (*)$$

3. Zerlege  $A \cup B$  geschickt, dann sieht man mit oben gezeigter Aussage und  $(*)$

$$\begin{aligned} \mathbb{P}(A \cup B) + \mathbb{P}(A \cap B) &= \mathbb{P}(A \uplus (B \setminus (A \cap B))) + \mathbb{P}(A \cap B) \\ &= \mathbb{P}(A) + \mathbb{P}(B \setminus (A \cap B)) + \mathbb{P}(A \cap B) \\ &= \mathbb{P}(A) + \mathbb{P}(B). \end{aligned}$$

Im letzten Schritt wurde  $(*)$  verwendet.

4. Folgt aus endlicher  $\sigma$ -Additivität, da  $\mathbb{P}\left(\bigcap_{i \geq 1} A_i\right) \geq 0$ .

5. Definiere  $F_1 := A_1, F_2 := A_2 \setminus A_1, \dots, F_{i+1} := A_{i+1} \setminus A_i$ . Die  $F_i$  Mengen sind paarweise disjunkt und damit folgt für  $m \rightarrow \infty$

$$A_m = \biguplus_{i=1}^m F_i \implies A = \biguplus_{i=1}^{\infty} F_i = \biguplus_{i=1}^{\infty} A_i$$

und

$$\mathbb{P}(A) = \mathbb{P}\left(\biguplus_{i=1}^{\infty} F_i\right) = \sum_{i=1}^{\infty} \mathbb{P}(F_i) = \lim_{m \rightarrow \infty} \lim_{m \rightarrow \infty} \mathbb{P}\left(\biguplus_{i=1}^m F_i\right) = \lim_{m \rightarrow \infty} \lim_{m \rightarrow \infty} \mathbb{P}(A_m). \quad \square$$

### ■ Beispiel I.5

Für ein beliebiges Ereignisraum  $(\Omega, \mathcal{F})$  ( $\Omega \neq \emptyset$ ) und eine beliebiges Element  $\xi \in \Omega$  definiere

$$\delta_{\xi}(A) := \begin{cases} 1 & \xi \in A \\ 0 & \text{sonst} \end{cases}$$

ein (degeneriertes) W-Maß auf  $(\Omega, \mathcal{F})$ , welches wir als DIRAC-Maß oder DIRAC-Verteilung bezeichnen.

### ■ Beispiel I.6

Würfeln mit fairem, 6-(gleich)seitigem Würfel mit Ergebnismenge  $\Omega = \{1, \dots, 6\}$  und Ereignisraum  $\mathcal{F} = \mathcal{P}(\Omega)$  setzen wir als Symmetriegründen

$$\mathbb{P}(A) = \frac{\#A}{6}.$$

(Wobei  $\#A$  oder auch  $|A|$  die Kardinalität von  $A$  ist.) Das definiert ein W-Maß.

### ■ Beispiel I.7

Wartezeit an der Bushaltestelle mit Ergebnisraum  $\Omega = \mathbb{R}_+$  und Ereignisraum BORELSche  $\sigma$ -Algebra  $\mathcal{B}(\mathbb{R}_+) = \mathcal{F}$ . Ein mögliches W-Maß können wir dann durch

$$\mathbb{P}(A) = \int_A \lambda e^{-\lambda x} dx$$

für einen Parameter  $\lambda > 0$  festlegen. (Offenbar gilt  $\mathbb{P}(\Omega) = 1$  und die  $\sigma$ -Additivität aufgrund der



Additivität des Integrals.) Wir bezeichnen diese Maße als Exponentialverteilung. (Warum gerade dieses Maß für Wartezeiten gut geeignet ist  $\nearrow$  später)

### Satz I.8 (Konstruktion von Wahrscheinlichkeitsmaßen durch Dichten)

Sei  $(\Omega, \mathcal{F})$  ein Ereignisraum.

- $\Omega$  abzählbar,  $\mathcal{F} = \mathcal{P}(\Omega)$ : Sei  $\rho = (\rho(\omega))_{\omega \in \Omega}$  eine Folge in  $[0, 1]$  in  $\sum_{\omega \in \Omega} \rho(\omega) = 1$ , dann definiert

$$\mathbb{P}(A) = \sum_{\omega \in A} \rho(\omega), A \in \mathcal{F}$$

ein (diskretes) Wahrscheinlichkeitsmaß  $\mathbb{P}$  auf  $(\Omega, \mathcal{F})$ .  $\rho$  wird als Zähldichte bezeichnet.

- Umgekehrt definiert jedes Wahrscheinlichkeitsmaß  $\mathbb{P}$  auf  $(\Omega, \mathcal{F})$  definiert Folge  $\rho(\omega) = \mathbb{P}(\{\omega\})$ ,  $\omega \in \Omega$  eine Folge  $\rho$  mit den obigen Eigenschaften.
- $\Omega \subset \mathbb{R}^n$ ,  $\mathcal{F} = \mathcal{B}(\Omega)$ : Sei  $\rho : \Omega \rightarrow [0, \infty)$  eine Funktion, sodass

1.  $\int_{\Omega} \rho(x) dx = 1$
2.  $\{x \in \Omega : \rho(x) \leq c\} \in \mathcal{B}(\Omega)$  für alle  $c > 0$

dann definiert  $\rho$  ein Wahrscheinlichkeitsmaß  $\mathbb{P}$  auf  $(\Omega, \mathcal{F})$  durch

$$\mathbb{P}(A) = \int_A \rho(x) dx = \int_A \rho d\lambda, \quad A \in \mathcal{B}(\Omega).$$

Das Integral interpretieren wir stets als Lebesgue-Integral bzw. Lebesgue-Maß  $\lambda$ .  $\rho$  bezeichnen wir als Dichte, Dichtefunktion/Wahrscheinlichkeitsdichte von  $\mathbb{P}$  und nennen ein solches  $\mathbb{P}$  (absolut) stetig (bzgl. dem Lebesgue-Maß).

### Anmerkung (English)

Zähldichte heißt im eng. pmf, Dichtefunktion = pdf und später Verteilungsfunktion=cdf - c steht für cumulative.

*Beweis.* • Der diskrete Fall ist klar.

- Im stetigen Fall folgt die Behauptung aus den bekannten Eigenschaften des Lebesgue-Integrals ( $\nearrow$  Schilling MINT, Lemma 8.9)  $\square$

### ► Bemerkung

- Die eindeutige Beziehung zwischen Dichte und Wahrscheinlichkeitsmaß überträgt sich nicht auf den stetigen Fall.
  - Nicht jedes Wahrscheinlichkeitsmaß auf  $(\Omega, \mathcal{B}(\Omega))$  mit  $\Omega \subset \mathbb{R}^n$  besitzt eine Dichte.
  - Zwei Dichtefunktionen definieren dasselbe Wahrscheinlichkeitsmaß, wenn sie sich nur auf einer Menge vom LEBESGUE-Maß 0 unterscheiden.
- Jede auf  $\Omega \subset \mathbb{R}^n$  definierte Dichtefunktion  $\rho$  lässt sich auf ganz  $\mathbb{R}^n$  fortsetzen durch  $\rho(x) =$

0 mit  $x \notin \Omega$ . Das erzeugte Wahrscheinlichkeitsmaß auf  $(\mathbb{R}^n, \mathcal{B}(\Omega))$  lässt mit dem Wahrscheinlichkeitsmaß auf  $(\Omega, \mathcal{B}(\Omega))$  identifizieren.

- Mittels Dirac-Maß  $\delta_x$  können auch jedes diskrete Wahrscheinlichkeitsmaß auf  $\Omega \subset \mathbb{R}^n$  als Wahrscheinlichkeitsmaß auf  $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$  interpretieren

$$\mathbb{P}(A) = \sum_{\omega \in A} \rho(\omega) = \int_A d\left(\sum_{\omega \in \Omega} \rho(\omega) \delta_\omega\right)$$

stetige und diskrete Wahrscheinlichkeitsmaße lassen sich kombinieren z.B.

$$\mathbb{P}(A) = \frac{1}{2} \delta_0 + \frac{1}{2} \int_A \mathbb{1}_{[0,1]}(x) dx \quad \forall A \in \mathcal{B}(\mathbb{R})$$

ist ein Wahrscheinlichkeitsmaß auf  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ .

Abschließend erinnern wir uns an:

**Satz I.9 (Eindeutigkeitssatz für Wahrscheinlichkeitsmaße)**

Sei  $(\Omega, \mathcal{F})$  Ereignisraum und  $\mathbb{P}$  ein Wahrscheinlichkeitsmaß auf  $(\Omega, \mathcal{F})$ . Sei  $\mathcal{F} = \sigma(\mathcal{G})$  für ein  $\cap$ -stabiles Erzeugendensystem  $\mathcal{G} \subset \mathcal{P}(\Omega)$ . Dann ist  $\mathbb{P}$  bereits durch seine Einschränkung  $\mathbb{P}|_{\mathcal{G}}$  eindeutig bestimmt.

*Beweis.* ↗ Schilling MINT, Satz 4.5. □

Insbesondere definiert z.B.

$$\mathbb{P}([0, a]) = \int_0^a \lambda e^{-\lambda x} dx = 1 - e^{-\lambda a}, a > 0$$

bereits die Exponentialverteilung aus Beispiel I.7.

**Definition I.10 (Gleichverteilung)**

Ist  $\Omega$  endlich, so heißt das Wahrscheinlichkeitsmaß mit konstanter Zähldichte  $\rho(\omega) = 1/|\Omega|$  die (diskrete) Gleichverteilung auf  $\Omega$  und wird mit  $U(\Omega)$  notiert ( $U$  = Uniform). Ist  $\Omega \subset \mathbb{R}^n$  eine Borelmenge mit Lebesgue-Maß  $0 < \lambda^n(\Omega) < \infty$ , so heißt das Wahrscheinlichkeitsmaß auf  $(\Omega, \mathcal{B}(\Omega))$  mit konstanter Dichtefunktion  $\rho(x) = 1/\lambda^n(x)$ , die (stetige) Gleichverteilung auf  $\Omega$ . Sie wird ebenso mit  $U(\Omega)$  notiert.

**Wahrscheinlichkeitsräume**

**Definition I.11 (Wahrscheinlichkeitsraum)**

Ein Tripel  $(\Omega, \mathcal{F}, \mathbb{P})$  mit  $\Omega, \mathcal{F}$  Ereignisraum und  $\mathbb{P}$  Wahrscheinlichkeitsmaß auf  $(\Omega, \mathcal{F})$ , nennen wir Wahrscheinlichkeitsraum.

## 2. Zufallsvariablen

Zufallsvariablen dienen dazu von einem gegebenen Ereignisraum  $(\Omega, \mathcal{F})$  zu einem Modellausschnitt  $\Omega', \mathcal{F}'$  überzugehen. Es handelt sich also um Abbildungen  $X : \Omega \rightarrow \Omega'$ . Damit wird auch jedem Ereignis

in  $\mathcal{F}'$  eine Wahrscheinlichkeit zuordnen können, benötigen wir

$$A' \in \mathcal{F}' \Rightarrow X^{-1}(A') \in \mathcal{F}$$

d.h.  $X$  sollte messbar sein.

**Definition I.12 (Zufallsvariable)**

Seien  $(\Omega, \mathcal{F})$  und  $(\Omega', \mathcal{F}')$  Ereignisräume. Dann heißt jede messbare Abbildung

$$X : \Omega \rightarrow \Omega'$$

Zufallsvariable (von  $(\Omega, \mathcal{F})$ ) nach  $(\Omega', \mathcal{F}')$  / auf  $(\Omega, \mathcal{F})$  oder Zufallselement.

■ **Beispiel I.13**

1. Ist  $\Omega$  abzählbar und  $\mathcal{F} = \mathcal{P}(\Omega)$ , so ist jede Abbildung  $X : \Omega \rightarrow \Omega'$  messbar und damit eine Zufallsvariable.
2. Ist  $\Omega \subset \mathbb{R}^n$  und  $\mathcal{F} = \mathcal{B}(\Omega)$ , so ist jede stetige Funktion  $X : \Omega \rightarrow \mathbb{R}$  messbar und damit eine Zufallsvariable.

**Satz I.14**

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  ein Wahrscheinlichkeitsraum und  $X$  eine Zufallsvariable von  $(\Omega, \mathcal{F})$  nach  $(\Omega', \mathcal{F}')$ . Dann definiert

$$\mathbb{P}'(A') := \mathbb{P}(X^{-1}(A')) = \mathbb{P}(\{X \in A'\}), \quad A' \in \mathcal{F}'$$

ein Wahrscheinlichkeitsmaß auf  $(\Omega', \mathcal{F}')$ , welches wir als Wahrscheinlichkeitsverteilung von X unter  $\mathbb{P}$  bezeichnen.

*Beweis.* Aufgrund der Messbarkeit von  $X$  ist die Definition sinnvoll. Zudem gelten

$$\mathbb{P}'(\Omega') = \mathbb{P}(X^{-1}(\Omega')) = \mathbb{P}(\Omega) = 1$$

und für  $A'_1, A'_2, \dots \in \mathcal{F}'$  paarweise disjunkt.

$$\begin{aligned} \mathbb{P}'\left(\bigcup_{i \geq 1} A'_i\right) &= \mathbb{P}\left(X^{-1}\left(\bigcup_{i \geq 1} A'_i\right)\right) \\ &= \mathbb{P}\left(\bigcup_{i \geq 1} X^{-1}(A'_i)\right) \\ &= \sum_{i \geq 1} \mathbb{P}(X^{-1} A'_i) \end{aligned}$$

da auch  $X^{-1} A'_1, X^{-1} A'_2, \dots$  paarweise disjunkt

$$\mathbb{P}'\left(\bigcup_{i \geq 1} A'_i\right) = \sum_{i \geq 1} \mathbb{P}'(A'_i).$$

Also ist  $\mathbb{P}'$  ein Wahrscheinlichkeitsmaß. □

► **Bemerkung**

- Aus Gründen der Lesbarkeit schreiben wir in der Folge  $\mathbb{P}(X \in A) = \mathbb{P}(\{\omega: X(\omega) \in A\})$
- Ist  $X$  die Identität, so fallen die Begriffe Wahrscheinlichkeitsmaß und Wahrscheinlichkeitsverteilung zusammen.
- In der (weiterführenden) Literatur zu Wahrscheinlichkeitstheorie wird oft auf die Angabe eines zugrundeliegenden Wahrscheinlichkeitsraumes verzichtet und stattdessen eine “Zufallsvariable mit Verteilung  $\mathbb{P}$  auf  $\Omega$ ” eingeführt. Gemeint ist (fast) immer  $X$  als Identität auf  $(\Omega, \mathcal{F}, \mathbb{P})$  mit  $\mathcal{F} = \mathcal{P}(\Omega)/\mathcal{B}(\Omega)$ .
- Für die Verteilung von  $X$  unter  $\mathbb{P}$  schreibe  $\mathbb{P}_X$  und  $X \sim \mathbb{P}_X$  für die Tatsache, dass  $X$  gemäß  $\mathbb{P}_X$  verteilt ist.

**Definition I.15 (identisch verteilte, reelle Zufallsvariablen)**

Zwei Zufallsvariablen sind identisch verteilt, wenn sie dieselbe Verteilung haben. Von besonderem Interesse sind für uns die Zufallsvariablen, die nach  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  abbilden, sogenannte reelle Zufallsvariablen.

Da die halboffenen Intervalle  $\mathcal{B}(\mathbb{R})$  erzeugen, ist die Verteilung einer reellen Zufallsvariable durch die Werte  $(-\infty, c], c \in \mathbb{R}$  eindeutig festgelegt.

**Definition I.16 ((kumulative) Verteilungsfunktion von  $\mathbb{P}$ )**

Sei  $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \mathbb{P})$  Wahrscheinlichkeitsraum, so heißt

$$F : \mathbb{R} \rightarrow [0, 1] \text{ mit } x \mapsto \mathbb{P}((-\infty, x])$$

(kumulative) Verteilungsfunktion von  $\mathbb{P}$ .

Ist  $X$  eine reelle Zufallsvariable auf beliebigem Wahrscheinlichkeitsraum  $(\Omega, \mathcal{F}, \mathbb{P})$ , so heißt

$$F : \mathbb{R} \rightarrow [0, 1] \text{ mit } x \mapsto \mathbb{P}(X \leq x) = \mathbb{P}(X \in (-\infty, x])$$

die (kumulative) Verteilungsfunktion von  $X$ .


■ **Beispiel I.17**

Sei  $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \mathbb{P})$  mit  $\mathbb{P}$  Exponentialverteilung mit Parameter  $\lambda > 0$

$$\mathbb{P}(A) = \int_{A \cap [0, \infty)} \lambda e^{-\lambda x} dx \quad A \in \mathcal{B}(\mathbb{R}).$$

Dann ist

$$F(x) = \mathbb{P}((-\infty, x]) = \begin{cases} 0 & x \leq 0 \\ \int_0^x \lambda e^{-\lambda y} dy = 1 - e^{-\lambda x} & x > 0 \end{cases}.$$




### ■ Beispiel I.18

Das Würfeln mit einem fairen, sechsseitigen Würfel kann mittels einer reellen Zufallsvariablen

$$X : \{1, 2, \dots, 6\} \rightarrow \mathbb{R} \text{ mit } x \mapsto x$$

modelliert werden. Es folgt als Verteilungsfunktion

$$\begin{aligned} F(x) &= \mathbb{P}(X \leq x) = \mathbb{P}(X^{-1}(-\infty, x]) = \mathbb{P}((-\infty, x]) \\ &= \frac{1}{6} \sum_{i=1}^6 \mathbb{1}_{i \leq x}. \end{aligned}$$



Allgemein:

**Satz I.19**

Ist  $\mathbb{P}$  ein Wahrscheinlichkeitsmaß auf  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  und  $F$  die zugehörige Verteilungsfunktion, so gelten

1.  $F$  ist monoton wachsend
2.  $F$  ist rechtsseitig stetig
3.  $\lim_{x \rightarrow -\infty} F(x) = 0, \lim_{x \rightarrow \infty} F(x) = 1$

Umgekehrt existiert zu jeder Funktion  $F : \mathbb{R} \rightarrow [0, 1]$  mit Eigenschaften 1-3 eine reelle Zufallsvariable auf  $((0, 1), \mathcal{B}((0, 1)), \mathbb{U}((0, 1)))$  mit Verteilungsfunktion  $F$ .

*Beweis.* Ist  $F$  Verteilungsfunktion, so folgt mit Satz I.4

$$x \leq y \Rightarrow F(x) = \mathbb{P}((-\infty, x]) \stackrel{\text{I.4.3}}{\leq} \mathbb{P}((-\infty, y]) = F(y)$$

und

$$\lim_{x \searrow c} F(x) = \lim_{x \searrow c} \mathbb{P}((-\infty, x]) \stackrel{\sigma\text{-Stetigkeit}}{=} \mathbb{P}((-\infty, c]) = F(c)$$

sowie

$$\begin{aligned} \lim_{x \rightarrow -\infty} F(x) &\stackrel{\text{I.4.5}}{=} \mathbb{P}(\emptyset) \stackrel{\text{I.4.1}}{=} 0 \\ \lim_{x \rightarrow \infty} F(x) &\stackrel{\text{I.4.5}}{=} \mathbb{P}(\mathbb{R}) = 1. \end{aligned}$$

Umgekehrt wähle

$$X(u) := \inf\{x \in \mathbb{R} : F(x) \geq u\}, \quad u \in (0, 1)$$

Dann ist  $X$  eine “linksseitige Inverse” von  $F$  (auch Quantilfunktion / verallgemeinerte Inverse). Wegen 3 gilt:

$$-\infty < X(u) < \infty$$

und zudem

$$\{X \leq x\} = (0, F(x)) \cap (0, 1) \in \mathcal{B}((0, 1)).$$

Da diese halboffene Mengen ein Erzeugendensystem von  $\mathcal{B}(\mathbb{R})$  bilden, folgt bereits die Messbarkeit von  $X$ , also ist  $X$  eine ZV. Insbesondere hat die Menge  $\{X \leq x\}$  gerade LEBESGUE-Maß  $F(x)$  und damit hat  $X$  die Verteilungsfunktion  $F$ .  $\square$

**Folgerung I.20**

Ist  $\mathbb{P}$  Wahrscheinlichkeitsmaß auf  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  und  $F$  die zugehörige Verteilungsfunktion. Dann besitzt  $\mathbb{P}$  genau eine Dichtefunktion  $\rho$ , wenn  $F$  stetig differenzierbar ist, denn dann gelten

$$F(x) = \int_{-\infty}^x \rho(x) \, dx, \text{ bzw. } \rho(x) = F'(x)$$

*Beweis.* Folgt aus Satz I.8, der Satz II.6 der Verteilungsfunktion und dem Eindeigkeitssatz ????.  $\square$

## Kapitel II

# *Erste Standardmodelle der Wahrscheinlichkeitstheorie*

## Diskrete Verteilungen

### 1. Diskrete Gleichverteilungen

Erinnerung:

► **Erinnerung (Definition I.I.10)**

Ist  $\Omega$  endlich, so heißt das Wahrscheinlichkeitsmaß mit Zähldichte

$$\rho(\omega) = \frac{1}{|\Omega|}, \omega \in \Omega$$

(diskrete) Gleichverteilung auf  $\Omega \rightarrow U(\Omega)$

Es gilt das für jedes  $A \in \mathcal{P}(\Omega)$

$$\mathbb{P}(A) = \frac{|A|}{|\Omega|}$$

Anwendungsbeispiele sind faires Würfeln, fairer Münzwurf, Zahlenlotto, ...


### 2. Urnenmodelle

Ein “Urnenmodell” ist eine abstrakte Darstellung von Zufallsexperimenten, bei denen zufällig Stichproben aus einer gegebenen Menge “gezogen” werden.

**Definition (Urne)**

Eine Urne ist ein Behältnis in welchem sich farbige/nummerierte Kugeln befinden, die ansonsten ununterscheidbar sind.

Aus der Urne ziehe man blind/zufällig eine oder mehrere Kugeln und notiere Farbe/Zahl.



**Abbildung II.1:** Urnenmodell**2.1. Urnenmodell mit Zurücklegen: Multinomial-Verteilung**

Gegeben: Urne mit  $N$  Kugeln, verschiedenfarbig mit Farben aus  $E$ ,  $|E| \geq 2$

Ziehe:  $n$  Stichproben/Kugeln, wobei nach jedem Zug die Kugel wieder zurückgelegt wird. Uns interessiert die Farbe in jedem Zug, setze also

$$\Omega = E^n \text{ und } \mathcal{F} = \mathcal{P}(\Omega)$$

Zur Bestimmung eines geeigneten Wahrscheinlichkeitsmaßes, nummerieren wir die Kugeln mit  $1, \dots, N$ , so dass alle Kugeln der Farbe  $a \in E$  eine Nummer aus  $F_a \subset \{1, \dots, N\}$  tragen. Würden wir die Nummern notieren, so wäre

$$\bar{\Omega} = \{1, \dots, N\}^n \text{ und } \bar{\mathcal{F}} = \mathcal{P}(\bar{\Omega})$$

und wir könnten die Gleichverteilung  $\bar{\mathbb{P}} = \mathbf{U}(\bar{\Omega})$  als Wahrscheinlichkeitsmaß für einen einzelnen Zug verwenden. Für den Übergang zu  $\Omega$  konstruieren wir Zufallsvariablen. Die Farbe im  $i$ -ten Zug wird beschrieben durch

$$X_i : \bar{\Omega} \rightarrow E \text{ mit } \bar{\omega} = (\bar{\omega}_1, \dots, \bar{\omega}_n) \mapsto a \text{ falls } \bar{\omega}_i \in F_a.$$

Der Zufallsvektor

$$X = (X_1, \dots, X_n) : \bar{\Omega} \rightarrow \Omega$$

beschreibt dann die Abfolge der Farben. Für jedes  $\omega \in \Omega$  gilt dann

$$\{X = \omega\} = F_{\omega_1} \times \dots \times F_{\omega_n} = \bigtimes_{i=1}^n F_{\omega_i}$$

und damit

$$\begin{aligned} \mathbb{P}(\{\omega\}) &= \bar{\mathbb{P}}(X^{-1}(\{\omega\})) = \bar{\mathbb{P}}(X = \omega) \\ &= \frac{|F_{\omega_1}| \cdots |F_{\omega_n}|}{|\bar{\Omega}|} \\ &= \prod_{i=1}^n \frac{|F_{\omega_i}|}{N} =: \prod_{i=1}^n \rho(\omega_i) \end{aligned}$$

Zähldichten, die sich als Produkte von Zähl-dichten schreiben lassen, werden auch als Produktdichten bezeichnet ( $\nearrow$  Abschnitt 2). Sehr oft interessiert bei einem Urnenexperiment nicht die Reihenfolge der gezogenen Farben, sondern nur die Anzahl der Kugeln in Farbe  $a \in E$  nach  $n$  Zügen. Dies entspricht

$$\hat{\Omega} = \left\{ k = (k_a)_{a \in E} \in \mathbb{N}_0^{|E|} : \sum_{a \in E} k_a = n \right\} \text{ und } \hat{\mathcal{F}} = \mathcal{P}(\hat{\Omega})$$



Den Übergang  $\Omega \rightarrow \hat{\Omega}$  beschreiben wir durch die Zufallsvariablen

$$Y_a(\omega) : \Omega \rightarrow \mathbb{N}_0 \text{ mit } \omega = (\omega_1, \dots, \omega_n) \mapsto \sum_{a \in E} \mathbb{1}_{\{a\}}(\omega_i)$$

und

$$Y = (Y_a)_{a \in E} : \Omega \rightarrow \hat{\Omega} = \left\{ k = (k_a)_{a \in E} : \sum_{a \in E} k_a = n \right\}$$

Wir erhalten

$$\begin{aligned} \mathbb{P}(Y = k) &= \mathbb{P}(Y_a = k_a, \ a \in E) \\ &= \sum_{\omega \in \Omega: Y(\omega) = k} \prod_{i=1}^n \rho(\omega_i) \\ &= \sum_{\omega \in \Omega: Y(\omega) = k} \prod_{a \in E} \rho(a) \\ &= \binom{n}{(k_a)_{a \in E}} \prod_{a \in E} \rho(a)^{k_a}, \end{aligned}$$

wobei

$$\binom{n}{(k_1, \dots, k_l)} = \begin{cases} \frac{n!}{k_1! k_2! \dots k_l!} & \sum_{i=1}^l k_i = n \\ 0 & \text{sonst} \end{cases}$$

der Multinomialkoeffizient ist, welcher die Anzahl der Möglichkeiten beschreibt,  $n$  Objekte in  $l$  Gruppen aufzuteilen, so dass Gruppe  $i$  gerade  $k_i$  Objekte beinhaltet.

**Definition II.1 (Multinomialverteilung)**

Sei  $l > 2, p = (p_1, \dots, p_l)$  eine Zähldichte und  $n \in \mathbb{N}$ , dann heißt die Verteilung auf

$\left\{ k = (k_i)_{i=1, \dots, l} \in \mathbb{N}_0^l : \sum_{i=1}^l k_i = n \right\}$  mit Zähldichte

$$m((k_1, \dots, k_l)) = \binom{n}{k_1, \dots, k_l} \prod_{i=1}^l p_i^{k_i}$$

Multinomialverteilung mit Parametern  $n$  und  $p$ . Wir schreiben auch  $\text{Multi}(n, p)$ .

■ **Beispiel II.2**

Eine Urne enthalte nur schwarze “1” und weiße “0” Kugeln, d.h.  $E = \{0, 1\}$ , und es sei  $\rho(1) = p$  gerade die Proportion der schwarzen Kugeln (= Wahrscheinlichkeit bei einem Zug schwarz zu ziehen), dann ist Wahrscheinlichkeit in  $n$  Zügen  $k$ -mal schwarz zu ziehen:

$$\binom{n}{k} \prod_{i=0,1} \rho(i)^{k_i} = \binom{n}{k} p^k (1-p)^{n-k}.$$

Ein solches (wiederholtes) Experiment mit nur zwei möglichen Ereignissen und fester Wahrscheinlichkeit  $p \in [0, 1]$  für eines der Ergebnisse nennen wir auch (wiederholtes) Bernoulliexperiment.

### Definition II.3 (Binomialverteilung, Bernoulli-Verteilung)

Sei  $p \in [0, 1]$  und  $n \in \mathbb{N}$ , dann heißt die Verteilung mit Zähldichte

$$\rho(k) = \binom{n}{k} p^k (1-p)^{n-k} \text{ mit } k \in \{0, 1, \dots, n\}.$$

Binomialverteilung auf  $\{0, \dots, n\}$  mit Parameter  $p$  (auch Erfolgswahrscheinlichkeit). Wir schreiben auch  $\text{Bin}(n, p)$ . Im Fall  $n = 1$  nennen wir die Verteilung mit Zähldichte

$$\rho(0) = 1 - p \text{ und } \rho(1) = p$$

auch Bernoulli-Verteilung mit Parameter  $p$  und schreiben  $\text{Bernoulli}(p)$ .

### Urnenmodell ohne Zurücklegen: Hypergeometrische Verteilung

Gegeben: Urne mit  $N$  Kugeln verschiedener Farben aus  $E$ ,

$$|E| \geq 2.$$

Es werden  $n \leq N$  Stichproben entnommen, wobei die gezogenen Kugeln nicht in die Urne zurückgelegt werden.

### 2.2. Urnenmodell ohne Zurücklegen: Hypergeometrische Verteilung

Gegeben: Urne mit  $N$  Kugeln verschiedener Farben aus  $E$ ,  $|E| \geq 2$ . Es werden  $n \leq N$  Stichproben entnommen, wobei die gezogenen Kugeln nicht in die Urne zurückgelegt werden.

#### ■ Beispiel II.4

Eine Urne enthalte  $S$  schwarze “1” und  $W$  weiße Kugeln “0” Kugeln, ( $E = \{0, 1\}, S + W = N$ ). Dann ist die Wahrscheinlichkeit in  $n$  Zügen ohne Zurücklegen gerade  $s$  schwarze und  $w$  weiße Kugeln zu ziehen

$$\rho(w) = \frac{\binom{W}{w} \binom{S}{s}}{\binom{N}{n}}, \quad 0 \leq s \leq S, 0 \leq w \leq W, s + w = n, S + W = N.$$

*Beweis.* Hausaufgabe 2.3!

□

### Definition II.5 (Hypergeometrische Verteilung)

Seien  $N \in \mathbb{N}, W \leq N, n \leq N$ , dann heißt die Verteilung auf  $\{0, \dots, n\}$  mit Zähldichte

$$\rho(w) = \frac{\binom{W}{w} \binom{N-W}{n-w}}{\binom{N}{n}}, \quad w = \max\{0, n - (N - W)\}, \dots, \min\{W, n\},$$

die Hypergeometrische Verteilung mit Parametern  $N, W, n$ . Wir schreiben  $\text{Hyper}(N, W, n)$ .

## 3. Poisson-Approximation und Poisson-Verteilung

$\text{Bin}(n, p)$  ist zwar explizit und elementar definiert, jedoch für große  $n$  mühsam auszuwerten. Für seltene Ereignisse ( $n$  groß,  $p$  klein) verwende daher:

### Satz II.6 (Poisson-Approximation)

Sei  $\lambda > 0$  und  $(p_n)_{n \in \mathbb{N}}$  eine Folge in  $[0, 1]$  mit

$$np_n \rightarrow \lambda, \quad n \rightarrow \infty.$$

Dann gilt  $\forall k \in \mathbb{N}_0$  für die Zähldichte der  $\text{Bin}(n, p_n)$ -Verteilung

$$\lim_{n \rightarrow \infty} \binom{n}{k} p_n^k (1 - p_n)^{n-k} = e^{-\lambda} \frac{\lambda^k}{k!}.$$

*Beweis.* Sei  $k \in \mathbb{N}_0$  fix, dann

$$\begin{aligned} \binom{n}{k} &= \frac{n!}{k!(n-k)!} = \frac{n^k}{k!} \frac{n(n-1) \cdots (n-k+1)}{n^k} \\ &= \frac{n^k}{k!} \cdot 1 \cdot \left(1 - \frac{1}{n} \cdots \frac{k-1}{n}\right) \\ &\stackrel{n \rightarrow \infty}{\sim} \frac{n^k}{k!}, \end{aligned}$$

wobei  $a(l) \stackrel{l \rightarrow \infty}{\sim} b(l) \Leftrightarrow \frac{a(l)}{b(l)} \xrightarrow{l \rightarrow \infty} 1$ . Damit

$$\begin{aligned} \binom{n}{k} p_n^k (1 - p_n)^{n-k} &\stackrel{n \rightarrow \infty}{\sim} \frac{n^k}{k!} p_n^k (1 - p_n)^{n-k} \\ &\stackrel{n \rightarrow \infty}{\sim} \frac{\lambda^k}{k!} (1 - p_n)^n \\ &= \frac{\lambda^k}{k!} \left(1 - \frac{np_n}{n}\right)^n \\ &\xrightarrow{n \rightarrow \infty} \frac{\lambda^k}{k!} e^{-\lambda}. \end{aligned}$$

Der letzte Schritt hat eine verwandte Ungleichung zur BERNOULLI-Ungleichung genutzt

$$\lim_{n \rightarrow \infty} \left(1 - \frac{np_n}{n}\right)^n \leq \lim_{n \rightarrow \infty} e^{-\frac{np_n}{n}} = \lim_{n \rightarrow \infty} e^{-np_n} \sim e^{-\lambda}$$

(Falls jemand eine Idee hat wie man die Ungleichung beweist, bitte bescheid sagen, oder einfach hinzufügen.)  $\square$

Der erhaltene Grenzwert liefert die Zähldichte auf  $\mathbb{N}_0$ , denn

$$\sum_{k=0}^{\infty} \frac{\lambda^k}{k!} e^{-\lambda} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = e^{-\lambda} e^{\lambda} = 1.$$

### Definition II.7 (Poissonverteilung)

Sei  $\lambda > 0$ . Dann heißt das auf  $(\mathbb{N}_0, \mathbb{P}(\mathbb{N}_0))$  definierte Wahrscheinlichkeitsmaß mit

$$\mathbb{P}(\{k\}) = \frac{\lambda^k}{k!} e^{-\lambda} \quad k \in \mathbb{N}_0,$$

Poissonverteilung mit Parameter  $\lambda$ . Schreibe  $\text{Poisson}(\lambda)$ .

Die Poissonverteilung ist ein natürliches Modell für die Anzahl von zufälligen, seltenen Ereignissen (z.B. Tore im Fußballspiel, Schadensfälle einer Versicherung, ...).

## Kapitel III

# *Bedingte Wahrscheinlichkeiten und (Un-)abhängigkeit*

## 1. Bedingte Wahrscheinlichkeiten

### ■ Beispiel III.1

Das Würfeln mit zwei fairen, sechsseitigen Würfeln können wir mit

$$\Omega = \{(i, j) : i, j \in \{1, \dots, 6\}\}$$

und  $\mathbb{P} = \mathbb{U}(\Omega)$ . Da  $|\Omega| = 36$  gilt also

$$\mathbb{P}(\{\omega\}) = \frac{1}{36} \quad \forall \omega \in \Omega.$$

Betrachte das Ereignis

$$A = \{(i, j) \in \Omega : i + j = 8\},$$

dann folgt

$$\mathbb{P}(A) = \frac{5}{36}.$$

Werden die beiden Würfe nacheinander ausgeführt, so kann nach dem ersten Wurf eine Neubewertung der Wahrscheinlichkeit von  $A$  erfolgen.

Ist z.B.

$$B = \{(i, j) \in \Omega, i = 4\}$$

eingetreten, so kann die Summe 8 nur durch eine weitere 4 realisiert werden, also mit Wahrscheinlichkeit

$$\frac{1}{6} = \frac{|A \cap B|}{|B|}.$$

Das Eintreten von  $B$  führt also dazu, dass das Wahrscheinlichkeitsmaß  $\mathbb{P}$  durch ein neues Wahrscheinlichkeitsmaß  $\mathbb{P}_B$  ersetzt werden muss. Hierbei sollte gelten:

$$\text{Renormierung: } \mathbb{P}_B(\Omega) = 1 \tag{R}$$

$$\text{Proportionalität: Für alle } A \in \mathcal{F} \text{ mit } A \subseteq B \text{ gilt } \mathbb{P}_B(A) = c_B \mathbb{P}(A) \text{ mit einer Konstante } c_B. \tag{P}$$

**Lemma III.2**

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum und  $B \in \mathcal{F}$  mit  $\mathbb{P}(B) > 0$ . Dann gibt es genau ein Wahrscheinlichkeitsmaß  $\mathbb{P}_B$  auf  $(\Omega, \mathcal{F})$  mit den Eigenschaften (R) und (P). Dieses ist gegeben durch

$$\mathbb{P}_B(A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \quad \forall A \in \mathcal{F}.$$

*Beweis.* Offenbar erfüllt  $\mathbb{P}_B$  wie definiert (R) und (P). Umgekehrt erfüllt  $\mathbb{P}$  (R) und (P). Dann folgt für  $A \in \mathcal{F}$ :

$$\mathbb{P}_B(A) = \mathbb{P}_B(A \cap B) + \underbrace{\mathbb{P}_B(A \setminus B)}_{=0, \text{ wegen (R)}} \stackrel{(P)}{=} c_B \mathbb{P}(A \cap B).$$

Für  $A = B$  folgt zudem aus (R)

$$1 = \mathbb{P}_B(B) = c_B \mathbb{P}(B)$$

also  $c_B = \mathbb{P}(B)^{-1}$ . □

**Definition III.3 (Bedingte Wahrscheinlichkeit)**

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum und  $B \in \mathcal{F}$  mit  $\mathbb{P}(B) > 0$ . Dann heißt

$$\mathbb{P}(A \mid B) := \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \quad \text{mit } A \in \mathcal{F}$$

die bedingte Wahrscheinlichkeit von  $A$  gegeben  $B$ . Falls  $\mathbb{P}(B) = 0$ , setze

$$\mathbb{P}(A \mid B) = 0 \quad \forall A \in \mathcal{F}$$

**■ Beispiel III.4**

In der Situation Beispiel III.1 gilt

$$A \cap B = \{(4, 4)\}$$

und damit

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{\frac{1}{36}}{\frac{1}{6}} = \frac{1}{6}$$

Aus Definition III.3 ergibt sich

**Lemma III.5 (Multiplikationsformel)**

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  ein Wahrscheinlichkeitsraum und  $A_1, \dots, A_n \in \mathcal{F}$ . Dann gilt

$$\mathbb{P}(A_1 \cap \dots \cap A_n) = \mathbb{P}(A_1) \mathbb{P}(A_2 \mid A_1) \dots \mathbb{P}(A_n \mid A_1 \cap \dots \cap A_{n-1})$$

*Beweis.* Ist  $\mathbb{P}(A_1 \cap \dots \cap A_n) = 0$ , so gilt auch  $\mathbb{P}(A_n \mid \bigcap_{i=1}^{n-1} A_i) = 0$ . Andernfalls sind alle Faktoren der rechten

Seite ungleich Null und

$$\begin{aligned} \mathbb{P}(A_1)\mathbb{P}(A_2 | A_1) \dots \mathbb{P}(A_n | \bigcap_{i=1}^{n-1} A_i) &= \mathbb{P}(A_1) \cdot \frac{\mathbb{P}(A_1 \cap A_2)}{\mathbb{P}(A_1)} \dots \frac{\mathbb{P}(\bigcap_{i=1}^n A_i)}{\mathbb{P}(\bigcap_{i=1}^{n-1} A_i)} \\ &= \mathbb{P}(\bigcap_{i=1}^n A_i) \end{aligned} \quad \square$$

Stehen die  $A_i$  in Lemma III.5 in einer (zeitlichen) Abfolge, so liefert Formel einen Hinweis wie Wahrscheinlichkeitsmaße für Stufenexperimente konstruiert werden können. Ein Stufenexperiment aus  $n$  nacheinander ausgeführten Teilexperimenten lässt sich als Baumdiagramm darstellen.




Abbildung III.1: Lemma III.5

### Satz III.6 (Konstruktion des Wahrscheinlichkeitsmaßes eines Stufenexperiments)

Gegeben seien  $n$  Ergebnisräume  $\Omega_i = \{\omega_i(1), \dots, \omega_i(k)\}$ ,  $k \in \mathbb{N} \cup \{\infty\}$  und es sei  $\Omega = \times_{i=1}^n \Omega_i$  der zugehörige Produktraum. Weiter seien  $\mathcal{F}_i$   $\sigma$ -Algebren auf  $\Omega_i$  und  $\mathcal{F} = \bigotimes_{i=1}^n \mathcal{F}_i$  die Produkt- $\sigma$ -Algebra auf  $\Omega$ . Setze  $\omega = (\omega_1, \dots, \omega_n)$  und

$$[\omega_1, \dots, \omega_m] := \{\omega_1\} \times \dots \times \{\omega_m\} \times \Omega_{m+1} \times \dots \times \Omega_n, \quad m \leq n$$

$$\mathbb{P}(\{\omega_m\}[\omega_1, \dots, \omega_{m-1}])$$

für die Wahrscheinlichkeit in der  $m$ -ten Stufe des Experiments  $\omega_m$  zu beobachten, falls in den vorausgehenden Stufen  $\omega_1, \dots, \omega_{m-1}$  beobachten wurden. Dann definiert

$$\mathbb{P}(\{\omega\}) := \mathbb{P}(\{\omega_1\}) \prod_{m=2}^n \mathbb{P}(\{\omega_m\} | [\omega_1, \dots, \omega_{m-1}])$$

ein Wahrscheinlichkeitsmaß auf  $(\Omega, \mathcal{F}, \mathbb{P})$ .

*Beweis.* Nachrechnen! □

### ■ Beispiel III.7 (Polya-Urne)

Gegeben sei eine Urne mit  $s$  schwarzen und  $w$  weißen Kugeln. Bei jedem Zug wird die gezogene

Kugel zusammen mit  $c \in \mathbb{N}_0 \cup \{-1\}$  weiteren Kugeln derselben Farbe zurückgelegt.

- $c = 0$ : Urnenmodell mit Zurücklegen
- $c = -1$ : Urnenmodell ohne Zurücklegen

Beide haben wir schon in Kapitel 2.2 gesehen.

Sei deshalb  $c \in \mathbb{N}$ . (Modell für zwei konkurrierende Populationen) Ziehen wir  $n$ -mal, so haben wir ein  $n$ -Stufenexperiment mit

$$\Omega = \{0, 1\}^n \text{ mit } 0 = \text{“weiß”}, 1 = \text{“schwarz”} \quad (\Omega_i = \{0, 1\})$$

Zudem gelten im ersten Schritt

$$\mathbb{P}(\{0\}) = \frac{w}{s+w} \text{ und } \mathbb{P}(\{1\}) = \frac{s}{s+w}$$

sowie

$$\mathbb{P}(\{\omega_m\} \mid [\omega_1, \dots, \omega_{m-1}]) = \begin{cases} \frac{w+c(m-1-\sum_{i=1}^{m-1} \omega_i)}{s+w+c(m-1)} & \omega_m = 0 \\ \frac{s+c \sum_{i=1}^{m-1} \omega_i}{s+w+c(m-1)} & \omega_m = 1 \end{cases}$$

Mit Satz III.6 folgt als Wahrscheinlichkeitsmaß auf  $(\Omega, \mathcal{P}(\Omega))$

$$\begin{aligned} \mathbb{P}(\{(\omega_1, \dots, \omega_n)\}) &= \mathbb{P}(\{\omega_1\}) \prod_{m=2}^n \mathbb{P}(\{\omega_m\} \mid [\omega_1, \dots, \omega_{m-1}]) \\ &= \frac{\prod_{i=0}^{l-1} (s+c \cdot i) \prod_{i=0}^{n-l-1} (w+c \cdot j)}{\prod_{i=0}^n (s+w+c \cdot i)} \text{ mit } l = \sum_{i=1}^n \omega_i. \end{aligned}$$

Definiere wir nun die Zufallsvariable

$$S_n : \Omega \rightarrow \mathbb{N}_0 \text{ mit } (\omega_1, \dots, \omega_n) \mapsto \sum_{i=1}^n \omega_i$$

welche die Anzahl der gezogenen schwarzen Kugeln modelliert, so folgt

$$\mathbb{P}(S_n = l) = \binom{n}{l} \frac{\prod_{i=0}^{l-1} (s+c \cdot i) \prod_{j=0}^{n-l-1} (w+c \cdot j)}{\prod_{i=0}^n (s+w+c \cdot i)}$$

Mittels  $a := s/c, b := w/c$  folgt

$$\begin{aligned} \mathbb{P}(S_n = l) &= \binom{n}{l} \frac{\prod_{i=0}^{l-1} (-a-i) \prod_{j=0}^{n-l-1} (-b-j)}{\prod_{i=0}^n (-a-b-i)} = \frac{\binom{-a}{l} \binom{-b}{n-l}}{\binom{-a-b}{n}} \\ &\text{mit } l \in \{0, \dots, n\} \end{aligned}$$

Dies ist die POLYA-Verteilung auf  $\{0, \dots, n\}, n \in \mathbb{N}$  mit Parametern  $a, b > 0$ .

### ■ Beispiel III.8

Ein Student beantwortet eine Multiple-Choice-Frage mit 4 Antwortmöglichkeiten, eine davon ist

richtig. Er kennt die richtige Antwort mit Wahrscheinlichkeit  $2/3$ . Wenn er diese kennt, so wählt er diese aus. Andernfalls wählt er zufällig (gleichverteilt) eine Antwort. Betrachte

$$W = \{\text{richtige Antwort gewusst}\}$$

$$R = \{\text{Richtige Antwort gewählt}\}$$

Dann gilt

$$\mathbb{P}(W) = \frac{2}{3}, \mathbb{P}(R | W) = 1, \mathbb{P}(R | W^C) = \frac{1}{4}$$

Angenommen, der Student gibt die richtige Antwort. Mit welcher Wahrscheinlichkeit hat er diese gewusst?  $\rightarrow \mathbb{P}(W | R) = ?$

### Satz III.9

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum und  $\Omega = \bigcup_{i \in I} B_i$  eine höchstens abzählbare Zerlegung in paarweise disjunkte Ereignisse  $B_i \in \mathcal{F}$ .

1. Satz von der totalen Wahrscheinlichkeit: Für alle  $A \in \mathcal{F}$  gilt

$$\mathbb{P}(A) = \sum_{i \in I} \mathbb{P}(A | B_i) \mathbb{P}(B_i) \quad (\text{totale Wahrscheinlichkeit})$$

2. Satz von BAYES: Für alle  $A \in \mathcal{F}$  mit  $\mathbb{P}(A) > 0$  und alle  $k \in I$

$$\mathbb{P}(B_k | A) = \frac{\mathbb{P}(A | B_k) \mathbb{P}(B_k)}{\sum_{i \in I} \mathbb{P}(A | B_i) \mathbb{P}(B_i)} \quad (\text{Bayes})$$

*Beweis.* 1. Es gilt:

$$\sum_{i \in I} \mathbb{P}(A | B_i) \mathbb{P}(B_i) \stackrel{\text{Def}}{=} \sum_{i \in I} \frac{\mathbb{P}(A \cap B_i)}{\mathbb{P}(B_i)} \mathbb{P}(B_i) = \sum_{i \in I} \mathbb{P}(A \cap B_i) \stackrel{\sigma\text{-Add.}}{=} \mathbb{P}(A)$$

2.

$$\mathbb{P}(B_k | A) \stackrel{\text{Def}}{=} \frac{\mathbb{P}(A \cap B_k)}{\mathbb{P}(A)} \stackrel{\text{Def}}{=} \frac{\mathbb{P}(A | B_k) \mathbb{P}(B_k)}{\mathbb{P}(A)}$$

also folgt (b) aus (a). □

### ■ Beispiel III.10

In der Situation von Definition III.3 folgt mit Satz III.9 ([totale Wahrscheinlichkeit](#))

$$\begin{aligned} \mathbb{P}(R) &= \mathbb{P}(R | W) \mathbb{P}(W) + \mathbb{P}(R | W^C) \mathbb{P}(W^C) \\ &= 1 \cdot \frac{2}{3} + \frac{1}{4} \cdot \frac{1}{3} = \frac{3}{4} \end{aligned}$$



und mit Satz III.9 (Bayes)

$$\mathbb{P}(W \mid R) = \frac{\mathbb{P}(R \mid W)\mathbb{P}(W)}{\mathbb{P}(R)} = \frac{1 \cdot \frac{2}{3}}{\frac{3}{4}} = \frac{8}{9} \text{ für die gesuchte Wahrscheinlichkeit.}$$




Abbildung III.2: Satz III.3

## 2. (Un)abhängigkeit

In vielen Fällen besagt die Intuition über verschiedene Zufallsexperimente / Ereignisse, dass diese sich nicht gegenseitig beeinflussen. Für solche  $A, B \in \mathcal{F}$  mit  $\mathbb{P}(A) > 0, \mathbb{P}(B) > 0$  sollte gelten

$$\mathbb{P}(A \mid B) = \mathbb{P}(A), \quad \mathbb{P}(B \mid A) = \mathbb{P}(B).$$

### Definition III.11 ((Stochastische) Unabhängigkeit)

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum. Zwei Ereignisse  $A, B \in \mathcal{F}$  heißt (stochastisch) unabhängig bezüglich  $\mathbb{P}$ , falls

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B).$$

Wir schreiben auch  $A \perp\!\!\!\perp B$ .

### ■ Beispiel III.12

Würfeln mit 2 fairen, sechsseitigen Würfeln:

$$\Omega = \{(i, j) \mid i, j \in \{1, \dots, n\}\}, \quad \mathcal{F} = \mathcal{P}(\Omega), \quad \mathbb{P} = \mathbb{U}(\Omega)$$

Betrachte

$$A := \{(i, j) \in \Omega, i \text{ gerade}\}$$

$$B := \{(i, j) \in \Omega, j \leq 2\}.$$

In diesem Fall, erwarten wir intuitiv Unabhängigkeit von  $A$  und  $B$ .

In der Tat ist

$$\mathbb{P}(A) = \frac{1}{2}, \quad \mathbb{P}(B) = \frac{1}{3} \text{ und } \mathbb{P}(A \cap B) = \frac{1}{6}$$

was

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$$

erfüllt. Betrachte nun

$$C := \{(i, j) \in \Omega \mid i + j = 7\}$$

$$D := \{(i, j) \in \Omega \mid i = 6\}$$

dann gilt

$$\mathbb{P}(C) = \frac{1}{6}, \quad \mathbb{P}(D) = \frac{1}{6}$$

und wegen  $C \cap D = \{(6, 1)\}$  folgt

$$\mathbb{P}(C \cap D) = \frac{1}{36} = \frac{1}{6} \frac{1}{6} = \mathbb{P}(C) \cdot \mathbb{P}(D)$$

$C$  und  $D$  sind also stochastisch unabhängig, obwohl eine kausale Abhängigkeit vorliegt!

### Definition III.13 (Unabhängigkeit bezüglich $\mathbb{P}$ )

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum und  $I \neq \emptyset$  endliche Indexmenge. Dann heißt die Familie  $(A_i)_{i \in I}$  von Ereignissen in  $\mathcal{F}$  unabhängig bezüglich  $\mathbb{P}$ , falls für alle  $J \subseteq I, J \neq \emptyset$  gilt:

$$\mathbb{P}\left(\bigcap_{i \in J} A_i\right) = \prod_{i \in J} \mathbb{P}(A_i)$$

Offensichtlich impliziert die Unabhängigkeit einer Familie die paarweise Unabhängigkeit je zweier Familienmitglieder nach Definition III.11. Umgekehrt gilt dies nicht!

### ■ Beispiel III.14 (Abhängigkeit trotz paarweiser Unabhängigkeit)

Betrachte zweifaches Bernoulliexperiment mit Erfolgswahrscheinlichkeit  $1/2$ , d.h.

$$\Omega = \{0, 1\}^2, \quad \mathcal{F} = \mathcal{P}(\Omega), \quad \mathbb{P} = \mathbb{U}(\Omega)$$

sowie

$$A = \{1\} \times \{0, 1\} \quad (\text{Münzwurf: erster Wurf ist Zahl})$$

$$B = \{0, 1\} \times \{1\} \quad (\text{Münzwurf: zweiter Wurf ist Zahl})$$

$$C = \{(0, 0), (1, 1)\} \quad (\text{beide Würfe haben selbes Ergebnis})$$

Dann gelten  $\mathbb{P}(A) = \frac{1}{2} = \mathbb{P}(B) = \mathbb{P}(C)$  und

$$\begin{aligned}\mathbb{P}(A \cap B) &= \mathbb{P}(\{(1, 1)\}) = \frac{1}{4} = \mathbb{P}(A)\mathbb{P}(B) \\ \mathbb{P}(A \cap C) &= \mathbb{P}(\{(1, 1)\}) = \frac{1}{4} = \mathbb{P}(A)\mathbb{P}(C) \\ \mathbb{P}(B \cap C) &= \mathbb{P}(\{(1, 1)\}) = \frac{1}{4} = \mathbb{P}(B)\mathbb{P}(C)\end{aligned}$$

also paarweise Unabhängigkeit. Aber

$$\mathbb{P}(A \cap B \cap C) = \mathbb{P}(\{(1, 1)\}) = \frac{1}{4} \neq \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C)$$

und  $A, B, C$  sind nicht stochastisch unabhängig.

### Definition III.15 (Unabhängige $\sigma$ -Algebren)

Seien  $(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum,  $I \neq \emptyset$  Indexmenge und  $(E_i, \mathcal{E}_i)$  Messräume

1. Die Familie  $\mathcal{F}_i \subset \mathcal{F}, i \in I$ , heißen unabhängig, wenn für die  $J \subseteq I, J \neq \emptyset, |J| < \infty$  gilt

$$\mathbb{P}\left(\bigcap_{i \in J} A_i\right) = \prod_{i \in J} \mathbb{P}(A_i) \quad \text{für beliebige } A_i \in \mathcal{F}_i, i \in J$$

2. Die Zufallsvariable  $X_i : (\Omega, \mathcal{F}) \rightarrow (E_i, \mathcal{E}_i), i \in I$ , heißen unabhängig, wenn die  $\sigma$ -Algebren

$$\sigma(X_i) = X_i^{-1}(\mathcal{E}_i) = \{\{X_i \in F\} : F \in \mathcal{E}_i\}, \quad i \in I$$

unabhängig sind.

### Lemma III.16 (Zusammenhang der Definitionen)

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum,  $I \neq \emptyset, A \in \mathcal{F}, i \in I$ . Die folgenden Aussagen sind äquivalent:

1. Die Ereignisse  $A_i, i \in I$  sind unabhängig.
2. Die  $\sigma$ -Algebren  $\sigma(A_i), i \in I$  sind unabhängig.
3. Die Zufallsvariablen  $\mathbb{1}_{A_i}, i \in I$  sind unabhängig.

*Beweis.* Da die Unabhängigkeit über endliche Teilmengen definiert ist, können wir oBdA  $I = \{1, \dots, n\}$  annehmen.

- Da  $\sigma(\mathbb{1}_{A_i}) = \sigma(A_i)$  folgt die Äquivalenz von 2. und 3. direkt aus Definition III.15.
- Zudem ist 2.  $\rightarrow$  1. klar!
- Für 1  $\rightarrow$  2. genügt es zu zeigen, dass

$$A_1, \dots, A_n \text{ unabhängig} \Rightarrow B_1, \dots, B_n \text{ unabhängig mit } B_i \in \{\emptyset, A_i, A_i^C, \Omega\}.$$

Rekursiv folgt dies bereits aus

$$A_1, \dots, A_n \text{ unabhängig} \Rightarrow B_1, A_2, \dots, A_n \text{ unabhängig mit } B_1 \in \{\emptyset, A_1, A_1^C, \Omega\}.$$

Für  $B_1 \in \{\emptyset, A_1, \Omega\}$  ist dies klar.

Sei also  $B_1 = A_1^C$  und  $J \subseteq I, J \neq \emptyset$ . Falls  $1 \notin J$ , ist nichts zu zeigen. Sei  $1 \in J$ , dann gilt mit

$$A = \bigcap_{i \in J, i \neq 1} A_i$$

sicherlich

$$\begin{aligned} \mathbb{P}(A_1^C \cap A) &= \mathbb{P}(A \setminus (A_1 \cap A)) \\ &= \mathbb{P}(A) - \mathbb{P}(A_1 \cap A) \\ &= \prod_{i \in J \setminus \{1\}} \mathbb{P}(A_i) - \prod_{i \in J} \mathbb{P}(A_i) \\ &= (1 - \mathbb{P}(A_1)) \prod_{i \in J \setminus \{1\}} \mathbb{P}(A_i) \\ &= \mathbb{P}(A_1^C) \prod_{i \in J \setminus \{1\}} \mathbb{P}(A_i) \end{aligned} \quad \square$$

Insbesondere zeigt Lemma III.16, dass wir in einer Familie unabhängiger Ereignisse beliebig viele Ereignisse durch ihr Komplement,  $\emptyset$  oder  $\Omega$  ersetzen können, ohne die Unabhängigkeit zu verlieren.

### Satz III.17

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum und  $\mathcal{F}_i \subseteq \mathcal{F}, i \in I$ , seien  $\cap$ -stabile Familien von Ereignissen. Dann gilt

$$\mathcal{F}_i, i \in I \text{ unabhängig} \iff \sigma(\mathcal{F}_i), i \in I \text{ unabhängig.}$$

*Beweis.* oBdA sei  $I = \{1, \dots, n\}$  und  $\Omega \in \mathcal{F}_i, i \in I$ .

- $\Leftarrow$ : trivial, da  $\mathcal{F}_i \subseteq \sigma(\mathcal{F}_i)$  und das Weglassen von Mengen erlaubt ist.
- $\Rightarrow$ : zeigen wir rekursiv

1. Wähle  $F_i \in \mathcal{F}_i, i = 2, \dots, n$  und definiere für  $F \in \sigma(\mathcal{F}_1)$  die endlichen Maße

$$\mu(F) = \mathbb{P}(F \cap F_2 \cap \dots \cap F_n) \text{ und } \nu(F) = \mathbb{P}(F) \mathbb{P}(F_2) \dots \mathbb{P}(F_n)$$

2. Da die Familien  $\mathcal{F}_i$  unabhängig sind, gilt  $\mu|_{\mathcal{F}_1} = \nu|_{\mathcal{F}_1}$ . Nach dem Eindeutigkeitsatz für Maße (Satz I.I.9) folgt  $\mu|_{\sigma(\mathcal{F}_1)} = \nu|_{\sigma(\mathcal{F}_1)}$  also

$$\mathbb{P}(F \cap F_2 \cap \dots \cap F_n) = \mathbb{P}(F) \mathbb{P}(F_2) \dots \mathbb{P}(F_n)$$

für alle  $F \in \sigma(\mathcal{F}_1)$  und  $F_i \in \mathcal{F}_i, i = 2, \dots, n$ . Da  $\Omega \in \mathcal{F}_i$  für alle  $i$  gilt die erhaltene Produktformel für alle Teilmengen  $J \subseteq I$ .

Also sind

$$\sigma(\mathcal{F}_1), \mathcal{F}_2, \dots, \mathcal{F}_n \text{ unabhängig}$$

3. Wiederholtes Anwenden von 1 und 2 liefert den Satz. □

Mit Satz III.17 folgen:

**Folgerung III.18**

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum und

$$\mathcal{F}_{i,j} \subseteq \mathcal{F}, \quad 1 \leq i \leq n, 1 \leq j \leq m(i)$$

unabhängige,  $\cap$ -stabile Familien. Dann sind auch

$$\mathcal{G}_i = \sigma(\mathcal{F}_{i,1}, \dots, \mathcal{F}_{i,m(i)}), \quad 1 \leq i \leq n$$

unabhängig.

**Folgerung III.19**

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum und

$$X_{ij} : \Omega \rightarrow E, \quad 1 \leq i \leq n, 1 \leq j \leq m(i)$$

unabhängige Zufallsvariablen. Zudem seien  $f_i : E^{m(i)} \rightarrow \mathbb{R}$  messbar. Dann sind auch die Zufallsvariablen

$$f_i(X_{i,1}, \dots, X_{i,m(i)}), \quad 1 \leq i \leq n$$

unabhängig.

**■ Beispiel III.20**

$X_1, \dots, X_n$  unabhängige reelle Zufallsvariablen. Dann sind auch

$$Y_1 = X_1, Y_2 = X_2 + \dots + X_n$$

unabhängig.

*Beweis* (Folgerung III.18). OBdA sei  $\Omega \in \mathcal{F}_{i,j} \forall i, j$ . Dann sind die Familien:

$$\mathcal{F}_i^\cap := \{F_{i,1} \cap \dots \cap F_{i,m(i)} \mid F_{i,j} \in \mathcal{F}_{i,j}, 1 \leq j \leq m(i)\}, 1 \leq i \leq n$$

$\cap$ -stabil, unabhängig und es gilt:  $\mathcal{F}_{i,1}, \dots, \mathcal{F}_{i,m(i)} \subseteq \mathcal{F}_i^\cap$  ( $\nearrow$  HA)! Nach Satz III.17 sind auch  $\sigma(\mathcal{F}_i^\cap)$  unabhängig. Damit folgt die Behauptung, da  $\sigma(\mathcal{F}_i^\cap) = \mathcal{G}_i$ :

$$\begin{aligned} \mathcal{F}_{i,1}, \dots, \mathcal{F}_{i,m(i)} &\subseteq \mathcal{F}_i^\cap \subseteq \sigma(\mathcal{F}_{i,1}, \dots, \mathcal{F}_{i,m(i)}) = \mathcal{G}_i \\ \Rightarrow \mathcal{G} = \sigma(\mathcal{F}_{i,1}, \dots, \mathcal{F}_{i,m(i)}) &\subseteq \sigma(\mathcal{F}_i^\cap) \subseteq \mathcal{G}_i. \end{aligned} \quad \square$$

*Beweis* (Folgerung III.19). Setze  $\mathcal{F}_{i,j} = \sigma(X_{i,j})$  und  $\mathcal{G}_i = \sigma(\mathcal{F}_{i,1}, \dots, \mathcal{F}_{i,m(i)})$ , dann sind nach Folgerung III.18 die  $\mathcal{G}_i, i = 1, \dots, n$  unabhängig. Zudem ist

$$Y_i := f_i(X_{i,1}, \dots, X_{i,m(i)})$$

$\mathcal{G}_i$  messbar, also  $\sigma(Y_i) \subseteq \mathcal{G}_i$ . Damit erben die  $Y_i$  die Unabhängigkeit der  $\mathcal{G}_i$ .  $\square$

**Satz III.21 (Unabhängigkeit von Zufallsvariablen)**

$(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum und  $X_1, \dots, X_n : (\Omega, \mathcal{F}) \rightarrow (E, \mathcal{E})$  Zufallsvariablen. Dann sind die folgenden Aussagen äquivalent:

1.  $X_1, \dots, X_n$  sind unabhängig
2.  $\mathbb{P}(X_1 \in A_1, \dots, X_n \in A_n) = \prod_{i=1}^n \mathbb{P}(X_i \in A_i) \quad \forall A_1, \dots, A_n \in \mathcal{E}.$
3. Die gemeinsame Verteilung der  $X_i$  entspricht dem Produktmaß der einzelnen Verteilungen

$$\mathbb{P}_{X_1, \dots, X_n} = \bigotimes_{i=1}^n \mathbb{P}_{X_i}$$

*Beweis.* Per Ringschluss:

$1 \Rightarrow 2$ : Seien  $A_1, \dots, A_n \in \mathcal{E}$  beliebig, dann gilt per Definition

$$\begin{aligned} \mathbb{P}_{X_1, \dots, X_n}(A_1 \times \dots \times A_n) &= \mathbb{P}(X_1 \in A_1, \dots, X_n \in A_n) \\ &= \mathbb{P}\left(\bigcap_{i=1}^n \{X_i \in A_i\}\right) \\ &\stackrel{\text{unabh}}{=} \prod_{i=1}^n \mathbb{P}(X_i \in A_i) \\ &= \prod_{i=1}^n \mathbb{P}_{X_i}(A_i) = \left(\bigotimes_{i=1}^n \mathbb{P}_{X_i}\right)(A_1 \times \dots \times A_n) \end{aligned}$$

$2 \Rightarrow 3$ : Aus der obigen Rechnung sehen wir, dass 2 bereits 3 impliziert für alle Rechtecke:  $\bigotimes_{i=1}^n A_i$ . Da die Familie der Rechtecke  $\cap$ -stabil ist und  $\mathbb{E}^{\otimes n}$  erzeugt, folgt die Aussage aus dem Eindeutigkeitssatz für Maße ???.

$3 \Rightarrow 1$ : Sei  $J \subseteq \{1, \dots, n\}$  und setze

$$A_i := \begin{cases} \text{beliebig} & \text{in } \mathbb{E}, i \in J \\ E & i \notin J. \end{cases}$$

Dann

$$\begin{aligned} \mathbb{P}(X_i \in A_i, i \in J) &= \mathbb{P}(X_i \in A_i, i = 1, \dots, n) \\ &= \prod_{i=1}^n \mathbb{P}(X_i \in A_i) \\ &= \prod_{i \in J} \mathbb{P}(X_i \in A_i). \end{aligned} \quad \square$$

**■ Beispiel III.22**

Im Urnenmodell mit Zurücklegen hat der Vektor  $X = (X_1, \dots, X_n)$  mit  $X_i$  = Farbe im  $i$ -ten Zug als Zähldichte die Produktdichte der  $X_i$ . Die  $X_1, \dots, X_n$  sind also unabhängig.

**2.1. Konstruktion unabhängiger Zufallsvariablen**

Kapitel I: Zu beliebiger Wahrscheinlichkeitsverteilung  $\mathbb{P}_X$  existiert Wahrscheinlichkeitsraum mit Zufallsvariable  $X$  auf diesem Wahrscheinlichkeitsraum, so dass  $X \sim \mathbb{P}_X$ .

1. Seien  $\mathbb{P}_{X_1}, \dots, \mathbb{P}_{X_n}$  Wahrscheinlichkeitsverteilungen auf  $(E, \mathbb{E})$ . Gibt es einen Wahrscheinlichkeitsraum  $(\Omega, \mathcal{F}, \mathbb{P})$  und Zufallsvariablen  $X_1, X_2$  unabhängig, so dass  $X_1 \sim \mathbb{P}_{X_1}$ ?
2. Wie kann ich beliebig (unendlich) viele unabhängige Zufallsvariablen konstruieren?

Wir beginnen mit 1:

Konstruiere zwei Wahrscheinlichkeitsräume  $(\Omega_i, \mathcal{F}_i, \mathbb{P}_i), i = 1, 2$  und Zufallsvariablen  $X_1, X_2$  mit  $X_i \sim \mathbb{P}_{X_i}$ . Auf dem Produktraum

$$\Omega = \Omega_1 \times \Omega_2, \quad \mathcal{F} := \mathcal{F}_1 \otimes \mathcal{F}_2 \text{ und } \mathbb{P} = \mathbb{P}_1 \otimes \mathbb{P}_2$$

definiere

$$\begin{aligned} X'_1 : \Omega_1 \times \Omega_2 &\rightarrow E : (\omega_1, \omega_2) \mapsto X_1(\omega_1) \\ X'_2 : \Omega_1 \times \Omega_2 &\rightarrow E : (\omega_1, \omega_2) \mapsto X_2(\omega_2) \end{aligned}$$

Dann gilt für beliebige Ereignisse:  $F_1, F_2 \in \mathbb{E}$

$$\underbrace{\{X'_1 \in F_1\} \cap \{X'_2 \in F_2\}}_{\supseteq \Omega = \Omega_1 \times \Omega_2} = \underbrace{\{X_1 \in F_1\}}_{\supseteq \Omega_1} \times \underbrace{\{X_2 \in F_2\}}_{\supseteq \Omega_2} \in \mathcal{F}_1 \times \mathcal{F}_2$$

und damit folgt die Messbarkeit der Abbildungen  $X'_1, X'_2$ , d.h.  $X'_1, X'_2$  sind Zufallsvariablen auf  $(\Omega, \mathcal{F})$ . Zudem gilt

$$\begin{aligned} \mathbb{P}(X'_1 \in F_1, X'_2 \in F_2) &= \mathbb{P}_1 \otimes \mathbb{P}_2(\{X_1 \in F_1\} \times \{X_2 \in F_2\}) \\ &= \mathbb{P}_1(X_1 \in F_1) \mathbb{P}_2(X_2 \in F_2), \end{aligned}$$

also

$$\mathbb{P}(X'_i \in F_i) = \mathbb{P}_i(X'_i \in F_i)$$

sowie nach Satz III.23  $X'_1 \perp\!\!\!\perp X'_2$ .

Wenn  $(\Omega_2, \mathcal{F}_1, \mathbb{P}_1) = (\Omega_2, \mathcal{F}_2, \mathbb{P}_2)$ , so liefert die obige Konstruktion zwei unabhängige Zufallsvariablen auf einem Wahrscheinlichkeitsraum. Andernfalls können wir auf den Produktraum ausweichen und  $X'_i$  anstelle von  $X_i$  betrachten. Die obige Konstruktion lässt sich direkt auf endlich viele Zufallsvariablen übertragen.

Zu 2:

**Satz III.23 (Satz von Kolmogorov)**

Sei  $I$  beliebige Indexmenge und  $(\Omega_i, \mathcal{F}_i, \mathbb{P}_i), i \in I$  Wahrscheinlichkeitsräume. Setze

$$\Omega_I := \prod_{i \in I} \Omega_i = \left\{ \omega : I \rightarrow \bigcup_{i \in I} \Omega_i, \omega_i \in \Omega_i, i \in I \right\}$$

$$\mathcal{F}_I := \sigma(\pi^{-1}(\mathcal{F}_i), i \in I)$$

wobei  $\pi_i : \Omega_I \rightarrow \Omega_i$  mit  $\omega \mapsto \omega_i$  die Projektionsabbildung. Dann existiert auf  $(\Omega_I, \mathcal{F}_I)$  genau ein Maß  $\mathbb{P}_I$ , sodass für alle  $H \subseteq I$  mit  $0 < |H| < \infty$  gilt

$$\pi_H(\mathbb{P}_I) = \bigotimes_{i \in H} \mathbb{P}_i,$$

wobei  $\pi_H : \Omega_I \rightarrow \Omega_H$  wiederum die Projektionsabbildung.

*Beweis.*  $\nearrow$  Schilling Maß und Integral, Satz 17.4. □

Sind auf den Wahrscheinlichkeitsräumen  $(\Omega_i, \mathcal{F}_i, \mathbb{P}_i), i \in I$ , nun Zufallsvariablen  $X_i : \Omega_i \rightarrow E$  gegeben, so definieren wir wie im Satz von Kolmogorov (Satz III.23)

$$(\Omega, \mathcal{F}, \mathbb{P}) := \left( \Omega_I, \mathcal{F}_I, \mathbb{P}_I = \bigotimes_{i \in I} \mathbb{P}_i \right) \text{ mit } \omega = (\omega_i)_{i \in I}$$

und wie im endlichen Fall

$$X'_i : \Omega \rightarrow E \text{ mit } X'_i(\omega) = X_i(\omega_i).$$

Da die Unabhängigkeit der Zufallsvariablen über endliche Teilfamilien definiert ist, folgt diese wie im endlichen Fall.

**2.2. Faltungen**

Seien  $X, Y$  zwei reelle und unabhängige Zufallsvariablen mit

$$X \sim \mathbb{P}_X \text{ und } Y \sim \mathbb{P}_Y.$$

Dann hat  $(X, Y)$  die Verteilung  $\mathbb{P}_X \otimes \mathbb{P}_Y$  auf  $\mathbb{R}^2$ . Andernfalls ist auch  $X + Y$  eine reelle Zufallsvariable, dann

$$X + Y = A(X, Y) \text{ mit } A : \mathbb{R}^2 \rightarrow \mathbb{R} : (x, y) \mapsto x + y.$$

$A$  ist stetig, also messbar. Die Verteilung von  $X + Y$  ist dann  $(\mathbb{P}_X \otimes \mathbb{P}_Y) \circ A^{-1}$ .



**Definition III.24 (Faltung)**

Seien  $\mathbb{P}_1, \mathbb{P}_2$  Wahrscheinlichkeitsmaße auf  $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$ . Das durch

$$\mathbb{P}_1 \star \mathbb{P}_2(F) = \iint \mathbb{1}_F(x+y) \mathbb{P}_1(dx) \mathbb{P}_2(dy)$$

definierte Wahrscheinlichkeitsmaß  $\mathbb{P}_1 \star \mathbb{P}_2 = (\mathbb{P}_1 \otimes \mathbb{P}_2) \circ A^{-1}$  auf  $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$  heißt Faltung von  $\mathbb{P}_1$  und  $\mathbb{P}_2$ .

**Satz III.25**

Seien  $X, Y : \Omega \rightarrow \mathbb{R}^n$  unabhängige Zufallsvariablen mit Verteilungen  $\mathbb{P}_X, \mathbb{P}_Y$ . Dann ist

$$\mathbb{P}_{X+Y} = \mathbb{P}_X \star \mathbb{P}_Y,$$

die Verteilung von  $X + Y$ .

*Beweis.* Siehe Herleitung Faltung. □

Faltung von Wahrscheinlichkeitsmaßen und Dichten besitzen wieder eine Dichte.

**Satz III.26**

Seien  $\mathbb{P}_1, \mathbb{P}_2$  Wahrscheinlichkeitsmaße auf  $(\mathbb{R}, \mathcal{B}(\mathbb{R}^n))$

1. Diskreter Fall: Sind  $\mathbb{P}_1, \mathbb{P}_2$  de facto Wahrscheinlichkeitsmaße auf  $(\mathbb{Z}, \mathcal{P}(\mathbb{Z}))$  mit Zähldichte  $\rho_1, \rho_2$ . Dann ist die Faltung  $\mathbb{P}_1 \star \mathbb{P}_2$  Wahrscheinlichkeitsmaß auf  $(\mathbb{Z}, \mathcal{P}(\mathbb{Z}))$  mit Zähldichte

$$\rho_1 \star \rho_2(k) = \sum_{l \in \mathbb{Z}} \rho_1(l) \rho_2(k-l).$$

2. Stetiger Fall: Besitzt  $\mathbb{P}_1, \mathbb{P}_2$  Dichtefunktionen  $\rho_1, \rho_2$ , so besitzt die Faltung  $\mathbb{P}_1 \star \mathbb{P}_2$  die Dichtefunktion

$$\rho_1 \star \rho_2(x) = \int_{\mathbb{R}} \rho_1(y) \rho_2(x-y) dy \quad x \in \mathbb{R}$$

*Beweis.* 1. Diskrete Fall: Sei  $k \in \mathbb{Z}$

$$\begin{aligned} (\mathbb{P}_1 \otimes \mathbb{P}_2)(A = k) &= \sum_{\substack{l_1, l_2 \in \mathbb{Z} \\ l_1 + l_2 = k}} \rho_1(l_1) \rho_2(l_2) \\ &= \rho_1 \star \rho_2(k) \end{aligned}$$

2. Stetiger Fall: Sei  $c \in \mathbb{R}$

$$\begin{aligned}
 \mathbb{P}_1 + \mathbb{P}_2((-\infty, c]) &= (\mathbb{P}_1 \otimes \mathbb{P}_2)(A \leq c) \\
 &= \int_{\mathbb{R}} \int_{\mathbb{R}} \mathbb{1}_{(-\infty, c]}(x+y) \rho_1(x) \rho_2(y) \, dx \, dy \\
 &\stackrel{y=z-x}{=} \int_{\mathbb{R}} \int_{\mathbb{R}} \mathbb{1}_{(-\infty, c]}(z) \rho_1(x) \rho_2(z-x) \, dx \, dz \\
 &= \int_{-\infty}^c \underbrace{\int_{\mathbb{R}} \rho_1(x) \rho_2(z-x) \, dx}_{\rho_1 \star \rho_2(z)} \, dz. \quad \square
 \end{aligned}$$

### ■ Beispiel III.27

Seien  $X \sim \text{Poisson}(\lambda), Y \sim \text{Poisson}(\mu)$  zwei unabhängigen reellen Zufallsvariablen (mit Werten in  $\mathbb{N}_0$ ). Dann ist  $X + Y$  eine Zufallsvariable mit Werten in  $\mathbb{N}_0$  und Zähldichte

$$\begin{aligned}
 \mathbb{P}(X + Y = k) &= \sum_{l \in \mathbb{Z}} \mathbb{P}(X = l) \mathbb{P}(Y = k - l) \\
 &= \sum_{l \in \mathbb{Z}} \frac{\lambda^l}{l!} e^{-\lambda} \frac{\mu^{k-l}}{(k-l)!} e^{-\mu} \\
 &= e^{-(\lambda+\mu)} \frac{1}{k!} \sum_{l=0}^k \binom{k}{l} \lambda^l \mu^{k-l} \\
 &= e^{-(\lambda+\mu)} \frac{1}{k!} (\lambda + \mu)^k \quad \forall k \in \mathbb{N}_0,
 \end{aligned}$$

so dass

$$X + Y \sim \text{Poisson}(\lambda + \mu).$$


D.h. der Typ der Verteilung ist bei der Faltung erhalten geblieben.

Hinweis: Das ist aber nicht immer der Fall!

### ■ Beispiel III.28

Seien  $X, Y \sim U([0, 1])$  zwei unabhängige Zufallsvariablen mit Dichten  $\rho(x) = \mathbb{1}_{[0,1]}(x)$ . Dann ist  $X + Y$  eine Zufallsvariable mit Werten in  $[0, 2]$  und Dichte

$$\begin{aligned}
 \rho \star \rho(x) &= \int_{\mathbb{R}} \rho(y) \rho(x-y) \, dx \, dy \\
 &= \int_{\mathbb{R}} \mathbb{1}_{[0,1]}(y) \mathbb{1}_{[0,1]}(x-y) \, dy \\
 &= \int_{0 \vee (x-1)}^{1 \wedge x} dy = \begin{cases} x & 0 \leq x \leq 1 \\ 2-x & 1 \leq x \leq 2 \\ 0 & \text{sonst.} \end{cases}
 \end{aligned}$$



## Kapitel IV

# Weitere Standardmodelle der Wahrscheinlichkeitstheorie

## 1. Stetige Gleichverteilung

### ► Erinnerung

$\Omega \subset \mathbb{R}^n$  Borel-messbar mit LEBESGUE-Volumen  $0 < \lambda(\Omega) < \infty$ . Wahrscheinlichkeitsmaß ist  $(\Omega, \mathcal{B}(\Omega))$  mit Dichte

$$\rho(x) = \frac{1}{\lambda(\Omega)}$$

heißt stetige Gleichverteilung auf  $\Omega$ :  $U(\Omega)$ .

Für alle  $A \in \mathcal{B}(\Omega)$  gilt:

$$\mathbb{P}(A) = \int_A \rho(x) \, dx = \frac{\lambda(A)}{\lambda(\Omega)}.$$

Meist verwenden wir  $U([a, b])$ ,  $a < b$  (Gleichverteilung auf Intervall) mit  $\rho(x) = 1/(b-a)$ ,  $a \leq x \leq b$  und Verteilungsfunktion

$$F(x) = \begin{cases} 0 & x < a \\ \int_a^x \frac{1}{b-a} \, dx = \frac{x-a}{b-a} & a \leq x \leq b \\ 1 & x > b. \end{cases}$$

## 2. Wartezeitverteilungen

### Negative Binomialverteilung:

Wir wiederholen ein Bernoulliexperiment mit Erfolgswahrscheinlichkeit  $p \in [0, 1]$  unendlich oft. Gesucht ist die Anzahl der Misserfolge bis zum  $r$ -ten Erfolg,  $r \in \mathbb{N}$ . Ein passender Ergebnisraum ist  $\Omega = \mathbb{N}_0$ . Für Modellierung ist es jedoch leichter in jedem Versuch erfolgt ("1") oder Misserfolg ("0") festzuhalten und  $i$  mit dem unendlichen Produktmaß des Bernoullimaßes auf  $\{0, 1\}^{\mathbb{N}}$  zu arbeiten.

Als Zufallsvariable

$$X_r : \{0, 1\}^{\mathbb{N}} \rightarrow \Omega$$

welche die Anzahl der Misserfolge bis zum  $r$ -ten Erfolg darstellt, setze

$$X_r(\omega) = \min \left\{ \sum_{i=1}^k \omega_i = r \right\} = r.$$

Dann

$$\mathbb{P}(X_r = k) = \sum_{\substack{\omega \in \{0,1\}^{\mathbb{N}} \\ X_r(\omega) = k}} \prod_{i=1}^{\infty} \rho(\omega_i)$$

mit  $\rho(0) = 1 - p, \rho(1) = p$  (Zähldichte der Bernoulliverteilung), also

$$\mathbb{P}(X_r = k) = \binom{r+k-1}{k} (1-p)^k p^r \quad r \in \mathbb{N}_0.$$

### Definition IV.1 (negative Binomialverteilung, geometrische Verteilung)

Sei  $p \in [0, 1]$  und  $r \in \mathbb{N}$ , dann heißt die Verteilung auf  $\mathbb{N}_0$  mit Zähldichte

$$\rho(k) = \binom{r+k-1}{k} p^r (1-p)^k$$

die negative Binomialverteilung mit Parametern  $(r, p)$ . Schreibe  $\text{negBin}(r, p)$ . Im Fall  $r = 1$  nennen wir die Verteilung mit Zähldichte

$$\rho(k) = p(1-p)^k \quad k \in \mathbb{N}_0$$

die geometrische Verteilung mit Parametern  $p$ . Schreibe  $\text{Geom}(p)$ .

## 2.1. Exponential- und Gammaverteilung

1. Ziel: Modelliere die Wartezeit auf  $r$  Ereignisse in kontinuierlicher Zeit.
2. Wähle:  $(\Omega, \mathcal{F}) = (\mathbb{R}_+, \mathcal{B}(\mathbb{R}_+))$
3. Annahmen:

- Jedes Ereignis geschieht zu einer zufälligen Zeit
- Die Anzahl der Ereignisse bis zur Zeit  $t$  sei  $\text{Poisson}(\lambda t)$  verteilt.

Die zweite Annahme macht Sinn, denn

- Poissonverteilung ist Modell für Anzahl seltener Ereignisse
- Nach Beispiel 3.26:

$$\text{Poisson}(\lambda t) \star \text{Poisson}(\lambda s) = \text{Poisson}(\lambda(t+s))$$

Die Linearität des Parameters entspricht also einer Stationaritätsvoraussetzung:

Modelliert

$$\begin{aligned} X &\sim \text{Poisson}(\lambda t) \text{ die Ereignisse in } (0, t], \\ Y &\sim \text{Poisson}(\lambda s) \text{ die Ereignisse in } (t, t + s] \end{aligned}$$

so modelliert

$$X + Y \sim \text{Poisson}(\lambda(t + s)) \text{ die Ereignisse in } (0, t + s].$$

Unter diesen Annahmen folgt für die Wahrscheinlichkeit in  $(0, t]$  mindestens  $r$  Ereignisse zu beobachten

$$\mathbb{P}((0, t)) = 1 - \sum_{k=0}^{r-1} \underbrace{e^{-\lambda t} \frac{(\lambda t)^k}{k!}}_{\text{Zähldichte Poisson}(\lambda t) \text{ in } t}$$

Wegen:

$$\begin{aligned} \frac{d}{dt} \left( 1 - \sum_{k=0}^{r-1} e^{-\lambda t} \frac{(\lambda t)^k}{k!} \right) &= -(-\lambda) e^{-\lambda t} \sum_{k=0}^{r-1} \frac{(\lambda t)^k}{k!} - e^{-\lambda t} \sum_{k=0}^{r-1} \frac{\lambda^k t^{k-1}}{(k-1)!} \\ &= e^{-\lambda t} \left( \sum_{k=0}^{r-1} \frac{\lambda^k t^{k-1}}{k!} - \sum_{l=0}^{r-1} \frac{\lambda^k t^{l-1}}{(l-1)!} \right) \end{aligned}$$

gilt

$$\mathbb{P}((0, t)) = \int_0^t e^{-\lambda x} \frac{\lambda^r x^{r-1}}{(r-1)!} dx.$$

Wir definieren allgemeiner:

**Definition IV.2 (Gammaverteilung, Gammafunktion)**

Seien  $\lambda > 0, r > 0$ , dann heißt die Verteilung auf  $(\mathbb{R}_+, \mathcal{B}(\mathbb{R}_+))$  mit Dichte

$$f(x) = \frac{\lambda^r}{\Gamma(r)} x^{r-1} e^{-\lambda x} \text{ mit } \Gamma(r) = \int_0^\infty y^{r-1} e^{-y} dy, r > 0$$

Gammafunktion, Gammaverteilung mit Parametern  $\lambda, r$ . Schreibe  $\text{Gamma}(\lambda, r)$ .

Insbesondere ist  $\text{Gamma}(\lambda, 1)$  gerade die Exponentialverteilung (vgl. Bsp 17?).

Die Gammaverteilung ist reproduktiv: Die Wartezeit auf  $r + s$  Ereignisse entspricht der Wartezeit auf  $r$  Ereignisse +  $s$  (weitere) Ereignisse:

**Lemma IV.3**

Seien  $X \sim \text{Gamma}(\lambda, r), Y \sim \text{Gamma}(\lambda, s)$  unabhängig, dann impliziert das

$$X + Y \sim \text{Gamma}(\lambda, r + s)$$

*Beweis.* Hier nur für  $r, s \in \mathbb{N}$ , allgemein später mit momenterzeugende Funktionen.

Seien  $\rho(x), \rho(y)$  Dichten von  $X, Y$ . Nach Satz III.25 folgt

$$\begin{aligned}
 \rho_{(X+Y)} &= \rho_X \star \rho_Y(x) = \int_{\mathbb{R}} \rho_X(y) \rho_Y(x-y) dy \\
 &= \int_{\mathbb{R}} \frac{\lambda^r}{\Gamma(r)} y^{r-1} e^{-\lambda y} \frac{\lambda^s}{\Gamma(s)} (x-y)^{s-1} e^{-\lambda(x-y)} dy \\
 &= \frac{\lambda^{r+s}}{\Gamma(r)\Gamma(s)} e^{-\lambda x} \int_0^x y^{r-1} (x-y)^{s-1} dy \\
 &\stackrel{\text{P.I.}}{=} \frac{\lambda^{r+s}}{\Gamma(r)\Gamma(s)} e^{-\lambda x} \left( \underbrace{\left[ \frac{1}{r} y^r (x-y)^{s-1} \right]_{y=0}^x}_{=0} + \frac{s-1}{r} \int_0^x y^r (x-y)^{s-2} dy \right) \\
 &\stackrel{\text{Ind}}{=} \frac{\lambda^{r+s}}{\Gamma(r)\Gamma(r)} e^{-\lambda x} \frac{\Gamma(r)\Gamma(s)}{\Gamma(r+s)} = \frac{\lambda^{r+s}}{\Gamma(r+s)} e^{-\lambda x}. \quad \square
 \end{aligned}$$

Exponentialverteilungen sind zudem gedächtnislos:

**Lemma IV.4 (Gedächtnislosigkeit der Exponentialverteilung)**

Sei  $X \sim \text{Exp}(\lambda)$ , dann gilt

$$\mathbb{P}(X > t) = \mathbb{P}(X > t+s \mid X > s) \quad t, s \geq 0. \quad (*)$$

*Beweis.*

$$\begin{aligned}
 \mathbb{P}(X > t+s \mid X \geq s) &= \frac{\mathbb{P}(X > t+s, X \geq s)}{\mathbb{P}(X > s)} \\
 &= \frac{\mathbb{P}(X > t+s)}{\mathbb{P}(X > s)} \\
 &= \frac{e^{-\lambda(t+s)}}{e^{-\lambda t}} = e^{-\lambda t} = \mathbb{P}(X > t). \quad \square
 \end{aligned}$$

■ **Beispiel IV.5**

Eine Studentin wartet morgens eine  $\text{Exp}(1/5)$  verteilte Zeit  $X$  auf den Bus zur Uni. Die Wahrscheinlichkeit einer Wartezeit  $\geq 5$  Minuten

$$\mathbb{P}(X \geq 5) = e^{-\frac{1}{5} \cdot 5} = e^{-1} \approx 0,37.$$

An einen kalten, stürmischen Frühlingstag hat die Studentin bereits 10 Minuten gewartet. Die Wahrscheinlichkeit mindestens 5 weitere Minuten zu warten ist

$$\mathbb{P}(X \geq 15 \mid X > 10) = \mathbb{P}(X \geq 5) = e^{-1} \approx 0,37.$$

Hinweis: Man kann sogar zeigen, dass die Exponentialverteilung die einzige absolutstetige Verteilung mit  $(*)$  ist.

## Kapitel V

# Erwartungswerte & Varianz

1. Frage:

Beispiel IV.5 Durchschnittliche Wartezeit?  $\rightsquigarrow$  Erwartungswert

Wie stark ist die Streuung um den Durchschnitt?  $\rightsquigarrow$  Varianz

## 1. Der Erwartungswert

### Definition V.1 (Erwartungswert)

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum und  $X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$  Zufallsvariable. Dann ist

$$\mathbb{E}[X] = \int_{\Omega} X(\omega) \mathbb{P}(\mathrm{d}\omega) = \int_{\mathbb{R}} x \mathbb{P}(X \in \mathrm{d}x)$$

der Erwartungswert von  $X$ .

Hinweis: Der Erwartungswert von  $X$  existiert, genau dann wenn

$$\int_{\Omega} |X(\omega)| \mathbb{P}(\mathrm{d}\omega) < \infty \text{ bzw. } \mathbb{E}[|X|] < \infty$$

d.h. genau dann wenn  $X \in \mathcal{L}^1(\mathbb{P})$ .

Für nichtnegative Zufallsvariablen ist der Erwartungswert immer definiert, wenn wir  $+\infty$  als zulässigen Wert annehmen, was wir in der Folge auch tun.

### ■ Beispiel V.2

$(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum,  $A \in \mathcal{F}$  und sei  $X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$  die Indikatorvariable

$$X(\omega) = \mathbb{1}_A(\omega)$$

Dann gilt:  $X \in \mathcal{L}^1(\mathbb{P})$  und

$$\mathbb{E}[X] = \int_{\Omega} \mathbb{1}_A(\omega) \mathbb{P}(\mathrm{d}\omega) = \int_A \mathbb{P}(\mathrm{d}\omega) = \mathbb{P}(A).$$

### Satz V.3

Sei  $X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$  Zufallsvariable und  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  Borel-messbar. Dann

$$\mathbb{E}[f(X)] = \int f(X) \mathrm{d}\mathbb{P} = \int_{\Omega} \mathbb{E}(X(\omega)) \mathrm{d}\mathbb{P}(\omega) = \int_{\mathbb{R}^n} f(X) \mathbb{P}(X \in \mathrm{d}x).$$

*Beweis.* Sei  $f(X)$  eine reelle Zufallsvariable. Die Formel folgt direkt auf dem Transformationssatz für Bildmaße ( $\nearrow$  Schilling MINT 18.1).  $\square$



**Satz V.4 (Erwartungswerte bei Existenz einer (Zähl-)dichte)**

Sei  $X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$  Zufallsvariable und

$$f : \mathbb{R}^n \rightarrow \mathbb{R} \text{ Borel-messbar.}$$

1. diskreter Fall: Ist  $\mathbb{P}_X$  ein Wahrscheinlichkeitsmaß auf  $(\mathbb{Z}, \mathcal{P}(\mathbb{Z}))$  und der Zähldichte  $\rho$ , so

$$\mathbb{E}[f(X)] = \sum_{x \in \mathbb{Z}} f(x) \rho(x).$$

2. stetiger Fall: Besitzt  $\mathbb{P}_X$  eine Dichte  $\rho$  (bzgl Lebesguemaß), so

$$\mathbb{E}[f(X)] = \int_{\mathbb{R}} f(x) \rho(x) \, dx$$

*Beweis.* Klar aus Definition V.1 und Satz V.3. □

**■ Beispiel V.5**

Sei  $X \sim \text{Bin}(n, p)$ . Dann gilt

$$\begin{aligned} \mathbb{E}[X] &= \sum_{k=1}^n k \binom{n}{k} p^k (1-p)^{n-k} \\ &= \sum_{k=1}^n \frac{n!}{(n-k)!(k-1)!} p^k (1-p)^{n-k} \\ &= np \underbrace{\sum_{k=1}^n \binom{n-1}{k-1} p^{k-1} (1-p)^{n-1-(k-1)}}_{\text{Zähldichte Bin}(n-1, p) \text{ in } k-1} \\ &= np. \end{aligned}$$

Da der Erwartungswert ein Integral ist, übertragen sich viele Eigenschaften.

**Satz V.6 (Eigenschaften des Erwartungswertes)**

Seien  $X, Y, X_n : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ ,  $n \in \mathbb{N}$  Zufallsvariablen in  $\mathcal{L}^1(\mathbb{P})$  und  $a, b \in \mathbb{R}$  konstant.

1. Linearität:  $\mathbb{E}[aX + bY] = a\mathbb{E}X + b\mathbb{E}Y$
2. Monotonie:  $X \leq Y$ , d.h.  $X(\omega) \leq Y(\omega), \forall \omega \in \Omega$ . Dann gilt

$$\mathbb{E}[X] \leq \mathbb{E}[Y] \text{ und insbesondere gilt } X \geq 0 \implies \mathbb{E}X \geq 0.$$

3. Lemma von FATOU:

$$\mathbb{E}[\liminf_{n \rightarrow \infty} X_n] \leq \liminf_{n \rightarrow \infty} \mathbb{E}[X_n]$$

4. Satz von BEPPO-LEVI: Wenn  $X_n \geq 0$  und  $X_n \uparrow X$  so gilt:

$$\mathbb{E}[X] = \sup_{n \in \mathbb{N}} \mathbb{E}[X_n] = \lim_{n \rightarrow \infty} \mathbb{E}[X_n]$$

5. Dominierte Konvergenz/ Satz von LEBESGUE: Sei  $\lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)$  und

$$\mathbb{P}(\{\omega : |X_n(\omega)| \leq Y(\omega)\}) = 1 \quad (|X| \leq Y \text{ } \mathbb{P} \text{ fast sicher})$$

$$\text{für } Y \in \mathcal{L}^1(\mathbb{P}) \implies X \in \mathcal{L}^1(\mathbb{P}) \text{ und } \lim_{n \rightarrow \infty} \mathbb{E}[X_n] = \mathbb{E}[X]$$

6. MARKOV-Ungleichung: Sei  $\varepsilon > 0$ , dann gilt

$$\mathbb{P}(|X| \geq \varepsilon) \leq \frac{1}{\varepsilon} \mathbb{E}[|X|]$$

7. HÖLDER-Ungleichung: Sei  $1 \leq p, q \leq \infty, \frac{1}{p} + \frac{1}{q} = 1$

$$\mathbb{E}[|XY|] \leq (\mathbb{E}[|X|^p])^{\frac{1}{p}} (\mathbb{E}[|Y|^q])^{\frac{1}{q}}$$

( $p = q = 2$  CAUCHY-SCHWARZ-Ungleichung)

8. JENSEN'sche Ungleichung: Sei  $X \geq 0$  und  $\varphi : [0, \infty) \rightarrow [0, \infty)$  konvex, messbar  
 $\varphi(\mathbb{E}[X]) \leq \mathbb{E}[\varphi(X)]$ .

*Beweis.* ↗ Schilling MINT.

□

■ **Beispiel V.7**

Da für  $X_1, \dots, X_n \sim \text{Bernoulli}(p)$  unabhängig gilt, dass  $\underbrace{X_1 + \dots + X_n}_{=X} \sim \text{Bin}(n, p)$  folgt

$$\begin{aligned}\mathbb{E}[X] &= \mathbb{E}[X_1 + \dots + X_n] = \mathbb{E}[X_1] + \dots + \mathbb{E}[X_n] = n\mathbb{E}[X_1] \\ &= n(1 \cdot \underbrace{\mathbb{P}(X_1 = 1)}_{=p} + 0 \cdot \mathbb{P}(X_1 = 0)) \\ &= n \cdot p.\end{aligned}$$

**Satz V.8 (Produktformel für Erwartungswerte)**

Seien  $(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum und  $X_1, \dots, X_n : \Omega \rightarrow \mathbb{R}^d$  unabhängige Zufallsvariablen und  $f_1, \dots, f_n : \mathbb{R}^d \rightarrow \mathbb{R}$  messbar. Wenn  $f_i(X_i) \geq 0, i = 1, \dots, n$  sei mit  $f_i(X_i) \in \mathcal{L}^1(\mathbb{P}), i = 1, \dots, n$ , dann gilt

$$\mathbb{E}\left[\prod_{i=1}^n f_i(X_i)\right] = \prod_{i=1}^n \mathbb{E}[f_i(X_i)]$$

Für den Beweis von Satz V.8 benötigen wir:

**Lemma V.9**

$(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum,  $X, Y : \Omega \rightarrow \mathbb{R}^d$  unabhängige Zufallsvariablen und  $h : \mathbb{R}^{2d} \rightarrow \mathbb{R}$  messbar. Falls  $h \geq 0$  oder  $h(X, Y) \in \mathcal{L}^1(\mathbb{P})$ , dann

$$\begin{aligned}\mathbb{E}[h(X, Y)] &= \int_{\mathbb{R}^d} \int_{\mathbb{R}^d} h(x, y) \mathbb{P}(X \in dx) \mathbb{P}(Y \in dy) \\ &= \mathbb{E}\left[\int_{\mathbb{R}^d} h(X, y) \mathbb{P}(Y \in dy)\right] \\ &= \mathbb{E}\left[\int_{\mathbb{R}^d} h(x, Y) \mathbb{P}(X \in dx)\right]\end{aligned}$$

*Beweis.* Sei  $h(X, Y)$  eine reelle Zufallsvariable und

$$\begin{aligned}\mathbb{E}[h(X, Y)] &= \int_{\Omega} h(X(\omega), Y(\omega)) d\mathbb{P}(\omega) \\ &\stackrel{???}{=} \int_{\mathbb{R}^d} h(x, y) \mathbb{P}(X \in dx, Y \in dy) \\ &\stackrel{X \perp\!\!\!\perp Y, ???}{=} \int_{\mathbb{R}^{2d}} h(x, y) \mathbb{P}_X \otimes \mathbb{P}_Y(dx, dy) \\ &\stackrel{\text{FUBINI}}{=} \int_{\mathbb{R}^d} \int_{\mathbb{R}^d} h(x, y) \mathbb{P}_X(dx) \mathbb{P}_Y(dy) \\ &\stackrel{???}{=} \int_{\Omega} \int_{\mathbb{R}^d} h(x, Y(\omega)) \mathbb{P}_X(dx) d\mathbb{P}(\omega) \\ &= \mathbb{E}\left[\int_{\mathbb{R}^d} h(x, Y) \mathbb{P}_X(dx)\right].\end{aligned}\quad \square$$

*Beweis (Satz V.8).* Betrachte  $n = 2$ , Zufallsvariablen  $X, Y$  und Abbildungen  $f, g$ . Setze  $h(x, y) = f(x)g(y)$ ,

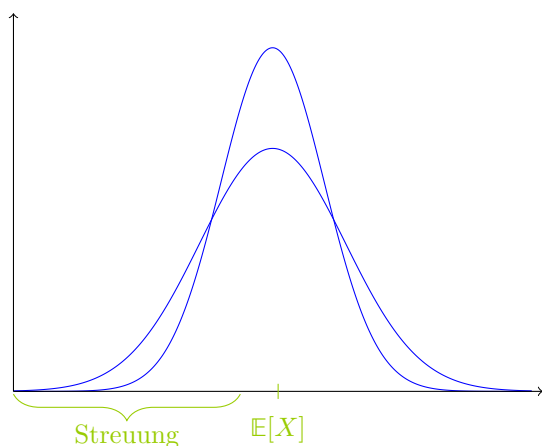
dann folgt für  $f, g \geq 0$  mit Lemma V.9

$$\begin{aligned}\mathbb{E}[f(X)g(Y)] &= \int_{\mathbb{R}^d} \int_{\mathbb{R}^d} f(x)g(y)\mathbb{P}(X \in dx)\mathbb{P}(Y \in dy) \\ &= \int_{\mathbb{R}^d} f(x)\mathbb{P}(X \in dx) \int_{\mathbb{R}^d} g(y)\mathbb{P}(Y \in dy) \\ &= \mathbb{E}[f(X)] \cdot \mathbb{E}[g(Y)].\end{aligned}$$

Für  $f(X), g(Y) \in \mathcal{L}^1(\mathbb{P})$  zeigt obige Rechnung

$$\mathbb{E}[f(X)g(Y)] = \mathbb{E}[|f(X)|]\mathbb{E}[|g(Y)|] < \infty$$

also  $f(X)g(Y) \in \mathcal{L}^1(\mathbb{P})$ . Die Aussage folgt über die obige Rechnung. Für allgemeines  $n$  folgt Satz V.8 durch Iteration mit Folgerung III.19.  $\square$



## 2. Varianz und höhere Momente

### Definition V.10 ( $k$ -te Momente)

$(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum,  $X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$  reelle Zufallsvariable. Dann ist für  $k \in \mathbb{N}$

$$\mathbb{E}[X^k] = \int_{\Omega} X^k(\omega)\mathbb{P}(\omega) = \int_{\mathbb{R}} x^k\mathbb{P}(X \in dx)$$

das  $k$ -te Moment von  $X$  (sofern definiert).

### ► Bemerkung

- Erwartungswert  $\cong$  erstes Moment
- Das  $k$ -te Moment existiert, genau dann wenn

$$\int_{\Omega} |X(\omega)|^k \mathbb{P}(d\omega) < \infty \text{ bzw. } X \in \mathcal{L}^k(\mathbb{P})$$

- MINT:  $\mathcal{L}^r(\mathbb{P}) \subseteq \mathcal{L}^s(\mathbb{P})$  für  $s \leq r$

Von Interesse ist insbesondere das zweite Moment.

**Definition V.11 (Varianz, Standardabweichung)**

$(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum,  $X, Y \in \mathcal{L}^2(\mathbb{P})$  reelle Zufallsvariablen.

1. Die Varianz von  $X$  ist

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

2. Die Standardabweichung/Streuung von  $X$  ist  $\sqrt{\text{Var} X}$ .

3. Die Kovarianz von  $X$  und  $Y$  ist

$$\begin{aligned} \text{Cov}(X, Y) &= \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] \\ &= \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] \end{aligned}$$

Hinweis: Wenn die Varianz 0 ist, heißt es nicht dass die Zufallsvariablen unabhängig waren

4. Sind  $\text{Var} X, \text{Var} Y \geq 0$ , dann ist die Korrelation von  $X$  und  $Y$

$$\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}.$$

5. Gilt  $\text{Corr}(X, Y) = 0$ , so heißen  $X, Y$  unkorreliert.

**► Bemerkung**

- Die Endlichkeit der Ausdrücke in Definition V.11 folgt aus der CAUCHY-SCHWARZ-Ungleichung

$$\mathbb{E}[|XY|] \leq (\mathbb{E}|X|^2)^{\frac{1}{2}} \cdot (\mathbb{E}|Y|^2)^{\frac{1}{2}}$$

- Für die (Ko)varianz gilt

$$\begin{aligned} \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] &= \mathbb{E}[XY - X\mathbb{E}[Y] - Y\mathbb{E}[X] + \mathbb{E}[X]\mathbb{E}[Y]] \\ &= \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] - \mathbb{E}[X]\mathbb{E}[Y] + \mathbb{E}[X]\mathbb{E}[Y] \\ &= \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]. \end{aligned}$$

**■ Beispiel V.12**

Sei  $X \sim \text{Bin}(n, p)$ , dann gilt

$$\text{Var}(X) = \mathbb{E}X^2 - \underbrace{(\mathbb{E}X)^2}_{=np}$$

mit

$$\begin{aligned}
\mathbb{E}X^2 &= \sum_{k=0}^n k^2 \binom{n}{k} p^k (1-p)^{n-k} \\
&= np \sum_{k=1}^n k \frac{(n-1)!}{(n-1-(k-1))!(k-1)!} p^{k-1} (1-p)^{n-1-(k-1)} \\
&= np \sum_{l=0}^{n-1} (l+1) \binom{n-1}{l} p^l (1-p)^{n-1-l} \quad \text{mit } l = k-1 \\
&= np \left( 1 + \sum_{l=0}^{n-1} l \binom{n-1}{l} p^l (1-p)^{n-1-l} \right) \\
&= np(1 + (n-1)p) \quad \text{mit Binomial Satz} \\
&= np + n(n-1)p^2 \\
&= np + n^2p^2 - np^2 - n^2p^2 \\
&= np + n(n-1)p^2.
\end{aligned}$$

Damit ist die  $\text{Var}(X) = np + n(n-1)p^2 - np^2 = np(1-p)$ .

### Satz V.13 (Eigenschaften der (Ko-)varianz)

$(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum,  $X, Y, X_1, \dots, X_n \in \mathcal{L}^2(\mathbb{P})$ ,  $a, b \in \mathbb{R}$ .

1.  $\text{Var}(aX + b) = a^2 \text{Var}(X)$
2. Sei  $(\text{Cov}(X, Y))^2 \leq \text{Var}X \text{Var}Y$  und insbesondere  $|\text{Corr}(X, Y)| \leq 1$
3.  $\text{Var}(\sum_{i=1}^n X_i) = \sum_{i=1}^n \text{Var}(X_i) + \sum_{i,j=1//i \neq j}^n \text{Cov}(X_i, X_j)$  Sind die  $X_1, \dots, X_n$  paarweise unkorreliert, so gilt die Formel von BIENAYMÉ:

$$\text{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{Var}(X_i)$$

4.  $X \perp\!\!\!\perp Y \implies \text{Corr}(X, Y) = 0$
5. TSCHEBYSCHEFF-Ungleichung: Für  $\varepsilon > 0$

$$\mathbb{P}(|X - \mathbb{E}X| > \varepsilon) \leq \frac{\text{Var}X}{\varepsilon^2}$$

*Beweis.* 1. Da  $\mathbb{E}[aX + b] = a\mathbb{E}X + b$ , folgt

$$\begin{aligned}
\text{Var}(aX + b) &= \mathbb{E}[(a\mathbb{E}X + b - (a\mathbb{E}X + b))^2] \\
&= \mathbb{E}[a^2(X - \mathbb{E}X)^2] = a^2 \text{Var}X.
\end{aligned}$$

2. Wegen 1. können wir oBdA annehmen, dass  $\mathbb{E}X = 0 = \mathbb{E}Y$ . Dann wird 2. zu

$$\mathbb{E}[XY]^2 \leq \mathbb{E}X^2 \cdot \mathbb{E}Y^2$$

und dies ist die CAUCHY-SCHWARZ Ungleichung.

3. Wähle wieder oBdA  $\mathbb{E}X_i = 0$ . Dann

$$\begin{aligned}\mathbb{V}\text{ar}\left(\sum_{i=1}^n X_i\right) &= \mathbb{E}\left[\left(\sum_{i=1}^n X_i\right)^2\right] \\ &= \mathbb{E}\left[\sum_{i,j=1}^n X_i X_j\right] \\ &= \sum_{i,j=1}^n \mathbb{E}[X_i X_j] \\ &= \sum_{i,j=1}^n \text{Cov}(X_i, X_j) \\ &= \sum_{i=1}^n \mathbb{V}\text{ar}(X_i) + \sum_{\substack{i,j=1 \\ i \neq j}}^n \text{Cov}(X_i, X_j)\end{aligned}$$

4. Sei

$$\begin{aligned}X \perp\!\!\!\perp Y &\implies \mathbb{E}[XY] = \mathbb{E}X\mathbb{E}Y \\ &\implies \text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}X\mathbb{E}Y = 0 \\ &\implies \text{Corr}(X, Y) = 0\end{aligned}$$

5. Wende die MARKOV-Ungleichung auf  $X' = (X - \mathbb{E}X)^2$  an, dann folgt

$$\begin{aligned}\mathbb{P}(|X - \mathbb{E}X| > \varepsilon) &\leq \mathbb{P}((X - \mathbb{E}X)^2 > \varepsilon^2) \\ &\stackrel{\text{MARKOV}}{\leq} \frac{1}{\varepsilon^2} \mathbb{E}[(X - \mathbb{E}X)^2] \\ &= \frac{\mathbb{V}\text{ar}X}{\varepsilon^2}.\end{aligned}$$

□

### 3. Wahrscheinlichkeitserzeugende Funktionen

#### Definition V.14 (Wahrscheinlichkeitserzeugende Funktion)

1. Ist  $\mathbb{P}$  Wahrscheinlichkeitsmaß auf  $(\mathbb{N}_0, \mathcal{P}(\mathbb{N}_0))$  mit Zähldichte  $\rho$ , so heißt

$$\psi_{\mathbb{P}} := \sum_{k \in \mathbb{N}_0} s^k \rho(k) \quad 0 \leq s \leq 1,$$

Wahrscheinlichkeitserzeugende Funktion von  $\mathbb{P}$ . (probability generating function - pgf)

2. Ist  $X$   $\mathbb{N}_0$ -wertige Zufallsvariable auf  $(\Omega, \mathcal{F}, \mathbb{P})$ , so heißt

$$\psi_X = \sum_{k \in \mathbb{N}_0} s^k \mathbb{P}(X = k) \quad 0 \leq s \leq 1,$$

Wahrscheinlichkeitserzeugende Funktion (pgf) von  $X$ .

► **Bemerkung**

- Da  $\sum_{k \in \mathbb{N}_0} \rho(k) = 1$  ist die pgf auf  $0 \leq s \leq 1$  wohldefiniert. Zudem ist  $\psi$  auf  $[0, 1)$  unendlich oft differenzierbar.
- Da  $\rho(k) \geq 0 \forall k$  ist die pgf stets konvex.
- Durch TAYLOREntwicklung von  $\psi$  um 0 gilt:

$$\psi_{\mathbb{P}}(s) = \sum_{k \in \mathbb{N}_0} \frac{s^k \psi_{\mathbb{P}}^{(k)}(0)}{k!}.$$

so dass für alle  $k \in \mathbb{N}_0$  folgt

$$\rho(k) = \frac{\psi_{\mathbb{P}}^{(k)}(0)}{k!}$$

Die Verteilung  $\mathbb{P}$  (bzw.  $\mathbb{P} \circ X^{-1}$ ) ist durch  $\psi_{\mathbb{P}}$  (bzw.  $\psi_X$ ) eindeutig bestimmt. Also “erzeugt  $\psi$  die Zähldichte”.

■ **Beispiel V.15**

Ist  $X \sim \text{Bin}(n, p)$ , so folgt

$$\begin{aligned} \psi_X(s) &= \sum_{k=0}^n s^k \binom{n}{k} p^k (1-p)^{n-k} \\ &= \sum_{k=0}^n \binom{n}{k} (ps)^k (1-p)^{n-k} \\ &= (ps - (1-p))^n = (1 + p(s-1))^n. \quad \text{Binomial Satz} \end{aligned}$$

**Satz V.16 (Momentenberechnung mit der pgf)**

Sei  $X$  eine  $\mathbb{N}_0$ -wertige Zufallsvariable, dann gilt

$$\mathbb{E}[X^n] < \infty \quad n \geq 1 \iff \psi_X^{(n)} = \lim_{s \uparrow 1} \psi_X^{(n)}(s) < \infty.$$

Insbesondere gilt dann

$$\psi_X^{(n)}(1) = \mathbb{E}[X(X-1) \dots (X-n+1)].$$

*Beweis.* Sei  $\rho(k) = \mathbb{P}(X = k)$ . Durch  $n$ -faches gliedweises Differenzieren der Potenzreihe  $\psi_X$  folgt

$$\psi_X^{(n)}(s) = \sum_{k \in \mathbb{N}_0} k(k-1) \dots (k-n+1) \rho(k) s^{k-n} \quad 0 \leq s < 1.$$



Dann existieren in  $[0, \infty)$

$$\begin{aligned}\lim_{s \uparrow 1} \psi_X &= \lim_{s \uparrow 1} \sum_{k=0}^{\infty} k(k-1) \cdots (k-n+1) \rho(k) s^{k-n} \\ &= \sum_{k=n}^{\text{inf ty}} \rho(k) k(k-1) \cdots (k-n+1) \\ &= \mathbb{E}[X(X-1) \cdots (X-n+1)]\end{aligned}$$

sowie induktiv

$$\begin{aligned}\psi^{(n)}(1) &= \lim_{s \uparrow 1} \frac{\psi^{(n-1)} - \psi^{(n-1)}(s)}{1-s} \\ &= \lim_{s \uparrow 1} \sum_{k \in \mathbb{N}_0} \rho(k) k(k-1) \cdots (k-(n-1)+1) \frac{1-s^{k-(n-1)}}{1-s} \\ &= \lim_{s \uparrow 1} \sum_{k \in \mathbb{N}_0} \rho(k) k(k-1) \cdots (k-n+2) \sum_{l=0}^{k-(n-1)} s^l \quad \text{Geo. Reihe} \\ &= \sum_{k \in \mathbb{N}_0} \rho(k) k(k-1) \cdots (k-n+2)(k-n+1) \quad \text{Monotonie} \\ &= \mathbb{E}[X(X-1) \cdots (X-n+1)]\end{aligned}$$

Insbesondere gilt  $\mathbb{E}X^n < \infty$  genau dann, wenn  $\psi_X^{(n)}(1) < \infty$  bzw.  $\lim_{s \uparrow 1} \psi_X^{(n)}(s) < \infty$

□

### ■ Beispiel V.17

Sei  $X \sim \text{Bin}(n, p)$ , dann gilt Beispiel V.15

$$\psi_X(s) = (1 + p(s-1))^n.$$

Damit

$$\begin{aligned}\psi_X'(s) &= n(1 + p(s-1))^{n-1} p \\ \psi_X''(s) &= n(n-1)(1 + p(s-1))^{n-2} \cdot p^2\end{aligned}$$

so dass

$$\mathbb{E}[X] = \psi_X'(1) = np$$

und

$$\begin{aligned}\text{Var}X &= \mathbb{E}[X^2] - (\mathbb{E}X)^2 = \mathbb{E}[X(X-1)] + \mathbb{E}X - (\mathbb{E}X)^2 \\ &= \psi_X''(1) + \psi_X'(1) - (\psi_X'(1))^2 \\ &= n(n-1)p^2 + np - (np)^2 = np - np^2 = np(1-p).\end{aligned}$$

**Satz V.18**

Seien  $X, Y$  unabhängige Zufallsvariablen,  $\mathbb{N}_0$ -wertig auf  $(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum. Dann gilt

$$\begin{aligned}\psi_{X+Y} &= \mathbb{E}[s^{X+Y}] = \mathbb{E}[s^X s^Y] \\ &= \mathbb{E}[s^X] \mathbb{E}[s^Y] \\ &= \psi_X(s) \psi_Y(s).\end{aligned}$$

**Satz V.19**

Sind  $\mathbb{P}_1, \mathbb{P}_2$  Wahrscheinlichkeitsmaße auf  $(\mathbb{N}_0, \mathcal{P}(\mathbb{N}_0))$ , so gilt

$$\psi_{\mathbb{P}_1 \star \mathbb{P}_2} = \psi_{\mathbb{P}_1}(s) \psi_{\mathbb{P}_2}(s) \quad 0 \leq s \leq 1.$$

## Kapitel VI

# *Bedingte Verteilungen und bedingte Erwartungswerte*

In Satz III.3:  $(\Omega, \mathcal{F}, \mathbb{P}), A, B \in \mathcal{F}$

$$\mathbb{P}(A | B) = \begin{cases} \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} & \mathbb{P}(B) > 0 \\ 0 / \text{beliebig} & \mathbb{P}(B) = 0 \end{cases}$$

In Fall  $\mathbb{P}(B) > 0$  ist  $\mathbb{P}(\cdot | B)$  ein Wahrscheinlichkeitsmaß und wir können das Integral

$$\mathbb{E}[X | B] := \int X(\omega) \mathbb{P}(d\omega | B)$$

definieren. Wir bezeichnen die als bedingten Erwartungswert von  $X$ . Für  $X = \mathbb{1}_A$  folgt (für  $\mathbb{P}(B) > 0$ )

$$\int X(\omega) \mathbb{P}(d\omega | B) = \mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{E}[\mathbb{1}_{A \cap B}]}{\mathbb{P}(B)} = \frac{\mathbb{E}[X \mathbb{1}_B]}{\mathbb{P}(B)}$$

und mittels maßtheoretischer Induktion folgt

$$\mathbb{E}[X | B] = \frac{\mathbb{E}[X \mathbb{1}_B]}{\mathbb{P}(B)}$$

allgemein ( $X \in \mathcal{L}^1, \mathbb{P}(B) > 0$ )

Frage: (Wie) können wir bedingte Erwartungswerte definieren, wenn  $\mathbb{P}(B) = 0$ ?

## 1. Bedingte Verteilungen

Seien  $X, Y$  Zufallsvariablen gegeben durch

$$X : (\Omega, \mathcal{F}) \rightarrow (\Omega_X, \mathcal{F}_X)$$

$$Y : (\Omega, \mathcal{F}) \rightarrow (\Omega_Y, \mathcal{F}_Y)$$

- Falls  $\Omega_Y$  höchstens abzählbar ist, gilt ( $\nearrow$  ???)

$$\mathbb{P}(X \in A | Y = y) = \begin{cases} \frac{\mathbb{P}(X \in A, Y = y)}{\mathbb{P}(Y = y)} & \mathbb{P}(Y = y) > 0 \\ 0 / \text{sonst} & \mathbb{P}(Y = y) = 0 \end{cases}$$

Insbesondere folgt mit dem Satz der totalen Wahrscheinlichkeit

$$\begin{aligned}\mathbb{P}(X \in A, Y \in B) &= \sum_{y \in B} \mathbb{P}(X \in A \mid Y = y) \mathbb{P}(Y = y) \quad \forall B \in \mathcal{F}_Y \\ &= \int_B \mathbb{P}(X \in A \mid Y = y) \mathbb{P}_Y(dy) \end{aligned} \quad (\star)$$

- Idee: Verwende  $(\star)$  um bedingte Verteilung zu definieren!

Sei also  $\mu_A : \Omega_Y \rightarrow \mathbb{R}$  gegeben so dass

$$\mathbb{P}(X \in A, Y \in B) = \int_B \mu_A(y) \mathbb{P}_Y(dy) \quad \forall B \in \mathcal{F}_Y \quad (\star\star)$$

Da  $\Omega_Y$  abzählbar, gilt  $\{y\} \in \mathcal{F}_Y \quad \forall y \in \Omega_Y$ . Also folgt aus  $(\star\star)$ , dass

$$\begin{aligned}\mathbb{P}(X \in A, Y = y) &= \int_{\{y\}} \mu_A(y) \mathbb{P}_Y(dy) \\ &= \mu_A(y) \mathbb{P}_Y(Y = y)\end{aligned}$$

Falls  $\mathbb{P}(Y = y) \neq 0$  folgt sofort

$$\mu_A(y) = \frac{\mathbb{P}(X \in A, Y = y)}{\mathbb{P}(Y = y)} = \mathbb{P}(X \in A \mid Y = y)$$

Andererseits gilt

$$\mathbb{P}_Y(\{y \in \Omega_Y : \mathbb{P}(Y = y) = 0\}) = \sum_{\substack{y \in \Omega_Y \\ \mathbb{P}(Y=y)=0}} \mathbb{P}_Y(\{y\}) = 0$$

so dass

$$\mu_A(y) = \mathbb{P}(X \in A \mid Y = y) \quad \mathbb{P}_Y \text{ f.s (d.h. bis auf } \mathbb{P}_Y\text{-Nullmengen)}$$

bzw.

$$\mathbb{P}_Y(\{y : \mu_A(y) \neq \mathbb{P}(X \in A \mid Y = y)\}) = 0$$

- Falls  $\Omega_Y$  überabzählbar ist und  $y \in \Omega_Y$  mit  $\mathbb{P}(Y = y) = 0$  (z.B.  $Y$  hat Dichte). Wir werden sehen, dann existiert  $\mu_A : (\Omega_Y, \mathcal{F}_Y) \rightarrow (\mathbb{R}_+, \mathcal{B}(\mathbb{R}_+))$  messbar, so dass  $(\star\star)$  gilt. Insbesondere ist  $\mu_A$  dann bis auf  $\mathbb{P}_Y$ -Nullmengen eindeutig bestimmt und wir können definieren:

$$\mathbb{P}(X \in A \mid Y = y) = \mu_A(y)$$

Wir benötigen:

**Satz VI.1 (Radon-Nikodym für endliche Maße)**

Seien  $\mu, \nu$  zwei endliche Maße auf  $(\Omega, \mathcal{F})$ . Dann ist  $\nu$  absolut stetig bzgl.  $\mu$  ( $\nu \ll \mu$ ) genau dann wenn  $\nu$  eine messbare Dichte  $f$  bezüglich  $\mu$  besitzt, d.h. wenn

$$\nu(A) = \int_A f(\omega) d\mu(\omega) \quad \forall A \in \mathcal{F}.$$

Insbesondere ist  $f$   $\mu$ -f.ü. eindeutig bestimmt.

*Beweis.*  $\nearrow$  MINT Schilling Satz 19.2. □

**Folgerung VI.2**

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum und

$$X : (\Omega, \mathcal{F}) \rightarrow (\Omega_X, \mathcal{F}_X)$$

$$Y : (\Omega, \mathcal{F}) \rightarrow (\Omega_Y, \mathcal{F}_Y)$$

Zufallsvariablen. Sei  $A \in \mathcal{F}_X$  beliebig. Dann existiert  $\mu_A : (\Omega_Y, \mathcal{F}_Y) \rightarrow ([0, 1], \mathcal{B}([0, 1]))$  messbar, so dass

$$\mathbb{P}(X \in A, Y \in B) = \int_B \mu_A(y) \mathbb{P}_Y(dy) \quad \forall B \in \mathcal{F}_Y.$$

Wir nennen  $\mathbb{P}(X \in A \mid Y = y)$  bedingte Wahrscheinlichkeit.

*Beweis.* Offensichtlich impliziert  $\mathbb{P}(y \in B) = 0$  auch  $\mathbb{P}(X \in A, Y \in B) = 0$  so dass

$$\mathbb{P}(X \in A, Y \in \cdot) \ll \mathbb{P}(Y \in \cdot) = \mathbb{P}_Y(\cdot)$$

Nach Satz VI.1 existiert eine messbare Funktion  $f : (\Omega_Y, \mathcal{F}_Y) \rightarrow (\mathbb{R}_+, \mathcal{B}(\mathbb{R}_+))$  mit

$$\mathbb{P}(X \in A, Y \in B) = \int_B f(y) \mathbb{P}_Y(dy) \quad \forall B \in \mathcal{F}_Y.$$

Sei  $D = \{y : f(y) > 1\}$ , dann gilt zudem  $\mathbb{P}_Y(D) = 0$ , denn

$$\mathbb{P}(Y \in D) \geq \mathbb{P}(X \in A, Y \in D) = \int_D f(y) \mathbb{P}_Y(dy)$$

impliziert

$$0 \geq \mathbb{P}(X \in A, Y \in D) - \mathbb{P}(Y \in D) = \int_D \underbrace{(f(y) - 1)}_{>0 \text{ in } D} \mathbb{P}_Y(dy) \geq 0$$

also gilt  $\mathbb{P}(D) = 0$ . Setze also

$$\mu_A(y) := \begin{cases} f(y) & y \in D^C \\ 0 & y \in D, \end{cases}$$

dann erfüllt  $\mu_A$  allen Eigenschaften. □

Für fixiertes  $A \in \mathcal{F}_X$  ist die nun definierte bedingte Wahrscheinlichkeit eindeutig bis auf  $\mathbb{P}_Y$ -Null-mengen. Für fixiertes  $y$  (und  $A$  variierend) ist  $\mathbb{P}(X \in A \mid Y = y)$  aber nicht immer ein Wahrscheinlich-

keitsmaß!

### ■ Beispiel VI.3

Betrachte den Wahrscheinlichkeitsraum  $([0, 1], \mathcal{B}([0, 1]), \mathbb{U}([0, 1]))$  und die Zufallsvariablen  $X, Y$  mit  $X(\omega) = Y(\omega) = \omega \quad \forall \omega \in [0, 1]$ . Dann

$$\mathbb{P}(X \in A, Y \in B) = \mathbb{P}(Y \in A \cap B) = \int_B \mathbb{1}_A(\omega) \mathbb{P}_Y(d\omega) \quad \forall B \in \mathcal{F}$$

so dass  $\mathbb{1}_A(\omega)$  eine Version von  $\mathbb{P}(X \in A \mid Y = y)$ . Insbesondere ist  $\mathbb{1}_A(y)$  für jedes  $y \in [0, 1]$  ein Wahrscheinlichkeitsmaß. Setzen wir

$$f(A) = \begin{cases} \sup A & A \neq \emptyset \\ 0 & A = \emptyset \end{cases}$$

so ist auch

$$\mathbb{P}'(X \in A \mid Y = y) = \mathbb{1}_A(y) + \mathbb{1}_{\{f(y)\}}(y)$$

eine Version der bedingten Wahrscheinlichkeit, denn

$$\begin{aligned} \int_B (\mathbb{1}_A(\omega) + \mathbb{1}_{\{f(y)\}}(\omega)) &= \mathbb{P}(Y \in A \cap B) + \underbrace{\mathbb{P}(Y \in B \cap f(A))}_{=0} \\ &= \mathbb{P}(X \in A, Y \in B) \end{aligned}$$

Allerdings ist  $\mathbb{P}'(X \in \cdot \mid Y = y)$  kein Wahrscheinlichkeitsmaß, denn für beliebiges  $y \in [0, 1]$  gilt

$$\mathbb{P}'(X \in [0, y] \mid Y = y) = \mathbb{1}_{[0, y]} + \mathbb{1}_{f([0, y])} = 2$$

Wie können solche Maße wie im Beispiel VI.3 ausgeschlossen werden? Dadurch ist folgende Definition motiviert.

#### Definition VI.4 (reguläre bedingte Verteilung)

Eine bedingte Verteilung  $\mathbb{P}(X \in \cdot \mid Y = \cdot)$  heißt regulär, wenn  $\mathbb{P}(X \in \cdot \mid Y = y)$  für alle  $y \in \Omega_Y$  ein Wahrscheinlichkeitsmaß ist.

Die Existenz regulärer bedingter Verteilungen ist nicht trivial. Wir beschränken uns daher auf den reellen Fall.

#### Satz VI.5

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum,  $X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$ ,  $Y : (\Omega, \mathcal{F}) \rightarrow (\Omega_Y, \mathcal{F}_Y)$  Zufallsvariablen. Dann existiert eine reguläre bedingte Verteilung

$$\mathbb{P}(X \in \cdot \mid Y = \cdot).$$

*Beweis.* Nur Beweisskizze (ausführlich wird ergänzt!)

Sei  $\tilde{\mathbb{P}}(X \in A \mid Y = \cdot)$  eine beliebige Version der bedingten Verteilung.

- Idee: "Korrigiere"  $\tilde{\mathbb{P}}$  auf geeigneten  $\mathbb{P}_Y$ -Nullmengen um geeigneter reguläre Version zu erhalten.

1. Es gibt eine  $\mathbb{P}_Y$ -Nullmenge  $N_1$ , so dass

$$\tilde{\mathbb{P}}(X \in \mathbb{R}^d \mid Y = y) = 1 \quad \forall y \notin N_1$$

2. Definiere  $\mathcal{G}^d := \left\{ \bigcup_{i=1}^k [a_i, b_i] \mid a_i, b_i \in \mathcal{G}^d, k \in \mathbb{N} \right\}$ . Dann gibt es eine  $\mathbb{P}_Y$ -Nullmenge  $N_2$ , so dass  $\tilde{\mathbb{P}}(X \in \cdot \mid Y = y)$  nicht negativ und additiv auf  $\mathcal{G}^d$  für  $Y \notin N_2$ .
3. Es gibt eine  $\mathbb{P}_Y$ -Nullmenge  $N_3$ , so dass  $\tilde{\mathbb{P}}(X \in \cdot \mid Y = y)$  für alle  $y \notin N_2 \cup N_3$   $\sigma$ -additiv auf  $\mathcal{G}^d$  ist.
4. Sei  $N = N_1 \cup N_2 \cup N_3$   $\mathbb{P}_Y$ -Nullmengen. Für  $y \in N^C$  existiert eine Erweiterung von  $\tilde{\mathbb{P}}(X \in \cdot \mid Y = y)$  zu einem Wahrscheinlichkeitsmaß  $\hat{\mathbb{P}}(X \in \cdot \mid Y = y)$  auf  $\mathcal{B}(\mathbb{R}^d)$ . Definiere

$$\mathbb{P}(X \in \cdot \mid Y = y) = \begin{cases} \hat{\mathbb{P}}(X \in \cdot \mid Y = y) & y \notin N \\ \mathbb{P}_0 \text{ beliebiges Wahrscheinlichkeitsmaß} & y \in N \end{cases}$$

dann ist  $\mathbb{P}(Y \in \cdot \mid Y = y)$  ein Wahrscheinlichkeitsmaß.

5.  $\mathbb{P}(X \in \cdot \mid Y = y)$  ist eine Version der bedingten Verteilung.

(↗ befindet sich in einer PDF-Datei auf Opal, eventuell hier hinzufügen später!)

□

### Satz VI.6

$(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum,  $X, Y: (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$  Zufallsvariablen mit gemeinsamer Dichte  $\rho_{X,Y}(x, y)$ . Dann besitzen  $X$  und  $Y$  die Randdichten ("Marginaldichten")

$$\rho_X(x) = \int_{\mathbb{R}} \rho_{X,Y}(x, y) dy \quad \text{und} \quad \rho_Y(y) = \int_{\mathbb{R}} \rho_{X,Y}(x, y) dx$$

Zudem gilt für alle  $A \in \mathcal{B}(\mathbb{R}), y \in \mathbb{R}$ :

$$\mathbb{P}(X \in A \mid Y = y) = \begin{cases} \int_A \frac{\rho_{X,Y}(x, y)}{\rho_Y(y)} dx & \rho_Y(y) \neq 0 \\ 0 & \text{sonst} \end{cases}$$

Insbesondere besitzt  $\mathbb{P}(X \in \cdot \mid Y = y)$  für alle  $y \in \mathbb{R}$  mit  $\rho_Y(y) > 0$  die Dichte (bedingte Dichte)

$$\rho_{X|Y}(x, y) = \frac{\rho_{X,Y}(x, y)}{\rho_Y(y)}$$

und ist in diesem Fall ein Wahrscheinlichkeitsmaß.

*Beweis.* Randdichten:

$$\begin{aligned} \mathbb{P}(X \in A) &= \mathbb{P}(X \in A, Y \in \mathbb{R}) = \int_{\mathbb{R}} \int_A \rho_{X,Y}(x, y) dx dy \\ &= \int_A \underbrace{\int_{\mathbb{R}} \rho_{X,Y}(x, y) dy}_{\rho_X(x)} dx \end{aligned}$$

Zudem gilt für  $A, B \in \mathcal{B}(\mathbb{R})$

$$\begin{aligned}
\mathbb{P}(X \in A, Y \in B) &= \int_B \int_A \rho_{X,Y}(x, y) \, dx \, dy \\
&= \int_B \int_A \rho_{X,Y}(x, y) \mathbb{1}_{\rho_Y(y) > 0} \, dx \, dy \\
&\quad + \int_B \int_A \rho_{X,Y}(x, y) \mathbb{1}_{\rho_Y(y) = 0} \, dx \, dy \\
&= \int_B \int_A \frac{\rho_{X,Y}(x, y)}{\rho_Y(y)} \mathbb{1}_{\rho_Y(y) > 0} \, dx \rho_Y(y) \, dy + \\
&\quad + \underbrace{\int_{B \cap \rho_Y(y)=0} \int_A \rho_{X,Y}(x, y) \, dx \, dy}_{\leq \int_{\mathbb{R}} \rho_{X,Y}(x, y) \, dx = \rho_Y(y)} \\
&= \int_B \int_A \frac{\rho_{X,Y}(x, y)}{\rho_Y(y)} \mathbb{1}_{\rho_Y(y) > 0} \, dx \mathbb{P}_Y(dy),
\end{aligned}$$

so dass

$$\mathbb{P}(X \in A \mid Y = y) = \begin{cases} \int_A \frac{\rho_{X,Y}(x, y)}{\rho_Y(y)} \, dx & \rho_Y(y) > 0 \\ 0 & \text{sonst} \end{cases}$$

nach Definition der bedingten Verteilung Definition VI.4. Für  $y$  mit  $\rho_Y(y) > 0$  folgt

$$\mathbb{P}(X \in \mathbb{R} \mid Y = y) = \int_{\mathbb{R}} \frac{\rho_{X,Y}(x, y)}{\rho_Y(y)} \, dx = \frac{1}{\rho_Y(y)} \int_{\mathbb{R}} \rho_{X,Y}(x, y) \, dx = \frac{\rho_Y(y)}{\rho_Y(y)} = 1. \quad \square$$

### ■ Beispiel VI.7

Betrachte  $f(x, y) = cxe^{-x(y+1)}$   $x, y > 0$   $c \in \mathbb{R}$  bestimmt. Damit  $f$  die Dichte zweier Zufallsvariablen  $X, Y$  ist, muss

$$\int_{\mathbb{R}_+} \int_{\mathbb{R}_+} f(x, y) \, dx \, dy \stackrel{!}{=} 1$$

gelten. Dazu sei

$$\begin{aligned}
\int_0^\infty \int_0^\infty cxe^{-x(y+1)} \, dy \, dx &= c \int_0^\infty xe^{-x} \int_0^\infty e^{-xy} \, dy \, dx \\
&= c \int_0^\infty xe^{-x} \left[ -\frac{1}{x} e^{-xy} \right]_{y=0}^\infty \\
&= c \underbrace{\int_0^\infty e^{-x} \, dx}_{=1} = c \stackrel{!}{=} 1
\end{aligned}$$

Wähle  $x = 1$ . Als Randdichten von  $X$  und  $Y$  folgen

$$\begin{aligned}
f_X(x) &= \int_0^\infty f(x, y) \, dy = \int_0^\infty xe^{-x(y+1)} \, dy \\
&\stackrel{\text{s.o.}}{=} e^{-x} \quad x > 0
\end{aligned}$$



(d.h.  $X \sim \text{Exp}(1)$ ) und

$$\begin{aligned}
 f_Y(y) &= \int_0^\infty f(x, y) \, dx = \int_0^\infty x e^{-x(y+1)} \, dx \\
 &\stackrel{\text{P.I.}}{=} \left[ -x \frac{1}{y+1} e^{-x(y+1)} \right]_{x=0}^\infty + \frac{1}{y+1} \int_0^\infty e^{-x(y+1)} \, dx \\
 &= 0 + \frac{1}{y+1} \left[ \frac{-1}{y+1} e^{-x(y+1)} \right]_{x=0}^\infty \\
 &= \frac{1}{(y+1)^2} \quad y > 0
 \end{aligned}$$

(Dies ist die Dichte einer PARETO-Verteilung.) Insbesondere sind  $X$  und  $Y$  nicht unabhängig, da sonst  $f(x, y) = f_X(x)f_Y(y)$  gelten müsste. Die bedingte Dichte von  $X$  gegeben  $Y = y_0, y_0 > 0$  berechnet sich als

$$f_{X|Y=y_0}(x) = \frac{f(x, y_0)}{f_Y(y_0)} = x(y_0 + 1)^2 e^{-x(y_0+1)}$$

und dies ist die Dichte einer Gamma( $y_0 + 1, 2$ )-Verteilung, d.h.

$$X \mid Y = y_0 \sim \text{Gamma}(y_0 + 1, 2).$$

## 2. Bedingte Erwartungswerte

### Satz VI.8

$(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum und  $X: (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$  und  $Y: (\Omega, \mathcal{F}) \rightarrow (\Omega_Y, \mathcal{F}_Y)$  Zufallsvariable, so dass  $\mathbb{E}[X]$  existiert ( $X \in \mathcal{L}^1(\mathbb{P})$  oder  $X \geq 0$ ). Dann existiert eine messbare Funktion  $g: (\Omega_Y, \mathcal{F}_Y) \rightarrow (\bar{\mathbb{R}}, \mathcal{B}(\bar{\mathbb{R}}))$ , so dass gilt

$$\mathbb{E}[X \mathbb{1}_{y \in B}] = \int_{y \in B} X \, d\mathbb{P} = \int_B g(y) \mathbb{P}_Y(dy) \quad \forall B \in \mathcal{F}_Y$$

Dieses  $g$  ist  $\mathbb{P}_Y$ -f.s. (fast sicher) eindeutig bestimmt. Wir nennen  $\mathbb{E}[X \mid Y = y] = g(y)$  bedingten Erwartungswert/bedingte Erwartung von  $X$  gegeben  $Y = y$ .

*Beweis.*

1. Sei  $X \geq 0$ . Definiere ein Maß  $\mu$  auf  $\mathcal{F}_Y$  durch

$$\mu(B) = \mathbb{E}[X \mathbb{1}_{y \in B}]$$

dann ist  $\mu \ll \mathbb{P}_Y$ . Aus dem Satz von RADON-NIKODYM (Satz VI.1) folgt die Existenz einer  $\mathbb{P}_Y$ -f.s. bestimmten Dichte  $g$ .

2. Sei  $X \in \mathcal{L}^1(\mathbb{P})$ . Es gilt  $\mathbb{E}[X^-] < \infty$  oder  $\mathbb{E}[X^+] < \infty$ . Sei oBdA  $\mathbb{E}[X^-] < \infty$ , dann folgt auch  $\mathbb{E}[X^- \mid Y = y] < \infty$   $\mathbb{P}_Y$  f.s.. Setze

$$\mathbb{E}[X \mid Y = y] := \begin{cases} \mathbb{E}[X^+ \mid Y = y] - \mathbb{E}[X^- \mid Y = y] & \mathbb{E}[X^- \mid Y = y] < \infty \\ 0 & \text{sonst.} \end{cases}$$

Dann folgt

$$\begin{aligned}
 \mathbb{E}[X \mathbb{1}_{y \in B}] &= \mathbb{E}[X^+ \mathbb{1}_{y \in B}] - \mathbb{E}[X^- \mathbb{1}_{y \in B}] \\
 &= \int_B \mathbb{E}[X^+ | Y = y] \mathbb{P}_Y(dy) - \int_B \mathbb{E}[X^- | Y = y] \mathbb{P}_Y(dy) \\
 &= \int_B \mathbb{E}[X | Y = y] \mathbb{P}_Y(dy) \quad \forall B \in \mathcal{F}_Y.
 \end{aligned}$$

Sind  $g_1, g_2$  zwei Versionen der bedingten Erwartung, dann gilt wegen  $\mathbb{E}[X^-] < \infty$  auch  $\int_{\Omega_Y} g_1^-(y) \mathbb{P}_Y(dy) < \infty$  für  $i = 1, 2$  und dann folgt

$$\begin{aligned}
 \int_B g_1^+(y) \mathbb{P}_Y(dy) &= \int_B g_1^-(y) \mathbb{P}_Y(dy) \\
 &= \int_B g_1(y) \mathbb{P}_Y(dy) \\
 &= \int_B g_2(y) \mathbb{P}_Y(dy) \\
 &= \int_B g_2^+(y) \mathbb{P}_Y(dy) - \int_B g_2^-(y) \mathbb{P}_Y(dy) \\
 &\implies \int_B (g_1^+(y) + g_2^+(y)) \mathbb{P}_Y(dy) \\
 &= \int_B (g_2^+(y) + g_1^-(y)) \mathbb{P}_Y(dy) \quad \forall B \in \mathcal{F}_Y
 \end{aligned}$$

also

$$g_1^+ + g_2^+ = g_2^+ + g_1^- \text{ } \mathbb{P}_Y\text{-f.s.}$$

impliziert

$$g_1^+ - g_1^- = g_1 = g_2 = g_2^+ - g_2^- \text{ } \mathbb{P}_Y\text{-fast-sicher.}$$

□

### ► Bemerkung

Bedingte Erwartung und bedingte Verteilung hängen zusammen:

- Sind  $X, Y$  so dass  $\mathbb{E}X$  existiert und eine reguläre bedingte Verteilung  $\mathbb{P}_{X|Y=y}(B) = \mathbb{P}(X \in B | Y = y)$  existiert, dann folgt

$$\mathbb{E}[X | Y = y] = \int_{\mathbb{R}} x \mathbb{P}_{X|Y=y}(dx).$$

Für Treppenfunktionen  $X = \sum_{i=1}^n \alpha_i \mathbb{1}_{A_i}$ ,  $\alpha_i > 0$ ,  $A_i$  disjunkt, folgt dies aus

$$\begin{aligned}
 \mathbb{E}[X \mathbb{1}_{y \in B}] &= \sum_{i=1}^n \alpha_i \mathbb{E}[\mathbb{1}_{A_i} \mathbb{1}_{y \in B}] \\
 &= \sum_{i=1}^n \alpha_i \mathbb{P}(X = \alpha_i, y \in B) \\
 &= \sum_{i=1}^n \alpha_i \int_B \mathbb{P}(X = \alpha_i \mid Y = y) \mathbb{P}_Y(dy) \\
 &= \int_B \sum_{i=1}^n \alpha_i \mathbb{P}(X = \alpha_i \mid Y = y) \mathbb{P}_Y(dy) \\
 &= \int_B \int_{\mathbb{R}} x \mathbb{P}_{X|Y=y}(dx) \mathbb{P}(dy)
 \end{aligned}$$

Für allgemeines  $X$  folgt die Aussage mittels maßtheoretischer Induktion.

Durch Einsetzen von  $X = \mathbb{1}_A$  in Gleichung in (??) folgt

$$\begin{aligned}
 \int_B \mathbb{E}[\mathbb{1}_A \mid Y = y] \mathbb{P}_Y(dy) &= \int_{Y \in B} \mathbb{1}_A d\mathbb{P} \\
 &= \mathbb{E}[\mathbb{1}_A \mathbb{1}_{y \in B}] \\
 &= \mathbb{P}(A \cap \{Y \in B\})
 \end{aligned}$$

und durch Vergleich mit Definition der bedingten Verteilung (Definition VI.4)

$$\mathbb{E}[\mathbb{1}_A \mid Y = y] = \mathbb{P}(A \mid Y = y) \quad \mathbb{P}\text{-f.s.}$$

### ■ Beispiel VI.9

Betrachte Beispiel VI.7, d.h. gegeben seien zwei Zufallsvariablen  $X, Y$  mit Dichte

$$f(x, y) = x e^{-x(y+1)} \quad x, y > 0$$

Die Erwartungswerte von  $X$  und  $Y$  folgen aus den Randdichten:

$$\mathbb{E}[X] = 1 \quad \text{da } X \sim \text{Exp}(1)$$

und

$$\begin{aligned}
 \mathbb{E}[Y] &= \int_0^\infty y f_y(y) dy = \int_0^\infty y \frac{1}{(y+1)^2} dy \\
 &= \int_0^\infty (z-1) \frac{1}{z^2} dz \\
 &= \int_1^\infty \frac{1}{z} dz - \int_1^\infty \frac{1}{z^2} dz = \infty
 \end{aligned}$$

Der bedingte Erwartungswert von  $X$  gegeben  $Y = y_0 > 0$  ist

$$\begin{aligned}\mathbb{E}[X \mid Y = y_0] &= \int_0^\infty x f_{X|Y=y_0}(x) \, dx \\ &= \int_0^\infty x^2 (y_0 + 1)^2 e^{-x(y_0+1)} \, dx \\ &= \frac{2}{y_0 + 1}\end{aligned}$$

da  $X \mid Y = y_0 \sim \text{Gamma}(y_0 + 1, 2)$ .

## 2.1. Der bedingte Erwartungswert als Zufallsvariable

Bisher: Bedingung der Form:  $Y = y \implies$  Sowohl bedingte Verteilung

$$\mu_A : (\Omega_Y, \mathcal{F}_Y) \rightarrow ([0, 1], \mathcal{B}([0, 1]))$$

als auch bedingte Erwartung

$$g : (\Omega_Y, \mathcal{F}_Y) \rightarrow (\bar{\mathbb{R}}, \mathcal{B}(\bar{\mathbb{R}}))$$

sind messbar.

Wir können also auch die Zufallsvariablen

$$\begin{aligned}\mu_A(Y) &=: \mathbb{P}(X \in A \mid Y) \\ g(Y) &=: \mathbb{E}[X \mid Y]\end{aligned}$$

betrachten.

### Definition VI.10 (bedingte Erwartung und Wahrscheinlichkeit)

$(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum,  $X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$  und  $Y : (\Omega, \mathcal{F}) \rightarrow (\Omega_Y, \mathcal{F}_Y)$  Zufallsvariablen, so dass  $\mathbb{E}[X]$  existiert. Die bedingte Erwartung von  $X$  gegeben  $Y$  ist die Zufallsvariable  $g(Y)$  mit

$$\begin{aligned}\int_{\{Y \in B\}} X(\omega) \mathbb{P}(\,d\omega) &= \int_{\{Y \in B\}} g(Y)(\omega) \mathbb{P}(\,d\omega) \\ &= \int_B g(y) \mathbb{P}_Y(\,dy) \quad \forall B \in \mathcal{F}_Y.\end{aligned}$$

Schreibe  $g(Y) =: \mathbb{E}[X \mid Y] =: \mathbb{E}[X \mid \sigma(Y)]$ .

$$\mathbb{P}(A \mid \sigma(Y)) := \mathbb{P}(A \mid Y) = \mathbb{E}[\mathbb{1}_A \mid Y]$$

ist die bedingte Wahrscheinlichkeit von  $A$  gegeben  $Y$ .

## 2.2. Bedingen auf beliebige $\sigma$ -Algebren

**Definition VI.11**

$(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum,  $X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$  Zufallsvariablen, so dass  $\mathbb{E}[X]$  existiert und  $\mathcal{G} \subset \mathcal{F}$   $\sigma$ -Algebra. Die bedingte Erwartung von  $X$  gegeben  $\mathcal{G}$  ist die  $\mathcal{G}$ -messbare Zufallsvariable  $X_{\mathcal{G}}$  mit

$$\int_G X(\omega) \mathbb{P}(d\omega) = \int_G X_{\mathcal{G}}(\omega) \mathbb{P}(d\omega) \quad \forall G \in \mathcal{G} \quad (\star)$$

Schreibe:  $X_{\mathcal{G}} = \mathbb{E}[X \mid \mathcal{G}]$ .  $\mathbb{P}(A \mid \mathcal{G}) := \mathbb{E}[\mathbb{1}_A \mid \mathcal{G}]$  heißt bedingte Wahrscheinlichkeit von  $A$  gegeben  $\mathcal{G}$ .

**► Bemerkung**

- Existenz und Eindeutigkeit (bis auf  $\mathcal{G}$ -Nullmengen) der bedingten Erwartung folgen wieder aus RADON-NIKODYM (Satz VI.1).
- Die Gleichung  $(\star)$  können wir umschreiben:

$$\mathbb{E}[\mathbb{E}[X \mid \mathcal{G}] \mathbb{1}_G] = \mathbb{E}[X \mathbb{1}_G] \quad \forall G \in \mathcal{G}$$

- $\mathbb{E}[X \mid \mathcal{G}]$  ist nur bis auf  $\mathcal{G}$ -Nullmengen bestimmt. Spreche daher von “Versionen” der bedingten Erwartung.

Die bedingte Erwartung übernimmt Eigenschaften der Erwartung:

**Lemma VI.12 (Rechenregeln bedingter Erwartungswert 1)**

$(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum,  $\mathcal{G} \subseteq \mathcal{F}$   $\sigma$ -Algebra,  $X, Y : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$  Zufallsvariablen, so dass  $\mathbb{E}[X], \mathbb{E}[Y]$  existieren.

1. Positivität:

$$X \geq 0 \quad \mathbb{P}\text{-f.s.} \implies \mathbb{E}[X \mid \mathcal{G}] \geq 0 \quad \mathbb{P}\text{-f.s.}$$

2. Konservativität:

$$X \equiv c \in \mathbb{R} \implies \mathbb{E}[X \mid \mathcal{G}] = c \quad \mathbb{P}\text{-f.s.}$$

3. Linearität: Für  $a, b \in \mathbb{R}$  und  $X, Y \in \mathcal{L}^1(\mathbb{P})$

$$\mathbb{E}[aX + bY \mid \mathcal{G}] = a\mathbb{E}[X \mid \mathcal{G}] + b\mathbb{E}[Y \mid \mathcal{G}] \quad \mathbb{P}\text{-f.s.}$$

4. Monotonie:

$$X \leq Y \implies \mathbb{E}[X \mid \mathcal{G}] \leq \mathbb{E}[Y \mid \mathcal{G}] \quad \mathbb{P}\text{-f.s.}$$

*Beweis.*

1. Folgt aus Definition VI.11.
2. Betrachte

$$\int_G X(\omega) \mathbb{P}(d\omega) = \int_G x \mathbb{P}(d\omega)$$

$\implies c$  ist Version der bedingten Erwartung.

3. Betrachte

$$\begin{aligned} \int_G (aX + bY) d\mathbb{P} &= a \int_G X d\mathbb{P} + b \int_G Y d\mathbb{P} \text{ nutze Linearität des Integrals} \\ &\stackrel{(\star)}{=} a \int_G \mathbb{E}[X | \mathcal{G}] d\mathbb{P} + b \int_G \mathbb{E}[Y | \mathcal{G}] d\mathbb{P} \\ &= \int_G (a\mathbb{E}[X | \mathcal{G}] + b\mathbb{E}[Y | \mathcal{G}]) d\mathbb{P} \end{aligned}$$

$\implies a\mathbb{E}[X | \mathcal{G}] + b\mathbb{E}[Y | \mathcal{G}]$  ist Version von  $\mathbb{E}[aX + bY | \mathcal{G}]$

4.  $X \leq Y \implies Y - X \geq 0$  und mit 1. und 3.  $\implies$  Behauptung.  $\square$

### Satz VI.13 (Konvergenzsätze der bedingten Erwartung)

$(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum  $\mathcal{G} \subseteq \mathcal{F}$   $\sigma$ -Algebra,  $X, X_1, X_2, \dots : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$  Zufallsvariablen

1. BEPPO-LEVI bedingt:

$$X_n \geq 0 \quad X_n \in \mathcal{L}^1(\mathbb{P}) \quad X_n \uparrow X \text{ und } \sup_{n \in \mathbb{N}} \mathbb{E}[X_n] < \infty \quad \mathbb{P}\text{-f.s.}$$

Dann gilt:  $\mathbb{E}[X | \mathcal{G}] = \sup_{n \in \mathbb{N}} \mathbb{E}[X_n | \mathcal{G}] = \lim_{n \rightarrow \infty} \mathbb{E}[X_n | \mathcal{G}] \quad \mathbb{P}\text{-f.s.}$

2. FATOU bedingt:  $X_n \geq 0, X_n \in \mathcal{L}^1(\mathbb{P})$  und  $\liminf_{n \rightarrow \infty} \mathbb{E}[X_n] < \infty$

Dann gilt

$$\mathbb{E}\left[\liminf_{n \rightarrow \infty} X_n | \mathcal{G}\right] \leq \liminf_{n \rightarrow \infty} \mathbb{E}[X_n | \mathcal{G}] \quad \mathbb{P}\text{-f.s.}$$

3. Dominierte-Konvergenz bedingt:  $\lim_{n \rightarrow \infty} X_n = X \quad \mathbb{P}\text{-f.s.}$  und  $|X_n| \leq Y \quad \mathbb{P}\text{-f.s.}$  mit  $Y \in \mathcal{L}^1(\mathbb{P})$ , dann gilt  $X \in \mathcal{L}^1(\mathbb{P})$  und

$$\lim_{n \rightarrow \infty} \mathbb{E}[X_n | \mathcal{G}] = \mathbb{E}[X | \mathcal{G}] \quad \mathbb{P}\text{-f.s.}$$

*Beweis.*

1. Aus BEPPO-LEVI (klassisch) folgt:

$$\mathbb{E}[X] = \sup_{n \in \mathbb{N}} \mathbb{E}[X_n] < \infty$$

also  $X \in \mathcal{L}^1(\mathbb{P})$  und damit existiert  $\mathbb{E}[X | \mathcal{G}]$ .  $\mathbb{E}[X_n | \mathcal{G}]$  ist monoton wachsend (Lemma VI.12). Also

$$\begin{aligned} \int_G \sup_{n \in \mathbb{N}} \mathbb{E}[X_n | \mathcal{G}] d\mathbb{P} &= \sup_{n \in \mathbb{N}} \int_G \mathbb{E}[X_n | \mathcal{G}] d\mathbb{P} \\ &\stackrel{\text{Definition VI.11}}{=} \sup_{n \in \mathbb{N}} \int_G X_n d\mathbb{P} \\ &= \int_G \sup_{n \in \mathbb{N}} X_n d\mathbb{P} \end{aligned}$$

2.  $\nearrow$  HA 8.2a

3. ↗ HA 8.2b

□

**Satz VI.14 (Rechenregeln bedingter Erwartungswert 2)**

$(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum,  $\mathcal{G} \subseteq \mathcal{F}$   $\sigma$ -Algebra und  $X, Y : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$  Zufallsvariablen, so dass  $\mathbb{E}[X]$  existiert. Es gelten:

1. Triviale  $\sigma$ -Algebra:

$$\mathbb{E}[X \mid \{\emptyset, \Omega\}] = \mathbb{E}[X]$$

2. einfache Turmeigenschaft:

$$\mathbb{E}[\mathbb{E}[X \mid \mathcal{G}]] = \mathbb{E}[X]$$

3. allgemeine Turmeigenschaft: Sei  $\mathcal{H} \subseteq \mathcal{G} \subseteq \mathcal{F}$   $\sigma$ -Algebra, dann

$$\mathbb{E}[\mathbb{E}[X \mid \mathcal{G}] \mid \mathcal{H}] = \mathbb{E}[X \mid \mathcal{H}] \quad \mathbb{P}\text{-f.s.}$$

4. Messbares Herausziehen: Ist  $Y$   $\mathcal{G}$ -messbar und gilt  $\mathbb{E}[XY] < \infty$ , dann

$$\mathbb{E}[XY \mid \mathcal{G}] = Y \mathbb{E}[X \mid \mathcal{G}]$$

*Beweis.* 1. Offenbar ist  $\{\emptyset, \Omega\}$   $\sigma$ -Algebra. Es gilt:

$$\int_G X \, d\mathbb{P} = \begin{cases} 0 & G = \emptyset \\ \mathbb{E}[X] & G = \Omega \end{cases}$$

und

$$\int_G \mathbb{E}[X] \, d\mathbb{P} = \begin{cases} 0 & G = \emptyset \\ \mathbb{E}[X] & G = \Omega \end{cases}$$

Also ist  $\mathbb{E}[X]$  eine Version von  $\mathbb{E}[X \mid \{\emptyset, \Omega\}]$ .

2. Sei

$$\begin{aligned} \mathbb{E}[\mathbb{E}[X \mid \mathcal{G}]] &\stackrel{\text{Def. EW}}{=} \int_{\Omega} \mathbb{E}[X \mid \mathcal{G}] \, d\mathbb{P} \\ &\stackrel{\text{VI.11, } \Omega \in \mathcal{G}}{=} \int_{\Omega} X \, d\mathbb{P} = \mathbb{E}[X] \end{aligned}$$

3. Für  $H \in \mathcal{H}$  gilt

$$\begin{aligned} \int_H \mathbb{E}[X \mid \mathcal{G}] \, d\mathbb{P} &\stackrel{\text{VI.11, } H \in \mathcal{G}}{=} \int_H X \, d\mathbb{P} \\ &\stackrel{\text{VI.11}}{=} \int_H \mathbb{E}[X \mid \mathcal{H}] \, d\mathbb{P} \end{aligned}$$

also ist  $\mathbb{E}[X \mid \mathcal{H}]$  eine Version von  $\mathbb{E}[\mathbb{E}[X \mid \mathcal{G}] \mid \mathcal{H}]$ .

4. Sei zunächst  $Y = \mathbb{1}_B$  mit  $B \in \mathcal{G}$ . Dann folgt für  $G \in \mathcal{G}$

$$\begin{aligned} \int_G Y \mathbb{E}[X | \mathcal{G}] d\mathbb{P} &= \int_{G \cap B} \mathbb{E}[X | \mathcal{G}] d\mathbb{P} \\ &\stackrel{\text{VI.11, } G \cap B \in \mathcal{G}}{=} \int_{G \cap B} X d\mathbb{P} \\ &= \int_G XY d\mathbb{P} \\ &\stackrel{\text{VI.11}}{=} \int_G \mathbb{E}[XY | \mathcal{G}] d\mathbb{P} \end{aligned}$$

und  $Y \mathbb{E}[X | \mathcal{G}]$  ist Version von  $\mathbb{E}[XY | \mathcal{G}]$ . Die allgemeine Aussage folgt mit maßtheoretischer Induktion.

□

### ■ Beispiel VI.15

Ein KFZ-Versicherungsunternehmen modelliert die Schäden, die aus einem Portfolio von Verträgen stammen. Alle Zufallsvariablen  $X_1, X_2, X_3, \dots$  sind unabhängig und identisch verteilt. (u.i.v) Zudem sei  $N$  eine Zufallsvariable mit Werten in  $\mathbb{N}_0$ , welche die Anzahl der Schäden in einem Jahr modelliert.  $N$  und  $\{X_1, X_2, \dots\}$  seien unabhängig. Der Gesamtschaden im Jahr des Portfolios ist dann

$$S = \sum_{i=1}^N X_i$$

Der erwartete Gesamtschaden ist

$$\begin{aligned} \mathbb{E}[S] &= \mathbb{E}\left[\sum_{i=1}^N X_i\right] \\ &= \mathbb{E}\left[\mathbb{E}\left[\sum_{i=1}^N X_i \mid N\right]\right] \quad (\text{Turmeigs.}) \\ &= \sum_{n=0}^{\infty} \mathbb{E}\left[\sum_{i=1}^N X_i \mid N=n\right] \mathbb{P}(N=n) \quad (\text{Def. EW.}) \\ &= \sum_{n=0}^{\infty} \mathbb{E}\left[\sum_{i=1}^n X_i\right] \mathbb{P}(N=n) \quad (X_i \perp\!\!\!\perp N) \\ &= \sum_{n=0}^{\infty} \sum_{i=1}^n \mathbb{E}[X_i] \mathbb{P}(N=n) \quad (\text{Linearität}) \\ &= \sum_{n=0}^{\infty} \sum_{i=1}^n \mathbb{E}[X_1] \mathbb{P}(N=n) \quad (X_i \text{ identisch verteilt}) \\ &= \mathbb{E}[X_1] \sum_{n=0}^{\infty} n \mathbb{P}(N=n) \\ &= \mathbb{E}[X_1] \cdot \mathbb{E}[N] \quad (\text{WALD-Gleichung}) \end{aligned}$$

## Bedingte Varianz



**Definition VI.16 (Bedingte Varianz)**

$(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum,  $\mathcal{G} \subseteq \mathcal{F}$   $\sigma$ -Algebra,  $X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$  mit  $X \in \mathcal{L}^2(\mathbb{P})$ . Dann ist

$$\mathbb{V}\text{ar}(X \mid \mathcal{G}) = \mathbb{E}[(X - \mathbb{E}[X \mid \mathcal{G}])^2 \mid \mathcal{G}]$$

die bedingte Varianz von  $X$  gegeben  $\mathcal{G}$ .

**Lemma VI.17 (Eigenschaft der bedingten Varianz)**

$(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum,  $\mathcal{G} \subseteq \mathcal{F}$   $\sigma$ -Algebra,  $X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$  Zufallsvariable in  $\mathcal{L}^2(\mathbb{P})$ . Es gelten:

1. Positivität:  $\mathbb{V}\text{ar}(X \mid \mathcal{G}) \geq 0$   $\mathbb{P}$ -f.s.

2. Für  $a, b \in \mathbb{R}$ :

$$\mathbb{V}\text{ar}(aX + b \mid \mathcal{G}) = a^2 \mathbb{V}\text{ar}(X \mid \mathcal{G})$$

3. Verschiebungssatz:

$$\mathbb{V}\text{ar}(X \mid \mathcal{G}) = \mathbb{E}[X^2 \mid \mathcal{G}] - (\mathbb{E}[X \mid \mathcal{G}])^2$$

*Beweis.* 1. Definition und Positivitätseigenschaft der bedingten Erwartung.

2. Linearität der bedingten Erwartung und Rechenregeln wie im klassischen Fall.

3. Betrachte

$$\begin{aligned} \mathbb{E}[(X - \mathbb{E}[X \mid \mathcal{G}])^2 \mid \mathcal{G}] &= \\ &= \mathbb{E}[X^2 \mid \mathcal{G}] - 2\underbrace{\mathbb{E}[X \mathbb{E}[X \mid \mathcal{G}] \mid \mathcal{G}]}_{\text{mb}} - \mathbb{E}[(\mathbb{E}[X \mid \mathcal{G}])^2 \mid \mathcal{G}] \\ &\stackrel{\text{mb herausziehen}}{=} \mathbb{E}[X^2 \mid \mathcal{G}] - 2\underbrace{\mathbb{E}[X \mid \mathcal{G}]\mathbb{E}[X \mid \mathcal{G}]}_{\text{1, Konservation}} + (\mathbb{E}[X \mid \mathcal{G}])^2 \\ &= \mathbb{E}[X^2 \mid \mathcal{G}] - (\mathbb{E}[X \mid \mathcal{G}])^2. \end{aligned} \quad \square$$

**Lemma VI.18 (Varianzzerlegung)**

$(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum,  $\mathcal{G} \subseteq \mathcal{F}$ ,  $X : (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$  Zufallsvariable in  $\mathcal{L}^2(\mathbb{P})$ . Dann:

$$\mathbb{V}\text{ar}(X) = \mathbb{E}[\mathbb{V}\text{ar}(X \mid \mathcal{G})] + \mathbb{V}\text{ar}(\mathbb{E}[X \mid \mathcal{G}])$$

*Beweis.* Sei

$$\begin{aligned} \mathbb{V}\text{ar}(\mathbb{E}[X \mid \mathcal{G}]) &= \mathbb{E}[(\mathbb{E}[X \mid \mathcal{G}])^2] - \mathbb{E}[\mathbb{E}[X \mid \mathcal{G}]]^2 \\ &\stackrel{\text{Turmegs.}}{=} \mathbb{E}[(\mathbb{E}[X \mid \mathcal{G}])^2] - (\mathbb{E}[X])^2 \end{aligned}$$

$$\begin{aligned}
\mathbb{E}[\text{Var}(X \mid \mathcal{G})] &\stackrel{\text{VI.17}}{=} \mathbb{E}[\mathbb{E}[X^2 \mid \mathcal{G}] - \mathbb{E}[X \mid \mathcal{G}]^2] \\
&= \mathbb{E}[\mathbb{E}[X^2 \mid \mathcal{G}]] - \mathbb{E}[\mathbb{E}[X \mid \mathcal{G}]^2] \\
&\stackrel{\text{Turm}}{=} \mathbb{E}[X^2] - \mathbb{E}[\mathbb{E}[X \mid \mathcal{G}]^2]
\end{aligned}$$

Durch Addition folgt die Behauptung.  $\square$

### ■ Beispiel VI.19

Betrachte  $S = \sum_{i=1}^N X_i$  aus Beispiel VI.15 mit  $N, X_i \in \mathcal{L}^2(\mathbb{P})$ . Aus der Varianzzerlegung folgt

$$\text{Var}(S) = \mathbb{E}[\text{Var}(S \mid N)] + \text{Var}(\mathbb{E}[S \mid N])$$

wobei

$$\begin{aligned}
\mathbb{E}[\text{Var}(S \mid N)] &= \sum_{n=0}^{\infty} \text{Var}(S \mid N = n) \mathbb{P}(N = n) \\
&= \sum_{n=0}^{\infty} \text{Var}\left(\sum_{i=1}^n X_i\right) \mathbb{P}(N = n) \\
&= \sum_{n=0}^{\infty} \sum_{i=1}^n \text{Var}(X_i) \mathbb{P}(N = n) \quad \text{BIENAYMÉ } X_i \text{ unabh.} \\
&= \text{Var}(X_1) \sum_{n=0}^{\infty} n \mathbb{P}(N = n) \\
&= \text{Var}(X_1) \mathbb{E}[N]
\end{aligned}$$

und

$$\begin{aligned}
\text{Var}(\mathbb{E}[S \mid N]) &= \mathbb{E}[(\underbrace{\mathbb{E}[S \mid N]}_{\mathbb{E}[S] = \mathbb{E}[X_1]\mathbb{E}[N], \text{VI.15}} - \mathbb{E}[\mathbb{E}[S \mid N]])^2] \quad \text{Def. Varianz} \\
&= \sum_{n=0}^{\infty} (\mathbb{E}[S \mid N = n] - \mathbb{E}[X_1]\mathbb{E}[N])^2 \mathbb{P}(N = n) \\
&= \sum_{n=0}^{\infty} (n\mathbb{E}[X_1] - \mathbb{E}[X_1]\mathbb{E}[N])^2 \mathbb{P}(N = n) \\
&= \mathbb{E}[X_1]^2 \sum_{n=0}^{\infty} (n - \mathbb{E}[N])^2 \mathbb{P}(N = n) \\
&= \mathbb{E}[X_1]^2 \cdot \underbrace{\sum_{n=0}^{\infty} n^2 \mathbb{P}(N = n)}_{\mathbb{E}[N^2]} - 2\mathbb{E}[N] \cdot \underbrace{\sum_{n=0}^{\infty} n \mathbb{P}(N = n)}_{\mathbb{E}[N]} \\
&\quad + \mathbb{E}[N]^2 \underbrace{\sum_{n=0}^{\infty} \mathbb{P}(N = n)}_{=1} \\
&= \mathbb{E}[X_1]^2 (\mathbb{E}[N^2] - \mathbb{E}[N]^2) = \mathbb{E}[X_1]^2 \text{Var}(N) \\
&\implies \text{Var}(S) = \text{Var}(X_1) \mathbb{E}[N] + (\mathbb{E}[X_1])^2 \text{Var}(N)
\end{aligned}$$

## Kapitel VII

# Die Normalverteilung

### Definition VII.1

Sei  $\mu \in \mathbb{R}, \sigma^2 > 0$ . Das Wahrscheinlichkeitsmaß  $\mathcal{N}(\mu, \sigma^2)$  auf  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  mit Dichtefunktion

$$g_{\mu, \sigma^2}(x) := \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad x \in \mathbb{R}$$

heißt Normalverteilung mit Parametern  $\mu$  und  $\sigma^2$ . Im Fall  $\mu = 0, \sigma^2 = 1$ , so heißt  $\mathcal{N}(0, 1)$  Standardnormalverteilung.

### ► Bemerkung

1.  $g_{\mu, \sigma^2}$  ist Wahrscheinlichkeitsdichte, da  $\int_{\mathbb{R}} e^{-\frac{x^2}{2}} dx = \sqrt{2\pi}$ .
2.  $\mu$  und  $\sigma^2$  sind gerade Erwartungswert und Varianz der Normalverteilung  $\mathcal{N}(\mu, \sigma^2)$ . Sei  $X \sim \mathcal{N}(\mu, \sigma^2)$

$$\begin{aligned} \mathbb{E}[X] &= \frac{1}{\sqrt{2\pi\sigma^2}} \int_{\mathbb{R}} x e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx \quad y = \frac{x-\mu}{\sqrt{\sigma^2}} \\ &= \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} (\sqrt{\sigma^2}y + \mu) e^{-\frac{y^2}{2}} dy \\ &= \underbrace{\sqrt{\frac{\sigma^2}{2\pi}} \int_{\mathbb{R}} y e^{-\frac{y^2}{2}} dy}_{=0, \text{ Symmetrie}} + \underbrace{\frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} \mu e^{-\frac{y^2}{2}} dy}_{\mu \sqrt{2\pi}} = \mu \\ \mathbb{V}\text{ar}(X) &= \frac{1}{\sqrt{2\pi\sigma^2}} \int_{\mathbb{R}} (x-\mu)^2 e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx \quad y = \frac{x-\mu}{\sqrt{\sigma^2}} \\ &= \frac{\sigma^2}{\sqrt{2\pi}} \int_{\mathbb{R}} y^2 e^{-\frac{y^2}{2}} dy \\ &= \frac{\sigma^2}{\sqrt{2\pi}} \int_{\mathbb{R}} (-y)(-y e^{-\frac{y^2}{2}}) dy \\ &\stackrel{\text{P.I.}}{=} \frac{\sigma^2}{\sqrt{2\pi}} \left( \underbrace{\left[ -y e^{-\frac{y^2}{2}} \right]_{-\infty}^{\infty}}_{=0} + \underbrace{\int_{\mathbb{R}} e^{-\frac{y^2}{2}} dy}_{=\sqrt{2\pi}} \right) \\ &= \sigma^2 \end{aligned}$$

Die Popularität der Normalverteilung erklärt sich insbesondere aus dem zentralen Grenzwertsatz. Hier eine einfache Form davon

**Satz VII.2 (de Moivre-Laplace, lokaler Grenzwertsatz)**

Seien  $p \in (0, 1)$ ,  $B_{n,p}(k) = \binom{n}{k} p^k (1-p)^{n-k}$  Zähldichte  $\text{Bin}(n, p)$ ,  $g(x)$  Dichte der Standardnormalverteilung. Dann gilt für  $c > 0$  beliebig mit

$$x_n(k) = \frac{k - np}{\sqrt{np(1-p)}}$$

$$\lim_{n \rightarrow \infty} \max_{k: |x_n(k)| < c} \left| \frac{\sqrt{np(1-p)} \cdot B_{n,p}(k)}{g(x_n(k))} - 1 \right| = 0$$

*Beweis.* ↗ pdf im Opal, bzw. später als Korollar des zentralen Grenzwertsatzes. Wird eventuell noch ergänzt, wenn Zeit ist. □

**Lemma VII.3 (Stirling-Formel)**

Es gilt

$$n! \stackrel{n \rightarrow \infty}{\sim} \sqrt{2\pi n} n^n e^{-n}$$

*Beweis.* ↗ pdf im Opal, wird auch eventuell mit ergänzt. □

## Kapitel VIII

# Momenterzeugende & charakteristische Funktionen

Ziel: “Übersetze” Verteilungen in Funktionen. Insbesondere einfache Faltungsoperation ( $\nearrow$  5.3).

### Definition VIII.1

1.  $(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum  $X : \Omega \rightarrow \mathbb{R}$  Zufallsvariable. Dann heißt

$$m_X(u) := \mathbb{E}[e^{uX}] \quad u \in \mathbb{R}, \text{ so dass } m_X(u) < \infty$$

momenterzeugende Funktion von  $X$  (mgf = moment generating function)

2. Ist  $\mathbb{P}$  Verteilung auf  $\mathbb{R}$ , so heißt

$$m_{\mathbb{P}}(u) = \int_{\mathbb{R}} e^{uX} \mathbb{P}(\mathrm{d}x) \quad u \in \mathbb{R}, \text{ so dass } m_{\mathbb{P}}(u) < \infty$$

momenterzeugende Funktion von  $\mathbb{P}$ .

### ■ Beispiel VIII.2

Sei  $X \sim \text{Gamma}(\lambda, r)$ .

$$\begin{aligned} m_X(u) &= \mathbb{E}[e^{uX}] \\ &= \int_0^\infty e^{ux} \lambda e^{-\lambda x} \frac{(\lambda x)^{r-1}}{\Gamma(r)} \mathrm{d}x \\ &= \frac{\lambda^r}{\Gamma(r)} \int_0^\infty e^{-(\lambda-u)x} x^{r-1} \mathrm{d}x \quad y = (\lambda-u)x \\ &= \frac{\lambda^r}{\Gamma(r)} \int_0^\infty e^{-y} \frac{y^{r-1}}{(\lambda-u)^{r-1}} \frac{\mathrm{d}y}{(\lambda-u)} \\ &= \left( \frac{\lambda}{\lambda-u} \right)^r \quad u < \lambda \end{aligned}$$

### Lemma VIII.3

Ist  $X$   $\mathbb{N}_0$ -wertig, so gilt für alle  $u \in \mathbb{R}$  mit  $m_X(u) < \infty$

$$m_X(u) = \mathbb{E}[e^{uX}] = \psi_X(e^u)$$

*Beweis.* Klar, da folgt aus Definition VIII.1. □

**Satz VIII.4**

$(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum,  $X, Y : \Omega \rightarrow \mathbb{R}$  Zufallsvariablen mit mgfs  $m_X, m_Y$ . Es gelten:

1.  $m_X(0) = 1$

2.  $a, b \in \mathbb{R}$

$$m_{aX+b}(u) = e^{bu} m_X(au) \quad \text{für } u \text{ so dass } m_X(au) < \infty$$

3.  $X \perp\!\!\!\perp Y \implies m_{X+Y}(u) = m_X(u)m_Y(u) \quad \forall u, \text{ so dass } m_X(u), m_Y(u) < \infty$

*Beweis.* 1. Klar!

2. Sei  $m_{aX+b}(u) = \mathbb{E}[e^{aXu+bu}] = e^{bu} \mathbb{E}[e^{auX}] = e^{bu} m_X(au)$ .

- 3.

$$\begin{aligned} m_{X+Y}(u) &= \mathbb{E}[e^{Xu+Yu}] \stackrel{X \perp\!\!\!\perp Y}{=} \mathbb{E}[e^{uX}] \mathbb{E}[e^{uY}] \\ &= m_X(u) m_Y(u) \end{aligned}$$

□

Der Bezeichnung “momenterzeugend” erklärt sich mit der folgenden Proposition:

**Satz VIII.5**

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum,  $X : \Omega \rightarrow \mathbb{R}$  Zufallsvariable mit momenterzeugender Funktion  $m_X$ , so dass ein  $\varepsilon > 0$  existiert mit  $m_X(u) < \infty$  auf  $[0, \varepsilon]$ . Dann gilt

$$\mathbb{E}[X^n] = \frac{d^n}{du^n} m_X(0) \quad \forall n \in \mathbb{N}$$

*Beweis.* Für alle  $u \in \mathbb{R}$  mit  $m_X(u) < \infty$  folgt

$$\begin{aligned} m_X(u) &= \mathbb{E}[e^{uX}] = \mathbb{E}\left[\sum_{k=0}^{\infty} \frac{(uX)^k}{k!}\right] \\ &\stackrel{\text{LEBESGUE}}{=} \sum_{k=0}^{\infty} \frac{\mathbb{E}[X^k] u^k}{k!} \end{aligned}$$

n-fachen Differenzieren folgt

$$\frac{d^n}{du^n} m_X(u) = \sum_{k=0}^{\infty} \frac{\mathbb{E}[X^k]}{k!} k(k-1) \cdots (k-n+1) u^{k-n}$$

so dass

$$\frac{d^n}{du^n} m_X(0) = \frac{\mathbb{E}[X^n]}{n!} n(n-1) \cdots (n-n+1) = \mathbb{E}[X^n].$$

□

Die mgf charakterisiert eine Verteilung eindeutig:

**Satz VIII.6**

Seien  $(\Omega, \mathcal{F}, \mathbb{R}), (\Omega', \mathcal{F}', \mathbb{P}')$  Wahrscheinlichkeitsräume,  $X : \Omega \rightarrow \mathbb{R}, Y : \Omega' \rightarrow \mathbb{R}$  Zufallsvariablen mit mgfs  $m_X, m_Y$ . Wenn  $m_X(u), m_Y(u)$  in einer Umgebung um Null definiert sind und im Definitionsbereich gilt  $m_X(u) = m_Y(u)$ , so haben  $X$  und  $Y$  die selben Verteilungen ( $X \stackrel{d}{=} Y$ , d = distribution)

*Beweis.* Sind  $X, Y$   $\mathbb{N}_0$ -wertig, so folgt dies aus Lemma VIII.3 und dementsprechenden Resultat für pgfs. Der allgemeine Fall folgt aus dem Resultat zu charakteristischen Funktionen (Satz VIII.12).  $\square$

**■ Beispiel VIII.7 ((vgl. Lemma IV.3))**

Seien  $X \sim \text{Gamma}(\lambda, r), Y \sim \text{Gamma}(\lambda, s)$  unabhängig, dann gilt nach Beispiel VIII.2

$$m_X(u) = \left( \frac{\lambda}{\lambda - u} \right)^r \quad u < \lambda \quad \text{und} \quad m_Y(u) = \left( \frac{\lambda}{\lambda - u} \right)^s \quad u < \lambda$$

und nach Satz VIII.4

$$m_{X+Y}(u) = m_X(u)m_Y(u) = \left( \frac{\lambda}{\lambda - u} \right)^r \left( \frac{\lambda}{\lambda - u} \right)^s = \left( \frac{\lambda}{\lambda - u} \right)^{r+s}$$

Dies ist die mgf einer  $\text{Gamma}(\lambda, r+s)$  Verteilung. Nach Satz VIII.6 folgt  $X+Y \sim \text{Gamma}(\lambda, r+s)$ .

**Anmerkung**

- pgf:  $\psi_X(u) = \mathbb{E}[u^X]$
- mgf:  $m_X(u) = \mathbb{E}[e^{uX}]$

**Definition VIII.8**

1. Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum,  $X : \Omega \rightarrow \mathbb{R}^d$  Zufallsvariable. Dann ist

$$\varphi_X(u) := \mathbb{E}[e^{i\langle u, X \rangle}] \quad u \in \mathbb{R}^d$$

charakteristische Funktion von  $X$ .

2. Ist  $\mathbb{P}$  Verteilung in  $\mathbb{R}^d$ , dann ist

$$\varphi_{\mathbb{P}}(u) = \int_{\mathbb{R}^d} e^{i\langle u, x \rangle} \mathbb{P}(dx) \quad u \in \mathbb{R}^d$$

charakteristische Funktion von  $\mathbb{P}$ .

**► Bemerkung**

- Da  $|e^{i\langle u, X \rangle}| = 1$ , ist die charakteristische Funktion für alle  $u \in \mathbb{R}^d$  definiert.
- Die charakteristische Funktion ist die inverse FOURIERtransformation des Maßes  $\mathbb{P}$  bzw.  $\mathbb{P}_X$ . Die mgf ist hingegen mit der LAPLACetransformation verwandt.
- Existiert die mgf in einer Umgebung der Null, dann ist sie dort holomorph (komplex diffbar) und kann daher in die komplexe Ebene fortgesetzt werden (siehe ↗ Funktionentheorie). Dies

führt auf die charakteristische Funktion.

- Ist  $X$  eine  $\mathbb{N}_0$ -wertige Funktion, so gilt

$$\varphi_X(u) = \psi_X(e^{iu})$$

### ■ Beispiel VIII.9

Sei  $X \sim \text{Gamma}(\lambda, r)$ . Dann folgt mittels Rechnung wie in Beispiel VIII.2 und dem Integralsatz von CAUCHY:

$$\varphi_X(u) = \left( \frac{\lambda}{\lambda - iu} \right)^r \quad u \in \mathbb{R}$$

### Satz VIII.10 (Rechenregeln)

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum,  $X, Y : \Omega \rightarrow \mathbb{R}^d$  mit charakteristischer Funktion  $\varphi_X, \varphi_Y$ . Dann

1.  $\varphi_X(0) = 1$
2. Seien  $A \in \mathbb{R}^{n \times n}, b \in \mathbb{R}^n$ . Dann gilt

$$\varphi_{AX+b}(u) = e^{i\langle u, b \rangle} \varphi_X(A^T u)$$

3. Wenn  $X \perp\!\!\!\perp Y$  dann folgt  $\varphi_{X+Y}(u) = \varphi_X(u) \varphi_Y(u) \quad u \in \mathbb{R}^d$

*Beweis.* Analog zu Satz VIII.4. □

### Satz VIII.11

Sei  $X \sim \mathcal{N}(\mu, \sigma^2)$ , dann

$$\varphi_X(u) = e^{i\mu u - \frac{\sigma^2 u^2}{2}} \quad u \in \mathbb{R}$$

und insbesondere

$$\varphi_{\mathcal{N}(0,1)}(u) = e^{-\frac{u^2}{2}} \quad u \in \mathbb{R}$$

*Beweis.* Betrachte die Standardnormalverteilung:

$$\varphi(u) := \varphi_{\mathcal{N}(0,1)}(u) = \int_{\mathbb{R}} e^{iux} \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx$$



Mit dem Differenzierbarkeitslemma für Parameterintegrale ( $\nearrow$  Schilling MINT, Satz 12.2)

$$\begin{aligned}
 \varphi'(u) &= \int_{\mathbb{R}} \left( \frac{d}{du} e^{iux} \right) \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx \\
 &= \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} ix e^{iux} e^{-\frac{x^2}{2}} dx \\
 &= \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} (-i) e^{iux} \left( \frac{d}{dx} e^{-\frac{x^2}{2}} \right) dx \\
 &\stackrel{\text{P.I.}}{=} \underbrace{\frac{-i}{\sqrt{2\pi}} \left[ e^{iux} e^{-\frac{x^2}{2}} \right]_{x=-\infty}^{\infty}}_{=0} + \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} i \left( \frac{d}{dx} e^{iux} \right) dx \\
 &= \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} i \cdot i u e^{iux} e^{-\frac{x^2}{2}} dx \\
 &= -u \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} e^{iux} e^{-\frac{x^2}{2}} dx \\
 &= -u \varphi(u)
 \end{aligned}$$

Die DGL  $\varphi'(u) = -u\varphi(u)$  besitzt die Lösung

$$\varphi(u) = \varphi(0) e^{-\frac{u^2}{2}}$$

mit  $\varphi(0) = 1$  nach Satz VIII.10, also folgt  $\varphi(u) = e^{-\frac{u^2}{2}}$ . Für  $X \sim \mathcal{N}(\mu, \sigma^2)$  gilt  $Z := \frac{X-\mu}{\sqrt{\sigma^2}} \sim \mathcal{N}(0, 1)$  ( $\nearrow$  HA 9.1) und nach Satz VIII.10 folgt

$$\varphi_X(u) = \varphi_{\sigma Z + \mu}(u) = e^{i\mu u} \varphi_Z(\sigma u) = e^{i\mu u} e^{-\frac{\sigma^2 u^2}{2}}.$$

□

Die Charakteristische Funktion charakterisiert eine Verteilung eindeutig:

#### Satz VIII.12

Seien  $(\Omega, \mathcal{F}, \mathbb{P}), (\Omega', \mathcal{F}', \mathbb{P}')$  Wahrscheinlichkeitsräume und  $X : \Omega \rightarrow \mathbb{R}^d, Y : \Omega' \rightarrow \mathbb{R}^d$  Zufallsvariablen mit charakteristischen Funktionen  $\varphi_X, \varphi_Y$ . Dann:

$$X \stackrel{d}{=} Y \iff \varphi_X(u) = \varphi_Y(u) \quad \forall u \in \mathbb{R}^d$$

Für den Beweis benötigen wir:

#### Lemma VIII.13

Seien  $(\Omega, \mathcal{F}, \mathbb{P}), (\Omega', \mathcal{F}', \mathbb{P}')$  Wahrscheinlichkeitsräume,  $X : \Omega \rightarrow \mathbb{R}^d, Y : \Omega' \rightarrow \mathbb{R}^d$  Zufallsvariablen. Dann gilt  $X \stackrel{d}{=} Y$  genau dann, wenn

$$\mathbb{E}[f(X)] = \mathbb{E}'[f(Y)] \quad \forall f \in C_c(\mathbb{R}^d)$$

(Wobei  $\mathbb{E}'[f(Y)]$  Erwartungswert bzgl  $\mathbb{P}'$  und  $C_c$  die Menge der stetigen Funktionen mit kompakten Träger sind)

*Beweis* (Lemma VIII.13). 1.  $\implies$  : klar.

2.  $\Leftarrow$ : Es genügt zu zeigen

$$\mathbb{E}[\mathbb{1}_K(X)] = \mathbb{P}(X \in K) = \mathbb{P}'(Y \in K) = \mathbb{E}'[\mathbb{1}_K(Y)] \quad (*)$$

für alle  $K \subset \mathbb{R}^d$  kompakt, denn die kompakten Mengen sind ein  $\cap$ -stabiler Erzeuger von  $\mathcal{B}(\mathbb{R}^d)$  und es gibt eine aufsteigende Folge  $K_n \uparrow \mathbb{R}^d$ . Die Indikatoren  $\mathbb{1}_K$  können wir durch  $C_c$ -Funktionen approximieren. Sei

$$\begin{aligned} \text{dist}(x, A) &:= \inf_{y \in A} |x - y| \quad A \subset \mathbb{R}^d \\ f_n(x) &:= \frac{x, U_n^c}{\text{dist}(x, U_n^c) + \text{dist}(x, K)} \quad U_n = \left\{ y \in \mathbb{R}^d : \text{dist}(y, K) < \frac{1}{n} \right\} \end{aligned}$$

Dann ist  $f_n \in C_c$  mit  $f_n \downarrow \mathbb{1}_K$ . Mit monotoner Konvergenz folgt  $(*)$  aus der Voraussetzung.  $\square$

*Beweis* (Satz VIII.12).

$(\Rightarrow)$  klar

$(\Leftarrow)$  Sei  $\varphi_X(u) = \varphi_Y(u)$ ,  $u \in \mathbb{R}^d$ . Wir konstruieren  $d$  unabhängige, identisch verteilte (u.i.v) Zufallsvariablen  $N_1, \dots, N_d \sim \mathcal{N}(0, 1)$  unabhängig von  $X$ . Dann ist auch  $N := (N_1, \dots, N_d)$  unabhängig von  $X$  (Folgerung III.19). Zudem gilt

$$\begin{aligned} \mathbb{P}(\sqrt{\sigma^2}N \in dy) &= \prod_{i=1}^d \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{y_i^2}{2\sigma^2}} dy_i \\ &= (2\pi\sigma^2)^{-\frac{d}{2}} e^{-\frac{|y|^2}{2\sigma^2}} dy \quad \text{mit } |y| = \sqrt{\sum y_i^2}. \end{aligned}$$

Es gilt für alle  $f \in C_c(\mathbb{R}^d)$ :

$$\begin{aligned} \mathbb{E}[f(X + \sqrt{\sigma^2}N)] &\stackrel{X \perp\!\!\!\perp N}{=} \int_{\mathbb{R}^d} \mathbb{E}[f(X + y)] (2\pi\sigma^2)^{-\frac{d}{2}} e^{-\frac{|y|^2}{2\sigma^2}} dy \\ &= (2\pi\sigma^2)^{-\frac{d}{2}} \int_{\mathbb{R}^d} f(z) \mathbb{E}[e^{-\frac{|X-z|^2}{2\sigma^2}}] dz, \end{aligned}$$

wobei für  $X \in \mathbb{R}^d$

$$\begin{aligned} e^{-\frac{|X-z|^2}{2\sigma^2}} &= \prod_{i=1}^d \underbrace{e^{-\frac{|X_i - z_i|^2}{\sigma^2}}}_{\varphi_{\mathcal{N}(0, \sigma^2)}(X_i - z_i)} \\ &= \prod_{i=1}^d \int_{\mathbb{R}} e^{i(X_i - z_i)y_i} \frac{\sigma}{\sqrt{2\pi}} e^{-\frac{\sigma^2 y_i^2}{2}} dy_i \\ &= \frac{\sigma^d}{(2\pi)^{\frac{d}{2}}} \int_{\mathbb{R}^d} e^{i\langle X - z, y \rangle} e^{-\frac{\sigma^2 |y|^2}{2}} dy, \end{aligned}$$

so dass

$$\begin{aligned} \mathbb{E}[f(X + \sqrt{\sigma^2}N)] &= (2\pi)^{-d} \int_{\mathbb{R}^d} f(z) \mathbb{E} \left[ \int_{\mathbb{R}^d} e^{i\langle X - z, y \rangle} e^{-\frac{\sigma^2 |y|^2}{2}} dy \right] dz \\ &= (2\pi)^{-d} \int_{\mathbb{R}^d} f(z) \int_{\mathbb{R}^d} \underbrace{\mathbb{E}[e^{i\langle X, Y \rangle}]}_{\varphi_X(y)} e^{-i\langle z, y \rangle} e^{-\frac{\sigma^2 |y|^2}{2}} dy dz \quad \text{dom. Konv.} \end{aligned}$$

Dieselbe Rechnung auf  $(\Omega', \mathcal{F}', \mathbb{P}')$  mit einem weiteren Vektor  $N'$  u.i.v  $\mathcal{N}(0, 1)$  Zufallsvariablen zeigt dann wegen  $\varphi_X(u) = \varphi_Y(u)$ .

$$\mathbb{E}[f(X + \sqrt{\sigma^2}N)] = \mathbb{E}'[f(Y + \sqrt{\sigma^2}N')]$$

Mit dominierter Konvergenz folgt für  $\sigma^2 \rightarrow 0$

$$\mathbb{E}[f(X)] = \mathbb{E}[f(Y)] \quad \forall f \in C_c(\mathbb{R}^d)$$

Mit Lemma VIII.13 folgt die Behauptung.  $\square$

Folgende Proposition ist analog zu Satz VIII.5.

**Satz VIII.14**

( $\mathcal{F}, \mathbb{P}$ ) Wahrscheinlichkeitsraum,  $X : \Omega \rightarrow \mathbb{R}^d$  Zufallsvariable mit charakteristischer Funktion  $\varphi_X$ .

Wenn  $\mathbb{E}[\|X\|^n] < \infty$  für ein  $n \in \mathbb{N}$ , dann existiert

$$\partial^\alpha = \frac{\partial^{|\alpha|}}{\partial^{\alpha_1} u_1 \dots \partial^{\alpha_d}} \varphi_X(u)$$

$$\forall \alpha \in \mathbb{N}_0^d \text{ mit } |\alpha| = \sum_{i=1}^d \alpha_i \leq n$$

Zudem ist  $\partial_u^\alpha \varphi_X$  stetig und es gilt

$$\mathbb{E}[X^\alpha] = i^{|\alpha|} \partial_u^\alpha \varphi_X(0)$$

*Beweis.* Da  $\|x^\alpha\| \leq \|x\|^{|\alpha|}$  für  $x \in \mathbb{R}^d, \alpha \in \mathbb{N}_0^d$  folgt aus der Annahme  $\mathbb{E}[\|X^\alpha\|] < \infty$ . Damit

$$\begin{aligned} \partial_u^\alpha \varphi_X(u) &= \int_{\mathbb{R}^d} e^{i\langle u, x \rangle} \mathbb{P}(X \in dx) \\ &\stackrel{(\star)}{=} \partial_u^\alpha \int_{\mathbb{R}^d} e^{i\langle u, x \rangle} \mathbb{P}(X \in dx) \\ &= \int_{\mathbb{R}^d} (ix)^\alpha e^{i\langle u, x \rangle} \mathbb{P}(X \in dx) \\ &= i^{|\alpha|} \int_{\mathbb{R}^d} e^{i\langle u, x \rangle} \mathbb{P}(X \in dx) \end{aligned}$$

so dass die Ableitung existiert und für  $u = 0$  die Momentenformel folgt. In  $(\star)$  haben wir  $|\alpha|$ -mal das Differenzierbarkeitslemma ( $\nearrow$  MINT Satz 12.1) verwendet, wobei  $\partial_u^\alpha e^{i\langle u, x \rangle}$  intbar ist, da

$$\left\| \partial_u^\alpha e^{i\langle u, x \rangle} \right\| = \left\| (ix)^\alpha e^{i\langle u, x \rangle} \right\| = \|(ix)^\alpha\| = \|x^\alpha\|.$$

$\square$

## Kapitel IX

# Konvergenzbegriffe und Gesetze der großen Zahlen

Ziel: Für  $X_1, X_2, \dots$  Zufallsvariablen (u.i.v) betrachten das Langzeitmittel  $Y := \frac{1}{n} \sum_{i=1}^n X_i$  für  $n \rightarrow \infty$ .

Wissen bereits: Für  $X_i \sim \text{Bernoulli}(p), p \in (0, 1)$  unabhängig

- Für  $np \rightarrow \lambda, n \rightarrow \infty$ :

$$\mathbb{P}(nY_n = k) \xrightarrow{n \rightarrow \infty} e^{-\lambda} \frac{\lambda^k}{k!} = \text{Poisson}(\{\lambda\})$$

(POISSON-Approx. Satz II.7).

- Für  $c > 0$  gilt mit  $x(k) := \frac{k-np}{\sqrt{np(1-p)}}$

$$\lim_{n \rightarrow \infty} \max_{k: |x_n(k)| \leq c} \left| \frac{\sqrt{np(1-p)} \mathbb{P}(nY_n = k)}{g(x_n(k))} - 1 \right| = 0$$

(DE MOIVRE-LAPLACE Satz VII.2).

## 1. Schwaches Gesetz der großen Zahlen

(WLLN- Weak law of large numbers)

Sei  $X_1, X_2, \dots$  u.i.v. Bernoulli( $\frac{1}{2}$ ) Zufallsvariablen (z.B. Münzwurf). Wir erwarten, etwa bei der Hälfte der Zufallsvariablen eine Null/Eins (Kopf/Zahl) zu sehen, also

$$Y_n = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{n \rightarrow \infty} \frac{1}{2} = \mathbb{E}[X_n] \quad \text{im geeigneten Sinne.}$$

Tatsächlich folgt mit der STIRLING-Formel (Lemma VII.3)

$$\begin{aligned} \mathbb{P}(Y_{2n} = \frac{1}{2}) &= \mathbb{P}(\text{Bin}(2n, p) = \frac{2n}{2}) \\ &= \binom{2n}{n} 2^{-2n} \\ &\underset{n \rightarrow \infty}{\sim} \frac{\sqrt{2\pi 2n} (2n)^{2n} e^{-2n}}{(\sqrt{2\pi n n} e^{-n})^2} 2^{-2n} \\ &= \frac{1}{\sqrt{\pi n}} \\ &\xrightarrow{n \rightarrow \infty} 0 \end{aligned}$$

Wir benötigen also einen geeigneten Grenzwertbegriff!

**Definition IX.1 (stochastische Konvergenz)**

Seien  $Y, Y_1, Y_2, \dots$  reelle Zufallsvariablen auf einem Wahrscheinlichkeitsraum  $(\Omega, \mathcal{F}, \mathbb{P})$ . Falls für alle  $\varepsilon > 0$  gilt

$$\lim_{n \rightarrow \infty} \mathbb{P}(|Y_n - Y| \leq \varepsilon) = 1$$

so konvergiert  $(Y_n)_{n \in \mathbb{N}}$  stochastisch oder in Wahrscheinlichkeit gegen  $Y$ .

Schreibweise:  $Y_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} Y$  oder  $\mathbb{P} - \lim_{n \rightarrow \infty} Y_n = Y$ . (oder auch  $\text{plim}_{n \rightarrow \infty} Y_n = Y$ ).

► **Bemerkung**

Für Zufallsvariablen in  $\mathbb{R}^d$  gilt eine entsprechende Definition mit euklidischer Norm anstelle des Betrags.

**Lemma IX.2**

Seien  $Y, Z, Y_1, Y_2, \dots$  Zufallsvariablen auf einem Wahrscheinlichkeitsraum  $(\Omega, \mathcal{F}, \mathbb{P})$ . Gelten

$$Y_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} Y \text{ und } Y_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} Z$$

so folgt

$$Y = Z \quad \mathbb{P} - \text{f.s.}$$

*Beweis.*  $\Delta$ -Ungleichung:  $|Y - Z| \leq |Y - Y_n| + |Y_n - Z|$ . Damit

$$\{|Y - Z| > 2\varepsilon\} \subseteq \{|Y - Y_n| > \varepsilon\} \cup \{|Y_n - Z| > \varepsilon\}$$

so dass

$$\mathbb{P}(|Y - Z| > 2\varepsilon) \leq \mathbb{P}(|Y - Y_n| > \varepsilon) + \mathbb{P}(|Y_n - Z| > \varepsilon) \xrightarrow{n \rightarrow \infty} 0$$

Also

$$\begin{aligned} \mathbb{P}(Y \neq Z) &= \mathbb{P}(|Y - Z| > 0) = \mathbb{P}\left(\bigcup_{k=1}^{\infty} \{|Y - Z| > k^{-1}\}\right) \\ &= \sum_{k=1}^{\infty} \mathbb{P}(|Y - Z| > k^{-1}) = 0 \implies Y = Z \quad \mathbb{P} - \text{f.s.} \quad \square \end{aligned}$$

**Lemma IX.3**

Seien  $Y_1, Y_2, \dots, Z_1, Z_2, \dots$  reelle Zufallsvariablen auf  $(\Omega, \mathcal{F}, \mathbb{P})$  und  $(a_n)_{n \in \mathbb{N}}$  reellwertige Folge. Es gelten:

1.  $Y_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} 0$  und  $Z_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} 0$ , dann  $Y_n + Z_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} 0$ .
2.  $Y_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} 0$  und  $(a_n)_{n \in \mathbb{N}}$  beschränkt, dann

$$a_n Y_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} 0.$$

*Beweis.* Für  $\varepsilon > 0$  beliebig gilt

$$\mathbb{P}(|Y_n - Z_n| > \varepsilon) \leq \mathbb{P}(|Y_n| > \frac{\varepsilon}{2}) + \mathbb{P}(|Z_n| > \frac{\varepsilon}{2}) \xrightarrow[n \rightarrow \infty]{\mathbb{P}} 0.$$

und andererseits, wenn  $|a_n| \leq A$

$$\mathbb{P}(|a_n Y_n| > \varepsilon) \leq \mathbb{P}(|Y_n| > \frac{\varepsilon}{A}) \xrightarrow[n \rightarrow \infty]{\mathbb{P}} 0. \quad \square$$

**Satz IX.4 (WLLN,  $\mathcal{L}^2$ -Version)**

$(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum,  $X_1, X_2, \dots$  paarweise unkorrelierte, reelle Zufallsvariablen auf  $\Omega$  in  $\mathcal{L}^2(\mathbb{P})$ , so dass

$$v := \sup_{i \in \mathbb{N}} \mathbb{V}\text{ar}(X_i) < \infty$$

Dann gilt für alle  $\varepsilon > 0$ .

$$\mathbb{P}\left(\left|1/n \sum_{i=1}^n (X_i - \mathbb{E}[X_i])\right| \geq \varepsilon\right) \leq \frac{v}{n\varepsilon^2}$$

also insbesondere

$$1/n \sum_{i=1}^n (X_i - \mathbb{E}[X_i]) \xrightarrow[n \rightarrow \infty]{\mathbb{P}} 0$$

Falls  $\mathbb{E}[X_i] = \mathbb{E}[X_1] \quad \forall i$ , so gilt

$$1/n \sum_{i=1}^n X_i \xrightarrow[n \rightarrow \infty]{\mathbb{P}} \mathbb{E}[X_1]$$

*Beweis.* Sei  $Y_n := 1/n \sum_{i=1}^n (X_i - \mathbb{E}[X_i])$ , dann ist  $Y_n \in \mathcal{L}^2(\mathbb{P})$  mit  $\mathbb{E}[Y_n] = 0$  und

$$\mathbb{V}\text{ar}(Y_n) = \frac{1}{n} \sum_{i=1}^n \mathbb{V}\text{ar}(X_i) \leq \frac{v}{n} \quad \text{BIENAMÉ}$$

und die Aussage folgt aus der Ungleichung von TSCHEBYSCHOFF (Satz V.13). □

**Satz IX.5 (WLLN,  $\mathcal{L}^1$ -Version)**

$(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum,  $X_1, X_2, \dots$  paarweise unabhängige, identisch verteilte reelle Zufallsvariablen auf  $\Omega$  in  $\mathcal{L}^1(\mathbb{P})$ . Dann gilt

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow[n \rightarrow \infty]{\mathbb{P}} \mathbb{E}[X_1].$$

*Beweis.* Wir verwenden ein Abschneideargument:

Definiere

$$X_i^b := X_i \mathbb{1}_{\{|X_i| \leq i^{1/4}\}} \text{ und } X_i^\sharp := X_i \mathbb{1}_{\{|X_i| > i^{1/4}\}}$$

sowie

$$Y_n^b := \frac{1}{n} \sum_{i=1}^n (X_i^b - \mathbb{E}[X_i^b]) \text{ und } Y_n^\sharp := \frac{1}{n} \sum_{i=1}^n (X_i^\sharp - \mathbb{E}[X_i^\sharp])$$

Wir zeigen  $Y_n^b \xrightarrow[n \rightarrow \infty]{\mathbb{P}} 0$  und  $Y_n^\sharp \xrightarrow[n \rightarrow \infty]{\mathbb{P}} 0$ . Mit Lemma IX.3 folgt dann die Behauptung.

Zu  $Y_n^b$ : Nach Folgerung III.19 sind auch  $X_i^b$  paarweise unabhängig. Es folgt

$$\begin{aligned} \mathbb{V}\text{ar}(Y_n^b) &= \frac{1}{n^2} \sum_{i=1}^n \mathbb{V}\text{ar}(X_i^b) \quad (\text{BIENAYÉ}) \\ &\leq \frac{1}{n^2} \sum_{i=1}^n \mathbb{E}[\underbrace{(X_i^b)^2}_{\leq i^{1/2}}] \\ &\leq \frac{1}{n^2} n n^{1/2} = n^{-1/2} \end{aligned}$$

Mit TSCHEBYSCHOFF (Lemma V.6) folgt  $Y_n^b \xrightarrow[n \rightarrow \infty]{\mathbb{P}} 0$ .

Zu  $Y_n^\sharp$ : Es gilt

$$\begin{aligned} \mathbb{E}[X_i^\sharp] &= \mathbb{E}[X_i \mathbb{1}_{\{|X_i| \leq i^{1/4}\}}] \stackrel{\text{i.v.}}{=} \mathbb{E}[X_i \mathbb{1}_{\{|X_i| \leq i^{1/4}\}}] \\ &= \mathbb{E}[X_1] - \mathbb{E}[X_1 \mathbb{1}_{\{|X_1| \leq i^{1/4}\}}] \xrightarrow[n \rightarrow \infty]{} 0. \end{aligned}$$

wegen monotoner Konvergenz. Also

$$\mathbb{E}[|Y_n^\sharp|] \leq \frac{2}{n} \sum_{i=1}^n \mathbb{E}[X_i^\sharp] \xrightarrow[n \rightarrow \infty]{} 0.$$

Mit MARKOV-Ungleichung (Lemma V.6) folgt für alle  $\varepsilon > 0$

$$\mathbb{P}(|Y_n^\sharp| \geq \varepsilon) \leq \frac{\mathbb{E}[|Y_n^\sharp|]}{\varepsilon} \xrightarrow[n \rightarrow \infty]{} 0$$

also  $Y_n^\sharp \xrightarrow[n \rightarrow \infty]{\mathbb{P}} 0$ . □

## 2. Das starke Gesetz der großen Zahlen

(SLLN - Strong law of large numbers)

### Definition IX.6 ( $\mathbb{P}$ f.s. Konvergenz)

Seien  $Y, Y_1, Y_2, \dots$  reellen Zufallsvariablen auf Wahrscheinlichkeitsraum  $(\Omega, \mathcal{F}, \mathbb{P})$ . Falls

$$\mathbb{P}(\{\omega: \lim_{n \rightarrow \infty} Y_n(\omega) = Y(\omega)\}) = 1$$

so konvergiert  $(Y_n)_{n \in \mathbb{N}}$   $\mathbb{P}$ -fast sicher gegen  $Y$ .

Schreibweise:  $Y_n \xrightarrow[n \rightarrow \infty]{\text{f.s.}} Y$  oder  $\lim_{n \rightarrow \infty} Y_n = Y$  f.s.

### ► Bemerkung

- Diese Konvergenzart wurde bereits verwendet, z.B. in MINT, Konvergenzsatz von LEBESGUE.
- Auch bei der f.s. Konvergenz ist der Grenzwert f.s. eindeutig bestimmt:  
 $Y_n \xrightarrow[n \rightarrow \infty]{\text{f.s.}} Y$  und  $Y_n \xrightarrow[n \rightarrow \infty]{\text{f.s.}} Z \implies \mathbb{P}(Y = Z) = \mathbb{P}(\{\lim Y_n = Y\} \cap \{\lim Y_n = Z\}) = 1$
- Erweiterung auf Zufallsvariablen in  $\mathbb{R}^d$  ist offensichtlich.

### Lemma IX.7

$Y, Y_1, Y_2, \dots$  reelle Zufallsvariablen auf  $(\Omega, \mathcal{F}, \mathbb{P})$ . Dann

$$Y_n \xrightarrow[n \rightarrow \infty]{\text{f.s.}} Y \implies Y_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} Y$$

*Beweis.* Für  $\varepsilon > 0$  gilt

$$\mathbb{P}(|Y_n - Y| > \varepsilon) = \mathbb{E}[\underbrace{\mathbb{1}_{\{|Y_n - Y| > \varepsilon\}}}_{=: Z_n}]$$

Die Zufallsvariablen  $Z_n$  sind gleichmäßig durch  $Z \equiv 1 \in \mathcal{L}^1(\mathbb{P})$  beschränkt und  $Z_n \xrightarrow[n \rightarrow \infty]{\text{f.s.}} 0$ . Nach dem Konvergenzsatz von LEBESGUE folgt

$$\lim_{n \rightarrow \infty} \mathbb{P}(|Y_n - Y| > \varepsilon) = \mathbb{E}[\lim Z_n] = 0. \quad \square$$

### ► Bemerkung

Die Umkehrung gilt i. A. nicht: Definiere eine Folge von Zufallsvariablen auf  $([0, 1], \mathcal{B}([0, 1]), \mathbb{U}([0, 1]))$  durch

$$Y_k := \mathbb{1}_{[m2^{-n}, (m+1)2^{-n})} \quad \text{falls } k = 2^n + m \text{ mit } 0 \leq m < 2^n$$

Dann gilt für alle  $0 < \varepsilon < 1$

$$\mathbb{P}(|Y_k| > \varepsilon) = 2^{-n} \xrightarrow[n \rightarrow \infty]{} 0$$



Also

$$Y_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} 0.$$

Allerdings  $\mathbb{P}(\{\omega : \lim Y_n(\omega) = 0\}) = 0$ , also  $Y_n \not\xrightarrow[n \rightarrow \infty]{\text{f.s.}} 0$

► **Erinnerung**

$$\omega \in \limsup_{n \rightarrow \infty} A_n = \bigcap_{k \in \mathbb{N}} \bigcup_{n \geq k} A_n$$

$\iff \omega$  ist in  $\infty$  vielen der  $A_n$  enthalten.

**Satz IX.8 (Borel-Cantelli-Lemma)**

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum und  $(A_n)_{n \in \mathbb{N}}$  Folge in  $\mathcal{F}$ .

1. Falls  $\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty$ , so folgt  $\mathbb{P}(\limsup_{n \rightarrow \infty} A_n) = 0$ .
2. Falls  $\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \infty$  und die  $A_n$  paarweise unabhängig sind, so folgt  $\mathbb{P}(\limsup_{n \rightarrow \infty} A_n) = 1$

► **Bemerkung**

Das BC-Lemma ist ein Null-Eins-Gesetz. (Gibt noch viel mehr davon! z.B. in Random Graphs, siehe Talk Logic and Random Graphs.)

*Beweis.* Es gilt

$$\begin{aligned} \omega \limsup_{n \rightarrow \infty} A_n &\iff \omega \text{ ist in } \infty \text{ vielen } A_n \text{ enthalten} \\ &\iff \sum_{n=1}^{\infty} \mathbb{1}_{A_n}(\omega) = \infty \end{aligned} \quad (\star)$$

1.

$$\mathbb{E}\left[\sum_{n=1}^{\infty} \mathbb{1}_{A_n}\right] \stackrel{\text{BL}}{=} \sum_{n=1}^{\infty} \mathbb{E}[\mathbb{1}_{A_n}] = \sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty$$

Die zeigt  $\sum_{n=1}^{\infty} \mathbb{1}_{A_n} < \infty$   $\mathbb{P}$ -f.s. und mit  $(\star)$   $\mathbb{P}(\limsup A_n) = 0$

2. Setze  $S_n = \sum_{i=1}^n \mathbb{1}_{A_i}$  und  $S = \lim_{n \rightarrow \infty} S_n = \sum_{i=1}^{\infty} \mathbb{1}_{A_i}$ . Wegen paarweiser Unabhängigkeit gilt über BIENNAYMÉ

$$\begin{aligned} \text{Var}(S_n) &= \text{Var}\left(\sum_{i=1}^n \mathbb{1}_{A_i}\right) = \sum_{i=1}^n \text{Var}(\mathbb{1}_{A_i}) \\ &\leq \sum_{i=1}^n \mathbb{E}[\mathbb{1}_{A_i}^2] = \sum_{i=1}^n \mathbb{E}[\mathbb{1}_{A_i}] = \sum_{i=1}^n \mathbb{P}(A_i) \\ &=: m_n \xrightarrow[n \rightarrow \infty]{} \infty \end{aligned}$$

Da  $S_n \leq S$  folgt  $\{S \leq 1/2m_n\} \subseteq \{S_n \leq 1/2m_n\}$  so dass

$$\begin{aligned}\mathbb{P}(S \leq 1/2m_n) &\leq \mathbb{P}(S_n \leq 1/2m_n) = \mathbb{P}(S_n - m_n \leq -1/2m_n) \quad m_n = \mathbb{E}[S_n] \\ &\leq \mathbb{P}(|S_n - m_n| \geq 1/2m_n)\end{aligned}$$

und mit TSCHEBYSCHEFF:

$$\begin{aligned}\mathbb{P}(S \leq 1/2m_n) &\leq \mathbb{P}(|S_n - m_n| \geq 1/2m_n) \\ &\leq \frac{\text{Var}(S_n)}{m_n^2/4} \\ &\leq \frac{4}{m_n} \xrightarrow{n \rightarrow \infty} 0\end{aligned}$$

Damit folgt mit monotoner Konvergenz

$$\mathbb{P}(S < \infty) = \mathbb{P}\left(\bigcup_{n=1}^{\infty} \{S \leq 1/2m_n\}\right) = \lim_{n \rightarrow \infty} \mathbb{P}(S \leq 1/2m_n) = 0$$

und daraus folgt dann  $\mathbb{P}(\limsup A_n) = 1$  mit  $(\star)$ . □

### Satz IX.9 (SLLN, $\mathcal{L}^2$ -Version)

$(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum und  $X_1, X_2, \dots$  paarweise unkorrelierte (reelle) Zufallsvariablen auf  $\Omega$  in  $\mathcal{L}^2(\mathbb{P})$ , so dass  $v := \sup_{i \in \mathbb{N}} \text{Var}(X_i) < \infty$ . Dann gilt

$$\frac{1}{n} \sum_{i=1}^n (X_i - \mathbb{E}[X_i]) \xrightarrow[n \rightarrow \infty]{\text{f.s.}} 0.$$

*Beweis.* Nehme oBdA an, dass  $\mathbb{E}[X_i] = 0 \quad \forall i$ , sonst betrachte

$$X'_i = X_i - \mathbb{E}[X_i]$$

Setze  $Y_n = 1/n \sum_{i=1}^n X_i$ .

Wir zeigen zunächst  $Y_n \xrightarrow[n \rightarrow \infty]{\text{f.s.}} 0$ , bevor wir zu  $Y_n$  übergehen. Aus Satz IX.4 (WLLN,  $\mathcal{L}^2$ ) ist bekannt:

$$\forall \varepsilon > 0 \quad \mathbb{P}(|Y_{n^2}| \geq \varepsilon) < \infty.$$

Insbesondere folgt

$$\sum_{n=1}^{\infty} \mathbb{P}(|Y_{n^2}| \geq \varepsilon) < \infty.$$

Aus BOREL-CANTELLI folgt

$$\mathbb{P}(\limsup_{n \rightarrow \infty} |Y_{n^2}| > \varepsilon) \leq \mathbb{P}(\limsup_{n \rightarrow \infty} \{|Y_{n^2}| \geq \varepsilon\}) = 0$$

und für  $\varepsilon \rightarrow 0$  folgt

$$\begin{aligned}\mathbb{P}(\lim_{n \rightarrow \infty} Y_{n^2} \neq 0) &= \mathbb{P}(\limsup_{n \rightarrow \infty} |Y_{n^2}| > 0) \\ &= \lim_{n \rightarrow \infty} \mathbb{P}(\limsup_{n \rightarrow \infty} |Y_{n^2}| > \varepsilon) = 0\end{aligned}$$

## 2. Das starke Gesetz der großen Zahlen Kapitel IX: Konvergenzbegriffe und Gesetze der großen Zahlen

also gilt  $Y_{n^2} \xrightarrow{\text{f.s.}} 0$ . Wähle nun für jedes  $m \in \mathbb{N}$  ein  $n = n(m)$  so dass

$$n^2 \leq m < (n+1)^2$$

Wir “vergleichen”  $Y_m$  mit  $Y_{n^2}$ :

$$\begin{aligned} \mathbb{P}(|mY_m - n^2Y_{n^2}| > \varepsilon n^2) &= \mathbb{P}\left(\left|\sum_{i=n^2+1}^m X_i\right| > \varepsilon n^2\right) \\ &\leq \frac{1}{\varepsilon^2 n^2} \text{Var}\left(\sum_{i=n^2+1}^m X_i\right) \quad \text{TSCHEBYSCHEFF} \\ &\leq \frac{v(m - n^2)}{\varepsilon^2 n^4} \quad \text{BIENAYMÉ} \end{aligned}$$

Es folgt

$$\begin{aligned} \sum_{m=1}^{\infty} \mathbb{P}(|mY_m - n^2Y_{n^2}| > \varepsilon n^2) &\leq \frac{v}{\varepsilon} \sum_m \frac{(m - n^2)}{n^4} \\ &= \frac{v}{\varepsilon} \sum_m \frac{(m - n(m))}{n(m)^4} \\ &= \frac{v}{\varepsilon^2} \sum_{n=1}^{\infty} \sum_{m=n^2}^{(n+1)^2-1} \frac{(m - n^2)}{n^4} \\ &= \frac{v}{\varepsilon^2} \sum_{n=1}^{\infty} \sum_{k=0}^{2n} \frac{k}{n^4} \\ &= \frac{v}{\varepsilon^2} \sum_{n=1}^{\infty} \frac{(2n)(2n+1)}{2n^4} < \infty \end{aligned}$$

und mit BOREL-CANTELLI:

$$\mathbb{P}\left(\lim_{m \rightarrow \infty} \left|\frac{mY_m}{n^2} - Y_{n^2}\right| = 0\right) = 1$$

Zusammen mit  $Y_{n^2} \xrightarrow{\text{f.s.}} 0$  folgt

$$\mathbb{P}\left(\lim_{m \rightarrow \infty} \left|\frac{mY_m}{n^2}\right| = 0\right) = 1$$

und da

$$|Y_m| \leq \frac{m}{n^2} |Y_m|$$

impliziert das

$$\mathbb{P}\left(\lim_{m \rightarrow \infty} |Y_m| = 0\right) = 1. \quad \square$$

### ► Bemerkung

Das SLLN gilt auch unter den Bedingungen von Satz IX.5 (WLLN,  $\mathcal{L}^1$ ). Der Beweis basiert auf einem Teilfolgen- sowie Abschneideargument. ( $\nearrow$  z.B. Klenke, Schilling WT, ...)

“Schnelle” stochastische Konvergenz impliziert f.s. Konvergenz.

**Lemma IX.10**

$Y, Y_1, Y_2, \dots$  reelle Zufallsvariablen auf  $(\Omega, \mathcal{F}, \mathbb{P})$  so dass  $Y_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} Y$  und so dass für eine Nullfolge von  $\varepsilon_n \downarrow 0$  gilt

$$\sum_{n=1}^{\infty} \mathbb{P}(|Y_n - Y| > \varepsilon_n) < \infty$$

Dann folgt

$$Y_n \xrightarrow[n \rightarrow \infty]{\text{f.s.}} Y$$

*Beweis.* Nach BOREL-CANTELLI folgt

$$\mathbb{P}(|Y_n - Y| > \varepsilon_n \text{ für unendliche viele } n) = 0$$

Dies ist äquivalent zu:  $\mathbb{P}(|Y_n - Y| > \varepsilon_n \text{ für höchstens endliche viele } n) = 1 \iff \exists \Omega' : \mathbb{P}(\Omega') = 1$ , so dass

$$\forall \omega \in \Omega' \exists N(\omega') \quad \forall n \geq N(\omega') : |Y_n(\omega') - Y(\omega')| \leq \varepsilon_n$$

impliziert das

$$\exists \Omega' \subseteq \Omega, \mathbb{P}(\Omega') = 1, \text{ so dass } |Y_n(\omega') - Y(\omega')| \xrightarrow[n \rightarrow \infty]{} 0 \implies Y_n \xrightarrow[n \rightarrow \infty]{\text{f.s.}} Y. \quad \square$$

**Folgerung IX.11**

$Y, Y_1, Y_2, \dots$  reelle Zufallsvariablen auf  $(\Omega, \mathcal{F}, \mathbb{P})$ , so dass  $Y_n \xrightarrow[n \rightarrow \infty]{\text{f.s.}} Y$ . Dann existiert eine Teilfolge  $(Y_{n_k})_{k \in \mathbb{N}} \subseteq (Y_n)_{n \in \mathbb{N}}$ , so dass  $Y_{n_k} \xrightarrow[k \rightarrow \infty]{\text{f.s.}} Y$ .

*Beweis.* Nach Voraussetzung gilt

$$\forall k \in \mathbb{N} \quad \forall \varepsilon > 0 \exists N(k, \varepsilon) : \forall n \geq N(k, \varepsilon) : \mathbb{P}(|Y_n - Y| > \varepsilon) \leq 2^{-k}$$

Wähle  $\varepsilon_k = 2^{-k}$  und  $n_k = N(k, 2^{-k})$ , dann ist

$$\sum_{k=1}^{\infty} \mathbb{P}(|Y_{n_k} - Y| > \varepsilon_k) \leq \sum_{k=1}^{\infty} 2^{-k} < \infty$$

und die Behauptung folgt aus Lemma IX.10.  $\square$

### 3. Der Satz von Glivenko-Cantelli

Gegeben seien  $n$  Realisierungen  $x_1 = X_1(\omega), x_2 = X_2(\omega), \dots, x_n = X_n(\omega)$  von u.i.v. Zufallsvariablen  $X_1, \dots, X_n$  in  $\mathbb{R}$  auf einem Wahrscheinlichkeitsraum  $(\Omega, \mathcal{F}, \mathbb{P})$ . Die Verteilung  $F$  von  $X_i$  ist unbekannt.

Frage: Wie können wir  $\mathbb{P}_{x_i}$  bzw. die zugehörige Verteilungsfunktion  $F$  bestimmen/ approximieren?

**Definition IX.12 (empirische Verteilungsfunktion, Zufallsproben)**

Seien  $X_1, X_2, \dots$  u.i.v. Zufallsvariablen auf  $(\Omega, \mathcal{F}, \mathbb{P})$  in  $\mathbb{R}$ , dann definiert

$$\hat{F}_n(x, \omega) := \frac{\#\{i: 1 \leq i \leq n \mid X_i(\omega) \leq x\}}{n}$$

die empirische Verteilungsfunktion der Zufallsproben  $(X_1, \dots, X_n)$ .

**► Bemerkung**

- Für alle  $\omega \in \Omega$  ist  $\hat{F}_n(x) : \mathbb{R} \rightarrow [0, 1]$  eine Verteilungsfunktion ( $\nearrow$  Übung)
- $\{\hat{F}_n, x \in \mathbb{R}\}$  ist eine Familie von Zufallsvariablen und damit ein stochastischer Prozess.

**Satz IX.13 (Eigenschaften der empirischen Verteilungsfunktion)**

Seien  $X_1, X_2, \dots$  u.i.v. Zufallsvariablen auf  $(\Omega, \mathcal{F}, \mathbb{P})$  in  $\mathbb{R}$  mit Verteilungsfunktion  $F$ . Dann gelten:

1.  $n\hat{F}_n(x) \sim \text{Bin}(n, F(x)) \quad \forall x \in \mathbb{R}$
2.  $\mathbb{E}[\hat{F}_n(x)] = F(x) \quad \forall x \in \mathbb{R}$
3.  $\text{Var}(\hat{F}_n(x)) = \frac{F(x)(1-F(x))}{n} \quad \forall x \in \mathbb{R}$
4.  $\hat{F}_n(x) \xrightarrow[n \rightarrow \infty]{\text{f.s.}} F(x) \quad x \in \mathbb{R}$

*Beweis.* 1. Es gilt

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{\{X_i \leq x\}}$$

mit

$$\mathbb{1}_{\{X_i \leq x\}} \sim \text{Bernoulli}(F(x))$$

Mit Unabhängigkeit der  $X_i$  folgt die Behauptung.

2. (2&3) folgt aus 1)  $\forall x$

$$\begin{aligned} \mathbb{E}[n\hat{F}_n(x)] &= nF(x) \\ \text{Var}(n\hat{F}_n(x)) &= n(1-F(x))F(x) \end{aligned}$$

3. Da die Zufallsvariablen  $Y_i = \mathbb{1}_{\{X_i \leq x\}}$  für jedes  $x$  u.i.v. und in  $\mathcal{L}^2$  sind, gilt nach dem SLLN

$$\begin{aligned} \hat{F}_n(x) &= \frac{1}{n} \sum_{i=1}^n Y_i \xrightarrow[n \rightarrow \infty]{\text{f.s.}} \mathbb{E}[Y_i] \\ &= \mathbb{E}[\mathbb{1}_{\{X_i \leq x\}}] = \mathbb{P}(X_i \leq x) = F(x). \end{aligned}$$

□

**Satz IX.14 (Gilvenko-Cantelli)**

$X_1, X_2, \dots$  u.i.v. Zufallsvariablen auf  $(\Omega, \mathcal{F}, \mathbb{P})$  in  $\mathbb{R}$  mit Verteilungsfunktion  $F$ . Dann gilt

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} \sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F(x)| = 0\right) = 1$$

$$\sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F(x)| \xrightarrow[n \rightarrow \infty]{\text{f.s.}} 0.$$

*Beweis.* Nehme zunächst an, dass  $F$  stetig ist. Für jedes  $m \in \mathbb{N}$  existieren dann

$$-\infty = z_0 < z_1 < \dots < z_{m-1} < z_m = \infty$$

so dass

$$F(z_0) = 0 \quad F(z_1) = \frac{1}{m} \quad \dots \quad F(z_k) = \frac{k}{m} \quad \dots \quad F(z_m) = 1$$

Es folgt für jedes  $z \in [z_n, z_{k+1})$

$$\begin{aligned} \hat{F}_n(z) - F(z) &\leq \hat{F}_n(z_{k+1}) - F(z_k) = \hat{F}_n(z_{k+1}) - F(z_{k+1}) + \frac{1}{m} \\ \hat{F}_n(z) - F(z) &\geq \hat{F}_n(z_n) - F(z_{k+1}) = \hat{F}_n(z_k) - F(z_k) - \frac{1}{m} \end{aligned} \quad (\star)$$

Setze für  $k \in \{0, 1, \dots, m\}$ ,  $m \in \mathbb{N}$ . Dann

$$A_{m,k} := \left\{ \omega \in \Omega : \lim_{n \rightarrow \infty} \hat{F}_n(z_k, \omega) = F(z_n) \right\}$$

dann gilt nach Satz IX.13  $\mathbb{P}(A_{m,k}) = 1 \quad \forall m, k$ . Für  $A_m := \bigcup_{k=0}^m A_{m,k}$  folgt

$$\mathbb{P}(A_m) = 1 - \mathbb{P}(A_m^C) = 1 - \mathbb{P}\left(\bigcup_{k=0}^m A_{m,k}^C\right) \geq 1 - \sum_{k=0}^m \mathbb{P}(A_{m,k}^C) = 1$$

Für jedes  $\omega \in A_m$  gibt es  $N(\omega) \in \mathbb{N}$ , so dass  $\forall n \geq N(\omega)$  und  $\forall k \in \{0, \dots, m\}$

$$|\hat{F}_n(z_k, \omega) - F(z_k)| < \frac{1}{m}$$

Zusammen mit  $(\star)$  folgt  $\forall n \geq N(\omega)$  und alle  $\omega \in A_m$

$$\sup_{x \in \mathbb{R}} |\hat{F}_n(z) - F(z)| < \frac{2}{m} \quad (\star\star)$$

Für  $A = \bigcap_{m \in \mathbb{N}} A_m$  folgt (wie bei  $A_m$ ) auch  $\mathbb{P}(A) = 1$  und aus  $(\star\star)$ , dass für jedes  $\omega \in A$  und jedes  $\varepsilon > 0$  ein  $N(\omega, \varepsilon) \in \mathbb{N}$  existiert, so dass  $\forall n > N(\omega, \varepsilon)$  gilt

$$\sup_{z \in \mathbb{R}} |\hat{F}_n(z, \omega) - F(z)| < \varepsilon$$

Für  $\varepsilon \rightarrow 0$  folgt die Behauptung.

Ist  $F$  nicht notwendigerweise stetig, so wähle für  $m \in \mathbb{N}$

$$-\infty = z_0 < z_1 < \dots < z_{m-1} < z_m = \infty$$

so dass

$$F(z_{k+1}^-) - F(z_k) = \lim_{y \uparrow \infty} F(y) - F(z_k) \leq \frac{1}{m}$$

Dann folgt analog zu  $(\star)$  für  $z \in [z_n, z_{k+1})$

$$\begin{aligned}\hat{F}_n(z) - F(z) &\leq \hat{F}_n(z_{k+1}^-) - F(z_{k+1}^-) + \frac{1}{m} \\ \hat{F}_n(z) - F(z) &\geq \hat{F}_n(z_n) - F(z_k) - \frac{1}{m}\end{aligned}$$

und damit

$$A'_{m,k} = \left\{ \omega \in \Omega : \lim_{n \rightarrow \infty} \hat{F}_n(z_k^-, \omega) = F(z_k^-) \right\}$$

folgt der verbleibende Beweis analog zum stetigen Fall.  $\square$

## 4. $\mathcal{L}^p$ -Konvergenz

### Definition IX.15 ( $\mathcal{L}^p$ -Konvergenz)

Seien  $Y, Y_1, Y_2, \dots$  reelle Zufallsvariablen auf  $(\Omega, \mathcal{F}, \mathbb{P})$ . Falls  $(Y, Y_n \in \mathcal{L}^p(\mathbb{P})), n \in \mathbb{N}$  für ein  $p \in [1, \infty]$  und

$$\lim_{n \rightarrow \infty} \|Y - Y_n\|_p := \lim_{n \rightarrow \infty} (\mathbb{E}[Y_n - Y]^p)^{1/p} = 0$$

so konvergiert  $(Y_n)_{n \in \mathbb{N}}$  in  $\mathcal{L}^p$  / im  $p$ -ten Mittel gegen  $Y$ . Wir schreiben:

$$Y_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}^p} Y \text{ oder } \mathcal{L}^p - \lim_{n \rightarrow \infty} Y_n = Y$$

### ► Bemerkung

- Der Grenzwert einer  $\mathcal{L}^p$ -konvergenten Folge ist f.s. eindeutig: MINKOWSKI-Ungleichung ( $\nearrow$  Schilling MINT, Korollar 14.5) liefert für  $1 \leq p \leq \infty$

$$\begin{aligned}\|Y - Z\|_p &= \|Y - Y_n + Y_n - Z\|_p \leq \underbrace{\|Y - Y_n\|_p}_{\rightarrow 0} + \underbrace{\|Y_n - Z\|_p}_{\rightarrow 0} \\ \implies \|Y - Z\|_p &\implies Y = Z \quad \mathbb{P}\text{-f.s.}\end{aligned}$$

- $\mathcal{L}^p$ -Konvergenz in  $\mathbb{R}^d$  lässt sich analog definieren.

### Lemma IX.16

$Y, Y_1, Y_2, \dots$  reelle Zufallsvariablen auf  $(\Omega, \mathcal{F}, \mathbb{P})$ . Es gelten für  $1 \leq p \leq \infty$

1.  $Y_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}^p} Y \implies Y_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}^1} Y$
2.  $Y_n \xrightarrow[n \rightarrow \infty]{\mathcal{L}^1} Y \implies Y_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} Y$

*Beweis.* 1. Für  $1 \leq p \leq \infty$  setze  $q = (1 - 1/p)^{-1}$  mit  $q = 1$  für  $p = \infty$  so dass  $1/p + 1/q = 1$  und mit


HÖLDER

$$\begin{aligned}
\|Y_n - Y\|_1 &= \mathbb{E}[Y_n - Y] = \int |Y_n - Y| \cdot 1 \, d\mathbb{P} \\
&= \left( \int |Y_n - Y|^p \right)^{1/p} \cdot \underbrace{\left( \int 1^q \, d\mathbb{P} \right)^{1/q}}_{=1} \\
&= (\mathbb{E}[|Y_n - Y|^p])^{1/p} \\
&= \|Y_n - Y\|_p \xrightarrow[n \rightarrow \infty]{0} 0
\end{aligned}$$

2. Mit der MARKOV-Ungleichung folgt  $\forall \varepsilon > 0$ 

$$\mathbb{P}(|Y_n - Y| > \varepsilon) \leq \frac{\mathbb{E}[|Y_n - Y|]}{\varepsilon} \xrightarrow[n \rightarrow \infty]{} 0.$$

□





## Kapitel X

# Verteilungskonvergenz und der zentrale Grenzwertsatz

## 1. Die Verteilungskonvergenz

### Definition X.1 (schwache Konvergenz)

$Y, Y_1, Y_2, \dots$  reelle Zufallsvariablen (“jede ZV darf ihren eigenen WR mitbringen”). Falls für alle  $f \in C_b(\mathbb{R})$  (stetig und beschränkt) gilt, dass

$$\lim_{n \rightarrow \infty} \mathbb{E}[f(Y_n)] = \mathbb{E}[f(Y)]$$

so konvergiert  $(Y_n)_{n \in \mathbb{N}}$  schwach / in Verteilung gegen  $Y$ .

Schreibe:  $Y_n \xrightarrow[n \rightarrow \infty]{d} Y$  oder  $Y_n \Rightarrow Y, n \rightarrow \infty$  oder  $\mathbb{P}_{Y_n} \Rightarrow \mathbb{P}_Y$ .

### ► Bemerkung

- Formal sollten wir eigentlich schreiben

$$\lim \mathbb{E}_n[f(Y_n)] = \mathbb{E}[f(Y)]$$

wobei  $\mathbb{E}_n[f(Y_n)]$  bzgl.  $\mathbb{P}_n, Y_n$  auf  $(\Omega_n, \mathcal{F}_n, \mathbb{P}_n)$ . Dies wird aber in der Regeln vernachlässigt.

- Für Zufallsvariablen in  $\mathbb{R}^d$  lässt sich schwache Konvergenz mittels  $f \in C_b(\mathbb{R}^d)$  (d.h.  $f: \mathbb{R}^d \rightarrow \mathbb{R}$ ) definieren.

Der Grenzwert einer schwach konvergenten Folge ist eindeutig in Verteilung.

### Lemma X.2

$Y, Z, Y_1, Y_2, \dots$  reelle Zufallsvariablen, so dass

$$Y_n \xrightarrow[n \rightarrow \infty]{d} Y \text{ und } Y_n \xrightarrow[n \rightarrow \infty]{d} Z$$

Dann gilt:  $Y \stackrel{d}{=} Z$  bzw.  $\mathbb{P}_Y = \mathbb{P}_Z$ .

*Beweis.* Betrachte ein fixes kompaktes Intervall  $[a, b] \subset \mathbb{R}$ . Da die kompakten Intervalle ein  $\cap$ -stabiler Erzeuger von  $\mathcal{B}(\mathbb{R})$  sind, genügt es zu zeigen

$$\int \mathbb{1}_{[a,b]} d\mathbb{P}_Y = \mathbb{P}_Y([a,b]) = \mathbb{P}_Z([a,b]) = \int \mathbb{1}_{[a,b]} d\mathbb{P}_Z.$$

Dazu konstruiere eine Folge  $(f_k)_{k \in \mathbb{N}}$  in  $C_b(\mathbb{R})$ , so dass  $f_k \downarrow f = \mathbb{1}_{[a,b]}$  ( $\nearrow$  Beweis zu Lemma VIII.13). Dann folgt

mit monotoner Konvergenz

$$\int \mathbb{1}_{[a,b]} d\mathbb{P}_Y = \lim_{k \rightarrow \infty} \int f_k d\mathbb{P}_Y = \lim_{k \rightarrow \infty} \lim_{n \rightarrow \infty} \int f_k d\mathbb{P}_{Y_n}$$

und analog

$$\int \mathbb{1}_{[a,b]} d\mathbb{P}_Z = \lim_{k \rightarrow \infty} \lim_{n \rightarrow \infty} \int f_k d\mathbb{P}_{Y_n}$$

Das liefert die Behauptung.  $\square$

### Satz X.3 (Portmanteau)

$Y, Y_1, Y_2, \dots$  reelle Zufallsvariablen. Die folgenden Aussagen sind äquivalent:

1.  $Y_n \xrightarrow[n \rightarrow \infty]{d} Y$
2.  $\lim_{n \rightarrow \infty} \mathbb{E}[f(Y_n)] = \mathbb{E}[f(Y)] \quad \forall f \in C_b^g(\mathbb{R})$  (glm stetig und beschränkt)
3.  $\limsup_{n \rightarrow \infty} \mathbb{P}(Y_n \in F) \leq \mathbb{P}(Y \in F) \quad \forall F \subset \mathbb{R}$  abgeschlossen
4.  $\liminf_{n \rightarrow \infty} \mathbb{P}(Y_n \in O) \geq \mathbb{P}(Y \in O) \quad \forall O \subset \mathbb{R}$  offen
5.  $\lim_{n \rightarrow \infty} \mathbb{P}(Y_n \in C) = \mathbb{P}(Y \in C) \quad C \in \mathcal{B}(\mathbb{R})$  mit  $\mathbb{P}_Y(\partial C) = 0$  (Rand von  $C$ )

*Beweis.* 1.  $\implies$  2.: ist klar

2.  $\implies$  3.: Sei  $F$  abgeschlossen und definiere für  $k \in \mathbb{N}$

$$f_k(x) = (1 - k \operatorname{dist}(x, F))^+ \text{ mit } \operatorname{dist}(x, F) = \inf_{y \in F} |x - y|$$

Dann ist  $f_k$  beschränkt und glm. stetig, denn

$$\begin{aligned} |f_k(y) - f_k(x)| &\leq k |\operatorname{dist}(y, F) - \operatorname{dist}(x, F)| \\ &\leq k |y - x| \quad \forall x, y \in \mathbb{R} \end{aligned}$$

da

$$\begin{aligned} \operatorname{dist}(x, F) &= \inf_z |x - z| \leq \inf_z (|x - z| + |y - z|) \\ &= |x - y| + \operatorname{dist} y, F. \end{aligned}$$

Zudem gilt  $f_k \leq \mathbb{1}_F$  und  $f_k \downarrow \mathbb{1}_F$ , so dass

$$\begin{aligned} \limsup_{n \rightarrow \infty} \mathbb{P}(Y_n \in F) &= \limsup_{n \rightarrow \infty} \mathbb{E}[\mathbb{1}_F(Y_n)] \\ &\leq \lim_{n \rightarrow \infty} \mathbb{E}[f_k(Y_n)] \\ &\stackrel{2.}{=} \mathbb{E}[f_k(Y)] \end{aligned}$$

Mit monotoner Konvergenz folgt

$$\begin{aligned} \limsup_{n \rightarrow \infty} \mathbb{P}(Y_n \in F) &\leq \inf_{k \in \mathbb{N}} \mathbb{E}[f_k(Y)] \\ &= \mathbb{E}[\mathbb{1}_F(Y)] = \mathbb{P}(Y \in F) \end{aligned}$$

3.  $\implies$  4.: Für jedes  $O \subset \mathbb{R}$  offen ist  $O^C$  abgeschlossen, so dass

$$\begin{aligned} \liminf_{n \rightarrow \infty} \mathbb{P}(Y_n \in O) &= \liminf_{n \rightarrow \infty} (1 - \mathbb{P}(Y_n \in O^C)) \\ &= 1 - \limsup_{n \rightarrow \infty} \mathbb{P}(Y_n \in O^C) \\ &\stackrel{3.}{\geq} 1 - \mathbb{P}(Y \in O^C) \\ &= \mathbb{P}(Y \in O). \end{aligned}$$

4.  $\implies$  3.: Analog und vertausche  $\limsup$  mit  $\liminf$ .

4. und 3.  $\implies$  5.: Sei  $C \in \mathcal{B}(\mathbb{R})$  und  $\overset{\circ}{C}$  das offene Innere von  $C$ ,  $\bar{C} = \overset{\circ}{C} \cup \partial C$  der Abschluss.

$$\begin{aligned} \lim_{n \rightarrow \infty} \mathbb{P}(Y_n \in C) &\leq \limsup_{n \rightarrow \infty} \mathbb{P}(Y_n \in \bar{C}) \\ &\stackrel{3.}{\leq} \mathbb{P}(Y \in \bar{C}) \\ &= \mathbb{P}(Y \in \overset{\circ}{C}) \quad (\text{da } \mathbb{P}_Y(\partial C) = 0) \\ &\stackrel{4.}{\leq} \liminf_{n \rightarrow \infty} \mathbb{P}(Y_n \in \overset{\circ}{C}) \\ &\leq \limsup_{n \rightarrow \infty} \mathbb{P}(Y_n \in C). \end{aligned}$$

5.  $\implies$  1.: Sei  $f \in C_b(\mathbb{R})$  positiv. (wenn nicht positiv: in positiven und negativen Anteil zerlegen und dann mit Linearität arbeiten). Da  $\partial\{f \geq t\} = \{f = t\}$  gilt, folgt  $\mathbb{P}_Y(\partial\{f \geq t\}) > 0$  für höchstens abzählbar viele  $t$  und das impliziert

$$\begin{aligned} \lim_{n \rightarrow \infty} \mathbb{E}[f(Y_n)] &= \lim_{n \rightarrow \infty} \int_{\mathbb{R}} f \, d\mathbb{P}_{Y_n} \\ &= \lim_{n \rightarrow \infty} \int_0^\infty \mathbb{P}_{Y_n}(f \geq t) \, dt \quad \text{folgt mit Schilling MINT Satz 16.7} \\ &= \lim_{n \rightarrow \infty} \int_0^\infty \mathbb{P}(f(Y_n) \geq t) \, dt \\ &= \int_0^\infty \lim_{n \rightarrow \infty} \mathbb{P}(f(Y_n) \geq t) \, dt \quad \text{dom. Konvergenz} \\ &= \int_0^\infty \mathbb{P}(f(Y) \geq t) \, dt \quad \text{nutze 5.} \\ &= \mathbb{E}[f(Y)] \quad \text{Satz 16.7.} \end{aligned}$$

Für allgemeines  $f$  folgt die Aussage mittels Linearität. □

#### Lemma X.4

$Y, Y_1, Y_2, \dots$  reelle Zufallsvariablen auf  $(\Omega, \mathcal{F}, \mathbb{P})$ . Es gilt

$$Y_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} \implies Y_n \xrightarrow[n \rightarrow \infty]{d} Y$$

*Beweis.* Seien  $f \in C_b^g(\mathbb{R})$  und  $\varepsilon > 0$  fixiert. Betrachte

$$|\mathbb{E}[f(Y_n)] - \mathbb{E}[f(Y)]| \leq \mathbb{E}[|f(Y_n) - f(Y)|] = \int_{\mathbb{R}} |f(Y_n) - f(Y)| \, d\mathbb{P}$$

Da  $f \in C_0^g$  existiert  $M \in \mathbb{R}$  mit  $|f| \leq M$  und

$$\exists \delta = \delta(\varepsilon) \in (0, 1) \text{ so dass } \forall |x - y| \leq \delta: |f(x) - f(y)| < \varepsilon \quad (\star)$$

Schreibe nun

$$\int |f(Y_n) - f(Y)| \, d\mathbb{P} = \int_{\{|Y_n - Y| \leq \delta\}} \dots \, d\mathbb{P} + \int_{\{|Y_n - Y| > \delta\}} \dots \, d\mathbb{P} = E_1 + E_2$$

mit

$$\begin{aligned} E_1 &\stackrel{(\star)}{\leq} \varepsilon \mathbb{P}(|Y_n - Y| \leq \delta) \\ E_2 &\leq 2M \mathbb{P}(|Y_n - Y| > \delta) \\ E_1 + E_2 &\leq \varepsilon \mathbb{P}(|Y_n - Y| \leq \delta) + 2M \mathbb{P}(|Y_n - Y| > \delta) \\ &\leq \varepsilon + 2M \underbrace{\mathbb{P}(|Y_n - Y| > \delta)}_{\xrightarrow[n \rightarrow \infty]{} 0} \rightarrow \varepsilon \end{aligned}$$

Für  $\varepsilon \rightarrow 0$  folgt die Behauptung. □

### Lemma X.5

$Y, Y_1, Y_2, \dots$  reelle Zufallsvariablen auf  $(\Omega, \mathcal{F}, \mathbb{P})$ . Für  $c \in \mathbb{R}$  konstant gilt

$$Y_n \xrightarrow[n \rightarrow \infty]{d} Y \equiv c \iff Y_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} Y \equiv c$$

*Beweis.* •  $\Leftarrow$ : Lemma X.4

- $\Rightarrow$ : Für  $\varepsilon > 0$  fixiert, wähle  $f \in C_b(\mathbb{R})$  so dass

$$f(0) = 0 \quad f(x) \geq \mathbb{1}_{[-\varepsilon, \varepsilon]^C}(x) \quad \forall x \in \mathbb{R}$$

Dann

$$\begin{aligned} \mathbb{P}(|Y_n - Y| > \varepsilon) &= \int_{[-\varepsilon, \varepsilon]^C} (Y_n - Y) \, d\mathbb{P} \\ &\leq \int f(Y_n - Y) \, d\mathbb{P} \\ &= \int f(Y_n - c) \, d\mathbb{P} \\ &\xrightarrow[n \rightarrow \infty]{} \int f(Y - c) \, d\mathbb{P} = \int f(0) \, d\mathbb{P} = 0. \end{aligned} \quad \square$$

**Satz X.6**

$Y, Y_1, Y_2, \dots$  reelle Zufallsvariablen mit Verteilungsfunktionen  $F_Y, F_{Y_1}, F_{Y_2}, \dots$

Dann gilt  $Y_n \xrightarrow[n \rightarrow \infty]{d} Y$  genau dann wenn

$$\lim_{n \rightarrow \infty} F_{Y_n}(x) = F_Y(x) \quad \forall \text{ Stetigkeitsstellen } x \text{ von } F_Y.$$

Ist  $F_Y$  stetig, so gilt in diesem Fall sogar gleichmäßige Konvergenz

$$\lim_{n \rightarrow \infty} \sup_{x \in \mathbb{R}} |F_{Y_n}(x) - F_Y(x)| = 0.$$

*Beweis.* Es gelte  $Y_n \xrightarrow[n \rightarrow \infty]{d} Y$ , d.h.  $\mathbb{E}[f(Y_n)] \rightarrow \mathbb{E}[f(Y)] \quad \forall f \in C_b(\mathbb{R})$ . Sei  $x \in \mathbb{R}$  fixiert,  $\varepsilon > 0$  und wähle  $f \in C_b(\mathbb{R})$  mit

$$\mathbb{1}_{(-\infty, x]} \leq f \leq \mathbb{1}_{(-\infty, x+\varepsilon]}$$

Dann

$$\begin{aligned} \limsup_{n \rightarrow \infty} F_{Y_n}(x) &= \limsup_{n \rightarrow \infty} \mathbb{P}(Y_n \leq x) \\ &= \limsup_{n \rightarrow \infty} \mathbb{E}[\mathbb{1}_{(-\infty, x]}(Y_n)] \\ &\leq \limsup_{n \rightarrow \infty} \mathbb{E}[f(Y_n)] \\ &= \lim_{n \rightarrow \infty} \mathbb{E}[f(Y_n)] = \mathbb{E}[f(Y)] \\ &\leq \mathbb{E}[\mathbb{1}_{(-\infty, x+\varepsilon]}(Y)] = F_Y(x + \varepsilon) \end{aligned}$$

Für  $\varepsilon \rightarrow 0$  folgt, da  $F_Y$  rechtsstetig

$$\limsup_{n \rightarrow \infty} F_{Y_n}(x) \leq F_Y(x)$$

Ist  $x$  Stetigkeitsstelle von  $F_Y$ , so gilt auch  $F_Y(x - \varepsilon) \rightarrow F_Y(x), \varepsilon \rightarrow 0$  und eine analoge Rechnung zeigt

$$\liminf_{n \rightarrow \infty} F_{Y_n}(x) \geq F_Y(x)$$

also

$$\lim_{n \rightarrow \infty} F_{Y_n}(x) = F_Y(x)$$

Umgekehrt: Es gelte  $\lim_{n \rightarrow \infty} F_{Y_n}(x) = F_Y(x) \quad \forall \text{ Stetigkeitsstellen } x \text{ von } F_Y$ . Fixiere  $f \in C_b^g(\mathbb{R})$  (PORTMANTEAU!),  $\varepsilon > 0$  und wähle Stetigkeitsstellen  $x_1 < x_2 < \dots < x_n$  von  $F_Y$ , so dass

$$\begin{aligned} F_Y(x_1) &< \varepsilon, F_Y(x_k) > 1 - \varepsilon \text{ und} \\ |f(y) - f(x_i)| &< \varepsilon \quad \forall x_{i-1} \leq y \leq x_i \end{aligned}$$

(möglich, da  $f$  gleichmäßig stetig und  $F_Y$  wegen Monotonie nur abzählbar viele Unstetigkeitsstellen besitzt.)

Das impliziert

$$\begin{aligned}
\mathbb{E}[f(Y_n)] &= \sum_{i=2}^k \mathbb{E}[f(y_n) \mathbb{1}_{\{x_{i-1} < Y_n \leq x_i\}}] + \mathbb{E}[f(Y_n) \mathbb{1}_{\{Y_n \leq x_1\} \cup \{Y_n > x_k\}}] \\
&\leq \sum_{i=2}^k (f(x_i) + \varepsilon)(F_{Y_n}(x_i) - F_{Y_n}(x_{i-1})) + 2\varepsilon \|f\|_\infty \\
&\xrightarrow{n \rightarrow \infty} \sum_{i=2}^k (f(x_i) + \varepsilon)(F_Y(x_i) - F_Y(x_{i-1})) + 2\varepsilon \|f\|_\infty \\
&\leq \mathbb{E}[f(Y)] + 2\varepsilon(1 + 2\|f\|_\infty)
\end{aligned}$$

Für  $\varepsilon \rightarrow 0$  folgt

$$\limsup_{n \rightarrow \infty} \mathbb{E}[f(Y_n)] \leq \mathbb{E}[f(Y)]$$

Der  $\liminf$  folgt analog

$$\lim \mathbb{E}[f(Y_n)] = \mathbb{E}[f(Y)].$$

Zur gleichmäßigen Konvergenz: Sei  $F_Y$  stetig und  $\varepsilon = k^{-1}$ ,  $k \in \mathbb{N}$ . Dann existieren  $z_i \in \mathbb{R}$  mit

$$F_Y(z_i) = \frac{i}{k} \quad 0 < i < k$$

Da auch  $F_{Y_n}$  monoton wächst, gilt

$$\sup_{x \in \mathbb{R}} |F_{Y_n}(x) - F_Y(x)| \leq \varepsilon + \underbrace{\max_{0 \leq i \leq k} |F_{Y_n}(z_i) - F_Y(z_i)|}_{\xrightarrow{n \rightarrow \infty} 0}.$$

□

### Satz X.7 (Stetigkeitssatz)

$Y, Y_1, Y_2, \dots$  Zufallsvariablen in  $\mathbb{R}^d$  mit charakteristischen Funktionen  $\varphi_Y, \varphi_{Y_1}, \varphi_{Y_2}, \dots$ . Dann gilt

$$Y_n \xrightarrow[n \rightarrow \infty]{d} Y \iff \lim_{n \rightarrow \infty} \varphi_{Y_n}(u) = \varphi_Y(u) \quad \forall u \in \mathbb{R}^d$$

Für den Beweis benötigen wir:

### Lemma X.8

$Y, Y_1, Y_2, \dots$  Zufallsvariablen in  $\mathbb{R}^d$  und sei  $N = (N_1, \dots, N_d)^T$  Zufallsvektor so dass  $N_1, N_2, \dots, N_d$  u.i.v. mit  $N_i \sim \mathcal{N}(0, 1)$ , unabhängig von  $Y, Y_1, Y_2, \dots$ . Falls:

$$Y_n + \sigma N \xrightarrow[n \rightarrow \infty]{d} Y + \sigma N \quad \sigma > 0$$

dann folgt

$$Y_n \xrightarrow[n \rightarrow \infty]{d} Y$$

*Beweis.* Sei  $f \in C_b^g(\mathbb{R})$  und  $\varepsilon > 0$  beliebig.

$$\begin{aligned} |\mathbb{E}[f(Y_n) - f(Y)]| &\leq |\mathbb{E}[f(Y_n)] - \mathbb{E}[f(Y_n + \sigma N)]| \\ &\quad + \underbrace{|\mathbb{E}[f(Y_n + \sigma N)] - \mathbb{E}[f(Y + \sigma N)]|}_{\xrightarrow[n \rightarrow \infty]{} 0} \\ &\quad + |\mathbb{E}[f(Y + \sigma N)] - \mathbb{E}[f(Y)]| \end{aligned}$$

Da  $f \in C_b^g(\mathbb{R})$  existiert  $\delta > 0$ , so dass

$$|f(x) - f(y)| \leq \varepsilon \text{ für } |x - y| \leq \delta$$

Damit

$$\begin{aligned} |\mathbb{E}[f(Y_n)] - \mathbb{E}[f(Y_n + \sigma N)]| &= \left| \mathbb{E}[\underbrace{f(Y_n) - f(Y_n + \sigma N)}_{\leq \varepsilon \text{ mit } \|\sigma N\| < \delta}] \right| \\ &\leq \varepsilon + 2\|f\|_\infty \mathbb{P}(\|\sigma N\| > \delta) \leq 2\varepsilon \quad \text{für } \sigma \leq \sigma_0(\delta, \varepsilon), \forall n \in \mathbb{N} \end{aligned}$$

Dann folgt für  $n$  hinreichend groß  $|\mathbb{E}[f(Y_n)] - \mathbb{E}[f(Y)]| \leq 5\varepsilon$ . Daraus folgt die Behauptung.  $\square$

*Beweis* (Satz X.7). Es gilt  $Y_n \xrightarrow[n \rightarrow \infty]{d} Y$ , dann folgt

$$\begin{aligned} \varphi_{Y_n}(u) &= \mathbb{E}[e^{i\langle u, Y_n \rangle}] = \mathbb{E}[\cos(\langle u, Y_n \rangle)] + i\mathbb{E}[\sin(\langle u, Y_n \rangle)] \\ &\xrightarrow[n \rightarrow \infty]{} \mathbb{E}[\cos(\langle u, Y \rangle)] + i\mathbb{E}[\sin(\langle u, Y \rangle)] \\ &= \varphi_Y(u). \end{aligned}$$

Gelte umgekehrt  $\varphi_{Y_n}(u) \rightarrow \varphi_Y(u) \forall u \in \mathbb{R}^d$ . Nach Lemma X.8 genügt zu zeigen, dass

$$Y_n + \sigma N \xrightarrow{d} Y + \sigma N \quad \sigma > 0$$

mit  $N$  wie in Lemma X.8. Sei  $f \in C_b(\mathbb{R})$ , dann gilt ( $\nearrow$  Beweis zu Lemma VIII.12).

$$\mathbb{E}[f(Y_n + \sigma N)] = \int_{\mathbb{R}^d} f(z) \rho_{Y_n + \sigma N}(z) \, dz$$

mit

$$\rho_{Y_n + \sigma N}(z) = (2\pi)^d \int_{\mathbb{R}^d} \varphi_{Y_n}(-y) e^{i\langle z, y \rangle} e^{-\sigma^2 y^2 / 2} \, dy$$

so dass

$$\begin{aligned} |\mathbb{E}[f(Y_n + \sigma N)] - \mathbb{E}[f(Y + \sigma N)]| &= \left| \int_{\mathbb{R}^d} f(z) (\rho_{Y_n + \sigma N}(z) - \rho_{Y + \sigma N}(z)) \, dz \right| \\ &\leq \|f\|_\infty \int_{\mathbb{R}^d} |\rho_{Y_n + \sigma N}(z) - \rho_{Y + \sigma N}(z)| \, dz \\ &= \|f\|_\infty \int_{\mathbb{R}^d} (\rho_{Y_n + \sigma N}(z) - \rho_{Y + \sigma N}(z))^+ + (\rho_{Y_n + \sigma N}(z) - \rho_{Y + \sigma N}(z))^- \, dz \\ &\stackrel{(*)}{=} 2\|f\|_\infty \int_{\mathbb{R}^d} (\rho_{Y_n + \sigma N} - \rho_{Y + \sigma N})^+ \, dz \\ &\xrightarrow[n \rightarrow \infty]{} 0 \end{aligned}$$

Majorante:  $\rho_{Y_n+\sigma N}(z)$  und  $e^{-\sigma^2 y^2/2}$  nach dominierter Konvergenz, da  $\varphi_{Y_n}(u) \rightarrow \varphi_Y(u)$ .

Zu Gleichung I.★:

$$\begin{aligned} & \int_{\mathbb{R}^d} (\rho_{Y_n+\sigma N}(z) - \rho_{Y+\sigma N}(z))^+ dz - \int_{\mathbb{R}^d} (\rho_{Y_n+\sigma N}(z) - \rho_{Y+\sigma N}(z))^- dz \\ &= \int_{\mathbb{R}^d} (\rho_{Y_n+\sigma N}(z) - \rho_{Y+\sigma N}(z)) dz \\ &= 1 - 1 = 0 \end{aligned} \quad (\star)$$

□

Mit dem Stetigkeitssatz lassen sich bekannte Resultate reproduzieren.

### Lemma X.9 (Poissonapproximation)

Sei  $X_n \sim \text{Bin}(n, p_n)$ , so dass  $np_n \xrightarrow{n \rightarrow \infty}$  dann gilt

$$X_n \xrightarrow[n \rightarrow \infty]{d} X \sim \text{Poisson}(\lambda).$$

*Beweis.* Nach Beispiel V.15

$$\begin{aligned} \varphi_{X_n}(u) &= \psi_{X_n}(e^{iu}) = (1 + p_n(e^{iu} - 1))^n \\ &= (1 + \frac{np_n(e^{iu} - 1)}{n})^n \\ &\xrightarrow[n \rightarrow \infty]{} e^{\lambda(e^{iu} - 1)} = \psi_X(u) \end{aligned}$$

und mit dem Stetigkeitssatz folgt die Behauptung. □

### Satz X.10 (WLLN, u.i.v-Version in $\mathbb{R}^d$ )

Seien  $X_1, X_2, \dots$  u.i.v  $\mathbb{R}^d$ -wertige Zufallsvariablen auf  $(\Omega, \mathcal{F}, \mathbb{P})$  mit  $X_i \in \mathcal{L}^1(\mathbb{P})$ . Dann gilt

$$1/n \sum_{i=1}^n X_i \xrightarrow[n \rightarrow \infty]{\mathbb{P}} \mathbb{E}[X_1].$$

*Beweis.* Für  $u \in \mathbb{R}^d$  gilt

$$\begin{aligned} \varphi_{1/n \sum X_i}(u) &= \varphi_{\sum X_i}(u/n) \\ &\stackrel{\text{unabh.}}{=} \prod_{i=1}^n \varphi_{X_i}(u/n) \stackrel{\text{ident. verteilt}}{=} (\varphi_{X_1}(u/n))^n \\ &\stackrel{\text{TAYLOR}}{=} (1 + 1/n \langle u, \varphi'_{X_1}(0) \rangle + o(\|u/n\|))^n \\ &= (1 + 1/n i \langle u, \mathbb{E}[X_1] \rangle + o(\|u/n\|))^n \quad \text{VIII.14} \\ &\xrightarrow[n \rightarrow \infty]{} \exp(i \langle u, \mathbb{E}[X_1] \rangle) \end{aligned}$$

und dies ist die charakteristische Funktion des Dirac-Maßes in  $\mathbb{E}[X_1]$ . Mit Stetigkeitssatz

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow[n \rightarrow \infty]{d} \mathbb{E}[X_1].$$



Und Lemma X.5 gibt

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow[n \rightarrow \infty]{\mathbb{P}} \mathbb{E}[X_1]. \quad \square$$

### Folgerung X.11 (Cramér-Wold device)

$Y, Y_1, Y_2, \dots$  Zufallsvariablen in  $\mathbb{R}^d$ . Dann gilt

$$Y_n \xrightarrow[n \rightarrow \infty]{d} Y \iff \langle u, Y_n \rangle \xrightarrow[n \rightarrow \infty]{d} \langle u, Y \rangle \quad \forall u \in \mathbb{R}^d.$$

*Beweis.* Es gilt

$$\varphi_{\langle u, Y_n \rangle}(t) = \mathbb{E}[e^{i\langle u, Y_n \rangle}] = \varphi_{Y_n}(tu)$$

und  $\varphi_{\langle u, Y \rangle}(t) = \varphi_Y(tu)$

$$\begin{aligned} Y_n \xrightarrow[n \rightarrow \infty]{d} Y &\iff \varphi_{Y_n}(v) \rightarrow \varphi_Y(v) \quad \forall v \in \mathbb{R}^d \quad \text{Stetigkeitslemma} \\ &\stackrel{\text{s.o.}}{\iff} \varphi_{\langle u, Y_n \rangle}(t) \rightarrow \varphi_{\langle u, Y \rangle}(t) \quad \forall t \in \mathbb{R}, u \in \mathbb{R}^d \\ &\iff \langle u, Y_n \rangle \xrightarrow[n \rightarrow \infty]{d} \langle u, Y \rangle \quad \forall u \in \mathbb{R}^d \quad \text{Stetigkeitslemma} \end{aligned} \quad \square$$

### Satz X.12 (Lemma von Slutsky)

Seien  $Y, Y_1, Y_2, \dots, Z, Z_1, Z_2, \dots$   $\mathbb{R}^d$ -wertige Zufallsvariablen auf  $(\Omega, \mathcal{F}, \mathbb{P})$ , so dass

$$Y_n \xrightarrow[n \rightarrow \infty]{d} Y \quad \text{und} \quad Y_n - Z_n \xrightarrow[n \rightarrow \infty]{\mathbb{P}} 0$$

Dann gilt

$$Z_n \xrightarrow[n \rightarrow \infty]{d} Y$$

*Beweis.* Es gilt

$$\begin{aligned} \varphi_{Z_n}(u) &= \mathbb{E}[e^{i\langle u, Z_n \rangle}] = \mathbb{E}[e^{i\langle u, Z_n - Y_n \rangle} e^{i\langle u, Y_n \rangle}] \\ &= \mathbb{E}[(e^{i\langle u, Z_n - Y_n \rangle} - 1)e^{i\langle u, Y_n \rangle}] + \underbrace{\mathbb{E}[e^{i\langle u, Y_n \rangle}]}_{\varphi_{Y_n}(u) \xrightarrow[n \rightarrow \infty]{} \varphi_Y(u)} \quad \forall u \in \mathbb{R}^d \end{aligned}$$

Es genügt zu zeigen, dass

$$E := \mathbb{E}[(e^{i\langle u, Z_n - Y_n \rangle} - 1)e^{i\langle u, Y_n \rangle}] \xrightarrow[n \rightarrow \infty]{} 0$$

Dazu

$$\begin{aligned} |E| &\leq \mathbb{E}[|(e^{i\langle u, Z_n - Y_n \rangle} - 1)e^{i\langle u, Y_n \rangle}|] \\ &= \mathbb{E}[|e^{i\langle u, Z_n - Y_n \rangle} - 1|] \end{aligned}$$

Die Funktion  $z \mapsto e^{i\langle u, z \rangle}$ ,  $u \in \mathbb{R}^d$ , ist lokal LIPSCHITZ-stetig, dann für  $u, y, z \in \mathbb{R}^d$

$$\begin{aligned} |e^{i\langle u, z \rangle} - e^{i\langle u, y \rangle}| &= |e^{i\langle u, z-y \rangle} - 1| \\ &= \left| \int_0^{i\langle u, z-y \rangle} e^\zeta d\zeta \right| \\ &\leq \sup_{|\zeta| \leq |\langle u, z-y \rangle|} |e^{i\zeta}| \cdot |i\langle u, z-y \rangle| = |\langle u, z-y \rangle| \\ &\leq |u| \cdot |z-y| \end{aligned}$$

Damit

$$\begin{aligned} |E| &\leq \mathbb{E}[|e^{i\langle u, Z_n - Y_n \rangle}| \mathbb{1}_{\{|Z_n - Y_n| \leq \delta\}}] \\ &\quad + \mathbb{E}[|e^{i\langle u, Z_n - Y_n \rangle} - 1| \mathbb{1}_{\{|Z_n - Y_n| \leq \delta\}}] \\ &\leq \delta|u| + 2 \underbrace{\mathbb{P}(|Z_n - Y_n| \leq \delta)}_{\xrightarrow{n \rightarrow \infty} 0} \\ &\xrightarrow{n \rightarrow \infty} \delta \cdot |u| \\ &\xrightarrow{\delta \rightarrow 0} 0. \end{aligned}$$

□

## 2. Der Zentrale Grenzwertsatz

(CLT, central limit theorem)

### Satz X.13 (CLT, u.i.v -Version)

$X_1, X_2, \dots$  reelle u.i.v Zufallsvariablen mit  $\mathbb{E}[X_1] =: \mu$  und  $0 < \text{Var}(X_1) =: \sigma^2 < \infty$ . Dann gilt

$$\frac{\sum_{i=1}^n (X_i - \mu)}{\sqrt{\sigma^2 n}} \xrightarrow[n \rightarrow \infty]{d} \mathcal{N}(0, 1).$$

*Beweis.* Verwende den Stetigkeitssatz:

$$\begin{aligned} \varphi_{\sum (X_k - \mu)/\sqrt{\sigma^2 n}}(u) &= \mathbb{E}[e^{iu(\sum (X_k - \mu)/\sqrt{\sigma^2 n})}] \\ &= \prod_{k=1}^n \mathbb{E}[e^{iu(X_k - \mu)/\sqrt{\sigma^2 n}}] \quad X_k \text{ unabh.} \\ &= \left( \mathbb{E}[e^{iu(X_1 - \mu)/\sqrt{\sigma^2 n}}] \right)^n \quad X_k \text{ identisch verteilt} \\ &= \left( \varphi_{X_1 - \mu}(u/\sqrt{\sigma^2 n}) \right)^n \\ &= \left( 1 + i \frac{u}{\sigma\sqrt{n}} \underbrace{\mathbb{E}[X_1 - \mu]}_{=0} + \frac{i^2}{2} \underbrace{\mathbb{E}[(X_1 - \mu)^2]}_{\sigma^2} + o\left(\left\| \frac{u}{\sqrt{\sigma^2 n}} \right\|^2\right) \right)^n \quad \text{TAYLOR} \\ &= \left( 1 - \frac{1}{2} \frac{u^2}{n} + o\left(\left\| \frac{u}{\sqrt{\sigma^2 n}} \right\|^2\right) \right)^n \\ &\xrightarrow{n \rightarrow \infty} \exp(-1/2 u^2) = \varphi_{\mathcal{N}(0,1)}(u). \end{aligned}$$

□

**Folgerung X.14 (CLT, De Moivre-Laplace)**

Sei  $S_n = \text{Bin}(n, p)$ ,  $p \in (0, 1)$ , dann

$$\frac{S_n - np}{\sqrt{np(1-p)}} \xrightarrow[n \rightarrow \infty]{d} Z \sim \mathcal{N}(0, 1).$$

*Beweis.* Es gilt:  $S_n \stackrel{d}{=} X_1 + \dots + X_n$ , für  $X_i \sim \text{Bernoulli}(p)$  unabhängig, mit  $\mathbb{E}[X_1] = p$ ,  $\mathbb{V}\text{ar}(X_1) = p(1-p)$ .  $\square$

**► Bemerkung**

Auch der lokale Grenzwertsatz von DE MOIVRE-LAPLACE (Satz VII.2) impliziert Folgerung X.14, siehe z.B. ↗ Dehling & Haupt.

Die Bedingungen des CLT lassen sich abschwächen. Zum Beispiel kann “identisch verteilt” durch die LINDEBERG-Bedingung ersetzt werden:

$$\forall \varepsilon > 0 \quad \lim_{n \rightarrow \infty} \frac{1}{\sum_{i=1}^n \mathbb{V}\text{ar}(X_i)} \sum_{k=1}^n \mathbb{E}[(X_k - \mathbb{E}[X_k])^2 \mathbb{1}_{\{|X_k - \mathbb{E}[X_k]| > \varepsilon \sum_{i=1}^n \mathbb{V}\text{ar}(X_i)\}}] = 0$$

und dann gilt

$$\frac{\sum_{k=1}^n (X_k - \mathbb{E}[X_k])}{\sqrt{\sum_{i=1}^n \mathbb{V}\text{ar}(X_i)}} \xrightarrow[n \rightarrow \infty]{d} Z \sim \mathcal{N}(0, 1)$$

Der folgende CLT geht noch etwas weiter und betrachtet die Zufallsvariablen in einem Dreiecksschema:

$$\begin{array}{ccccccc} X_{1,1} & X_{1,2} & \dots & X_{1,k(1)} & & & \\ X_{2,1} & X_{2,2} & & & X_{2,k(2)} & & \\ \vdots & & & & & & \\ X_{k,1} & X_{k,2} & & & & & X_{k,k(k)} \\ \vdots & & & & & & \end{array} \quad \text{mit } k(n) \rightarrow \infty \text{ für } n \rightarrow \infty$$

**Satz X.15 (CLT, Lindeberg-Feller)**

Seien  $\{X_{n,k}, k = 1, \dots, k(n), n \in \mathbb{N}\}$  reelle Zufallsvariablen in einem Dreiecksschema mit  $\mathbb{E}[X_{n,k}] = 0$  und  $0 < \mathbb{V}\text{ar}(X_{n,k}) = \sigma_{n,k}^2 < \infty$ , so dass  $\forall n \in \mathbb{N}$  die Zufallsvariablen  $X_{n,1}, \dots, X_{n,k(n)}$  unabhängig sind. Zudem gelten

$$\sum_{k=1}^{k(n)} \sigma_{n,k}^2 \xrightarrow{n \rightarrow \infty} \sigma^2 \in (0, \infty)$$

und die LINDEBERG-Bedingung für Schemata:

$$\forall \varepsilon > 0: \lim_{n \rightarrow \infty} \sum_{k=1}^{k(n)} \mathbb{E}[X_{n,k}^2 \mathbb{1}_{|X_{n,k}| > \varepsilon}] = 0$$

Dann gilt

$$\sum_{k=1}^{k(n)} X_{n,k} \xrightarrow[n \rightarrow \infty]{d} Z \sim \mathcal{N}(0, \sigma^2)$$

*Beweis.* Wir beginnen mit einer TAYLOREntwicklung der charakteristischen Funktion der  $X_{n,k}$ :

$$\varphi_{X_{n,k}} = 1 + \dots + \underbrace{i \mathbb{E}[X_{n,k}]}_{=0} \cdot u - \frac{1}{2} \underbrace{\mathbb{E}[X_{n,k}^2]}_{\sigma_{n,k}^2} u^2 + R_{n,k}(u)$$

wobei wir  $R_{n,k}$  folgendermaßen abschätzen. Für  $x \in \mathbb{R}$  gilt

$$\begin{aligned} |e^{ix} - 1 - ix - 1/2(ix)^2| &= \left| \int_0^x \int_0^t (1 - e^{iy}) dy dt \right| \\ &\leq \left| \int_0^{|x|} \int_0^{|t|} (1 - e^{iy}) dy dt \right| \end{aligned}$$

mit  $|1 - e^{iy}| = \left| \int_0^y e^{iz} dz \right| \leq |y| \wedge 2$  so dass  $|e^{ix} - 1 - ix + 1/2x^2| \leq |x|^3/6 \wedge x^2$ . Für  $x = uX_{n,k}$  folgt im Erwartungswert

$$\begin{aligned} |R_{n,k}(u)| &\leq u^2 \mathbb{E}[X_{n,k}^2 \wedge \frac{|u| \cdot |X_{n,k}^3|}{6}] \\ &= u^2 \left( \int_{|X_{n,k}| > \varepsilon} (X_{n,k}^2 \wedge \frac{|u| \cdot |X_{n,k}^3|}{6}) d\mathbb{P} + \int_{|X_{n,k}| \leq \varepsilon} (X_{n,k}^2 \wedge \frac{|u| \cdot |X_{n,k}^3|}{6}) d\mathbb{P} \right) \\ &\leq u^2 \left( \int_{|X_{n,k}| > \varepsilon} (X_{n,k}^2) d\mathbb{P} + \int_{|X_{n,k}| \leq \varepsilon} \frac{|u| \cdot |X_{n,k}^3|}{6} d\mathbb{P} \right) \\ &\leq u^2 \mathbb{E}[X_{n,k}^2 \mathbb{1}_{|X_{n,k}| > \varepsilon}] + \varepsilon/6 |u|^3 \mathbb{E}[X_{n,k}^2] \end{aligned}$$

Seien  $\{Y_{n,k}, k = 1, \dots, k(n), n \in \mathbb{N}\}$  Zufallsvariablen mit  $Y_{n,k} \sim \mathcal{N}(0, \sigma_{n,k}^2)$ , so dass  $\forall n$  die Zufallsvariablen  $Y_{n,1}, \dots, Y_{n,k(n)}$  unabhängig sind. Dann gilt (analog zu oben)

$$\varphi_{Y_{n,k}}(u) = 1 - 1/2\sigma_{n,k}^2 u^2 + \tilde{R}_{n,k}(u)$$

mit

$$\begin{aligned}
 |\tilde{R}_{n,k}(u)| &\leq u^2 \mathbb{E}[Y_{n,k}^2 \wedge \frac{|u||Y_{n,k}|^3}{6}] \leq |u|^3 \frac{\mathbb{E}[|Y_{n,k}|^3]}{6} \\
 &\leq |u|^3 C \sigma_{n,k}^3 \quad \text{Übung und für eine Konstante } C \\
 &\leq |u|^3 C \sigma_{n,k}^2 \max_{1 \leq k \leq k(n)} \sigma_{n,k}
 \end{aligned}$$

Zusammen folgt

$$\begin{aligned}
 |\varphi_{X_{n,k}}(u) - \varphi_{Y_{n,k}}(u)| &\leq |R_{n,k}(u)| + |\tilde{R}_{n,k}(u)| \\
 &\leq \underbrace{u^2 \mathbb{E}[X_{n,k}^2 \mathbb{1}_{|X_{n,k}| > \varepsilon}]}_{\xrightarrow{n \rightarrow \infty} 0 \text{ LINDBERG}} + \underbrace{\frac{\varepsilon}{6} \sigma_{n,k}^2}_{\rightarrow 0, \varepsilon \rightarrow 0} + |u|^3 C \underbrace{\max_{1 \leq k \leq k(n)} \sigma_{n,k}}_{\xrightarrow{n \rightarrow \infty} 0}
 \end{aligned}$$

(vgl. Satz 11.5) und mit der Unabhängigkeitsannahme:

$$\begin{aligned}
 |\varphi_{X_{n,1}+\dots+X_{n,k(n)}}(u) - \varphi_{Y_{n,1}+\dots+Y_{n,k(n)}}(u)| &= \left| \prod_{k=1}^{k(n)} \varphi_{X_{n,k}}(u) - \prod_{k=1}^{k(n)} \varphi_{Y_{n,k}}(u) \right| \\
 &\stackrel{(*)}{=} \left| \sum_{i=1}^{k(n)} \left( \prod_{j=1}^{i-1} \varphi_{X_{n,j}}(u) \right) \cdot (\varphi_{X_{n,i}}(u) - \varphi_{Y_{n,i}}(u)) \cdot \left( \prod_{j=i+1}^{k(n)} \varphi_{Y_{n,j}}(u) \right) \right| \\
 &\leq \sum_{k=1}^{k(n)} |\varphi_{X_{n,k}}(u) - \varphi_{Y_{n,k}}(u)| \xrightarrow{n \rightarrow \infty, \varepsilon \rightarrow 0} 0
 \end{aligned}$$

mit (\*), da

$$\begin{aligned}
 \sum_{k=1}^n \left( \prod_{j=1}^{k-1} a_j (a_k - b_k) \right) \prod_{j=k-1}^n b_j &= (a_1 - b_1) \prod_{j=2}^n b_j + a_1 (a_2 - b_2) \prod_{j=3}^n b_j + \dots + \prod_{j=1}^{n-1} a_j (a_n - b_n) \\
 &= \prod_{k=1}^n a_n - \prod_{k=1}^n b_n \quad (*)
 \end{aligned}$$

Da

$$\begin{aligned}
 \varphi_{Y_{n,1}+\dots+Y_{n,k(n)}} &= \prod_{k=1}^{k(n)} \varphi_{Y_{n,k(n)}} \\
 &= \exp(-u^2(\sigma_{n,1}^2 + \dots + \sigma_{n,k(n)}^2)/2) \\
 &\xrightarrow{n \rightarrow \infty} e^{-u^2 \sigma^2 / 2} \quad u \in \mathbb{R}
 \end{aligned}$$

folgt

$$\varphi_{X_{n,1}+\dots+X_{n,k(n)}}(u) \xrightarrow{n \rightarrow \infty} e^{-u^2 \sigma^2 / 2} \quad u \in \mathbb{R}$$

und mit Stetigkeitsatz (put ref here!) folgt die Behauptung.  $\square$

## Kapitel XI

# Diskrete Martingale

### Definition XI.1

Eine Folge  $(X_n)_{n \in \mathbb{N}_0}$  von reellen Zufallsvariablen auf  $(\Omega, \mathcal{F}, \mathbb{P})$  heißt Martingal, falls

1.  $\mathbb{E}[|X_n|] < \infty$  also  $X_n \in \mathcal{L}^1(\mathbb{P}) \forall n \in \mathbb{N}_0$
2.  $\mathbb{E}[X_{n+1} \mid X_0, X_1, \dots, X_n] = X_n, \mathbb{P}\text{-f.s. } \forall n \in \mathbb{N}$

Die Folge  $(X_n)_{n \in \mathbb{N}}$  heißt Super-/Submartingal, falls 1. und folgendes gilt

1.  $\mathbb{E}[X_{n+1} \mid X_0, X_1, \dots, X_n] \leq / \geq X_n, \mathbb{P}\text{-f.s. } \forall n \in \mathbb{N}$

### ■ Beispiel XI.2

Sei  $(Y_n)_{n \in \mathbb{N}}$  Folge von u.i.v. Zufallsvariablen auf  $(\Omega, \mathcal{F}, \mathbb{P})$  in  $\mathcal{L}^1(\mathbb{P})$ , reellwertig mit  $\mathbb{E}[Y_1] = 0$ . Dann ist  $(X_n)_{n \in \mathbb{N}}$  mit

$$X_0 = 0 \text{ und } X_n = \sum_{k=1}^n Y_k \quad n \geq 1$$

ein Martingal, denn

1.  $\mathbb{E}[|X_n|] \leq \sum_{k=1}^n \mathbb{E}[|Y_k|] < \infty$
- 2.

$$\begin{aligned} \mathbb{E}[X_{n+1} \mid X_0, \dots, X_n] &= \mathbb{E}[X_n + Y_{n+1} \mid X_0, \dots, X_n] = \mathbb{E}[X_n \mid X_0, \dots, X_n] + \mathbb{E}[Y_{n+1} \mid X_0, \dots, X_n] \\ &= X_n + \mathbb{E}[Y_{n+1}] = X_n \quad \mathbb{P}\text{-f.s. } \forall n \in \mathbb{N} \end{aligned}$$

Für  $\mathbb{E}[Y_1] \geq / \leq 0$  erhält man dementsprechend ein Sub-/Supermartingal.

### ■ Beispiel XI.3

Sei  $(X_n)_{n \in \mathbb{N}}$  ein (Super-/Sub-)Martingal auf  $(\Omega, \mathcal{F}, \mathbb{P})$  und  $(C_n)_{n \in \mathbb{N}}$  eine Folge von beschränkten Zufallsvariablen in  $[0, \infty)$ , sodass  $C_n$   $\sigma(X_0, \dots, X_{n-1})$ -messbar ist. Dann ist  $(Y_n)_{n \in \mathbb{N}_0}$  mit

$$Y_0 := 0 \quad Y_n = \sum_{i=1}^n C_i (X_i - X_{i-1}) \quad \text{für } n \geq 1$$

ein (Super-/Sub-)Martingal ( $\nearrow$  Übung).


Interpretation:

- $(X_i - X_{i-1})$  entspricht Gewinn in Runde  $i$  pro Einsatzeinheit ( $X$  Martingal  $\rightsquigarrow$  faires Spiel mit Supermartingal  $\rightsquigarrow$  nachteilig und Submartingal  $\rightsquigarrow$  vorteilig)
- $C_i$  entspricht Einsatz in Runde  $i$

- $Y_n$  entspricht Gewinn nach  $n$  Runden

**Lemma XI.4 (Doob's Upcrossing Lemma)**

Sei  $(X_n)_{n \in \mathbb{N}_0}$  ein Supermartingal auf  $(\Omega, \mathcal{F}, \mathbb{P})$  und für  $a, b \in \mathbb{R}, N \in \mathbb{N}$ . Sei  $U_N[a, b] = \#$  Upcrossings von  $[a, b]$  durch  $X$  bis zur Zeit  $N$ :



d.h.

$$U_N[a, b](\omega) = \{\max k \in \mathbb{N}_0 : \exists 0 \leq S_1 < t_1 < S_2 < t_2 < \dots < s_k < t_k \leq N \\ : X_{s_i} < a, X_{t_i} > b, i \in \{1, \dots, k\}\}$$

Dann gilt

$$\mathbb{E}[U_N[a, b]] \leq \frac{\mathbb{E}[(X_N - a)^-]}{b - a}$$

*Beweis.* Interpretiere  $(X_i - X_{i-1})$  als Gewinn in Spielrunde  $i$  pro Einsatzeinheit. Wähle als Spielstrategie

$$C_1 := \mathbb{1}_{\{X_0 < a\}} \\ C_n := \mathbb{1}_{\{C_{n-1}=1\}} \mathbb{1}_{\{X_{n-1} \leq b\}} + \mathbb{1}_{\{C_{n-1}=0\}} \mathbb{1}_{\{X_{n-1} \leq a\}}$$

Dann ist  $(C_n)_{n \in \mathbb{N}}$  beschränkt, nicht-negativ und  $C_n$  ist  $\sigma(X_0, \dots, X_{n-1})$  messbar. Nach Beispiel XI.3 ist  $(Y_n)_{n \in \mathbb{N}_0}$  mit

$$Y_0 = 0 \\ Y_n = \sum_{i=1}^n C_i (X_i - X_{i-1})$$

ein Superimartingal. Es folgt

$$\mathbb{E}[Y_n] = \mathbb{E}[\mathbb{E}[Y_N | Y_0, \dots, Y_{N-1}]] \leq \mathbb{E}[Y_{N-1}] \leq \dots \leq \mathbb{E}[Y_0] = 0$$

Zudem gilt  $\forall \omega \in \Omega$

$$Y_N(\omega) \geq (b - a)U_N[a, b] - (X_N(\omega) - a)^- \\ \implies (b - a)\mathbb{E}[U_N[a, b]] \leq \mathbb{E}[Y_N] + \mathbb{E}[(X_N - a)^-] \\ \leq \mathbb{E}[(X_N - a)^-]$$

□

**Satz XI.5 (CLT für Martingale)**

Sei  $(X_n)_{n \in \mathbb{N}_0}$  ein Martingal mit  $X_n \in \mathcal{L}^2(\mathbb{P}) \forall n \in \mathbb{N}_0$ , so dass  $X_0 = 0$  und

$$\mathbb{E}[\Delta_n^2 \mid \mathcal{F}_{n-1}] = \sigma^2$$

deterministisch ist, wobei

$$\Delta_n := X_n - X_{n-1} \text{ und } \mathcal{F}_n := \sigma(X_0, \dots, X_n)$$

Gilt zudem die LINDBERG- Bedingung für Martingale

$$\forall \varepsilon > 0: \lim_{n \rightarrow \infty} 1/s_n^2 \sum_{k=1}^n \mathbb{E}[\Delta_k^2 \mathbb{1}_{|\Delta_k| > \varepsilon s_n} \mid \mathcal{F}_{k-1}] = 0$$

mit  $s_n^2 = \sum_{k=1}^n \sigma_k^2$ . Dann folgt

$$\frac{x_n}{s_n} \xrightarrow[n \rightarrow \infty]{d} Z \sim \mathcal{N}(0, 1)$$

Die Folge  $(\mathcal{F}_n)_{n \in \mathbb{N}}$  ist eine “Filtration”.

*Beweis.* Ähnlich zum Beweis des CLT nach LINDBERG-FELLER:

$$\mathbb{E}[e^{iu\Delta_k} \mid \mathcal{F}_{k-1}] = 1 + iu \underbrace{\mathbb{E}[\Delta_k \mid \mathcal{F}_{k-1}]}_{\mathbb{E}[X_k - X_{k-1} \mid \mathcal{F}_{k-1}]} - u^2 \underbrace{\mathbb{E}[\Delta_k^2 \mid \mathcal{F}_{k-1}]}_{\sigma_k^2} + R_k(u)$$

wobei

$$\begin{aligned} \mathbb{E}[\Delta_k \mid \mathcal{F}_{k-1}] &= \mathbb{E}[X_k - X_{k-1} \mid \mathcal{F}_{k-1}] \\ &= X_{k-1} - X_{k-1} \quad \text{Martingale-Eigenschaft und mb. Herausziehen} \\ &= 0 \end{aligned}$$

mit

$$|R_k(u)| \leq u^2 \mathbb{E}[\Delta_k^2 \mathbb{1}_{|\Delta_k| > \varepsilon s_n} \mid \mathcal{F}_{k-1}] + \frac{\varepsilon}{6} |u|^3 s_n \sigma_k^2$$

Seien  $(Y_k \sim \mathcal{N}(0, \sigma^2))$  unabhängige Zufallsvariablen, unabhängig von  $(X_n)_{n \in \mathbb{N}_0}$  mit  $Y_k \sim \mathcal{N}(0, \sigma_k^2)$ , dann folgt (wieder analog!)

$$\varphi_{Y_k}(u) = 1 - \frac{1}{2} \sigma_k^2 u^2 + \tilde{R}_k(u)$$

mit

$$|\tilde{R}_k(u)| \leq u^2 \mathbb{E}[Y_k^2 \mathbb{1}_{|Y_k| > \varepsilon s_n}] + \frac{\varepsilon}{6} |u|^3 + s_n \sigma_k^2$$

sodass

$$|\mathbb{E}[e^{iu\Delta_k} \mid \mathcal{F}_{k-1}] - \mathbb{E}[e^{iuY_k}]| \leq u^2 \mathbb{E}[\Delta_k^2 \mathbb{1}_{|\Delta_k| < \varepsilon s_n} \mid \mathcal{F}_{k-1}] + u^2 \mathbb{E}[Y_k^2 \mathbb{1}_{|Y_k| > \varepsilon s_n}] + \frac{\varepsilon}{3} |u|^3 s_n \sigma_k^2 \quad (*)$$



zudem

$$z_n := \sum_{k=1}^n \sim \mathcal{N}(0, \sigma_1^2) \cdots \mathcal{N}(0, \sigma_n^2) = \mathcal{N}\left(0, \sum_{k=1}^n \sigma_k^2\right) = \mathcal{N}(0, s_n^2)$$

sodass

$$\frac{z_n}{s_n} \sim \mathcal{N}(0, 1)$$

und nach Satz VIII.VIII.11

$$\varphi_{z_n/s_n}(u) = \exp\left(-\frac{u^2}{2}\right)$$

Es folgt

$$\begin{aligned} |\varphi_{x_n}(u) - \varphi_{z_n}(u)| &= |\mathbb{E}[e^{iux_n}] - \mathbb{E}[e^{iuz_n}]| \\ &= |\mathbb{E}[\mathbb{E}[e^{iux_n} - e^{iuz_n} \mid \mathcal{F}_{n-1}]]| \\ &= |\mathbb{E}[\mathbb{E}[e^{iux_{n-1}} e^{iu\Delta_n} - e^{iuz_{n-1}} e^{iuY_n} \mid \mathcal{F}_{n-1}]]| \\ &= |\mathbb{E}[e^{iux_{n-1}} \mathbb{E}[e^{iu\Delta_n} \mid \mathcal{F}_{n-1}] - \mathbb{E}[e^{iuz_{n-1}}] \mathbb{E}[e^{iuY_n}]]| \\ &\leq |\mathbb{E}[e^{iux_{n-1}} (\mathbb{E}[e^{iu\Delta_n} \mid \mathcal{F}_{n-1}] - \mathbb{E}[e^{iuY_n}])]| \\ &\quad + |\mathbb{E}[(e^{iux_{n-1}} - \mathbb{E}[e^{iuz_{n-1}}]) \mathbb{E}[e^{iuY_n}]]| \\ &\leq \mathbb{E}[|\mathbb{E}[e^{iu\Delta_n} \mid \mathcal{F}_{n-1}] - \mathbb{E}[e^{iuY_n}]|] + \underbrace{|\mathbb{E}[(e^{iux_{n-1}} - \mathbb{E}[e^{iuz_{n-1}}])]|}_{\text{wende obige Schritte an}} \cdot \underbrace{|\mathbb{E}[e^{iuY_n}]|}_{\leq 1} \\ &\leq \sum_{k=1}^n \mathbb{E}[|\mathbb{E}[e^{iu\Delta_k} \mid \mathcal{F}_{k-1}] - \mathbb{E}[e^{iuY_k}]|] \end{aligned}$$

Für  $u = \frac{v}{s_n}$  folgt mit (\*)

$$\begin{aligned} \left| \varphi_{x_n/s_n}(v) - \varphi_{z_n/s_n}(v) \right| &= |\varphi_{x_n}(u) - \varphi_{z_n}(u)| \\ &\leq \sum_{k=1}^n \mathbb{E}[|\mathbb{E}[e^{iu\Delta_k} \mid \mathcal{F}_{k-1}] - \mathbb{E}[e^{iuY_k}]|] \\ &\leq \sum_{k=1}^n \mathbb{E}[u^2 \mathbb{E}[\Delta_k^2 \mathbb{1}_{|\Delta_k| > \varepsilon s_n} \mid \mathcal{F}_{k-1}] + u^2 \mathbb{E}[Y_k^2 \mathbb{1}_{|Y_k| > \varepsilon s_n}] + \frac{\varepsilon}{3} |u|^3 s_n \sigma_k^2] \\ &= v^2 \mathbb{E}\left[\frac{1}{s_n^2} \sum_{k=1}^n \mathbb{E}[\Delta_k^2 \mathbb{1}_{|\Delta_k| > \varepsilon s_n} \mid \mathcal{F}_{k-1}]\right] \\ &\quad \underbrace{\rightarrow 0 \text{ Lindeberg mit dom. Konvergenz}^1}_{\rightarrow 0} \\ &\quad + \underbrace{\frac{v^2}{s_n^2} \sum_{k=1}^n \mathbb{E}[Y_k^2 \mathbb{1}_{|Y_k| > \varepsilon s_n}]}_{\rightarrow 0} + \underbrace{\sum_{k=1}^n \frac{\varepsilon}{3} |v|^3 \frac{\sigma_k^2}{s_n^2}}_{= \frac{\varepsilon}{3} |v|^3} \quad (**) \\ &\rightarrow \frac{\varepsilon}{3} |v|^3 \\ &\rightarrow 0 \end{aligned}$$

Die Behauptung folgt mit dem Stetigkeitssatz, wenn (\*\*) gilt.

Dazu

$$\begin{aligned}
 \mathbb{E}[Y_k \mathbb{1}_{|Y_k| > \varepsilon s_n}] &= \frac{1}{\sqrt{2\pi\sigma_k^2}} \int_{|x| > \varepsilon s_n} x^2 \exp\left(\frac{-x^2}{2\sigma_k^2}\right) dx \\
 &\stackrel{y=\frac{x}{\sigma_k}}{=} \frac{\sigma_k^2}{\sqrt{2\pi}} \int_{|y| > \varepsilon s_n} y^2 \exp\left(\frac{-y^2}{2}\right) dy \\
 &\leq \frac{\sigma_k^2}{\sqrt{2\pi}} \int_{|y| > \varepsilon \min_{k \leq n} \{s_n / \sigma_k\}} y^2 \exp\left(\frac{-y^2}{2}\right) dy \\
 \Rightarrow \frac{1}{s_k^2} \sum_{k=1}^n \mathbb{E}[Y_k^2 \mathbb{1}_{|Y_k| > \varepsilon s_n}] &\leq \frac{1}{\sqrt{2\pi}} \int_{|y| > \varepsilon \min_{k \leq n} \{s_n / \sigma_k\}} y^2 \exp\left(\frac{-y^2}{2}\right) dy \quad (***)
 \end{aligned}$$

Da

$$\begin{aligned}
 \sigma_k^2 &= \mathbb{E}[\Delta_k^2 \mid \mathcal{F}_{k-1}] = \mathbb{E}[\Delta_k^2 \mathbb{1}_{|\Delta_k| \leq \varepsilon s_n} \mid \mathcal{F}_{k-1}] + \mathbb{E}[\Delta_k^2 \mathbb{1}_{|\Delta_k| > \varepsilon s_n} \mid \mathcal{F}_{k-1}] \\
 &\leq \varepsilon^2 s_n^2 + \mathbb{E}[\Delta_k^2 \mathbb{1}_{|\Delta_k| > \varepsilon s_n} \mid \mathcal{F}_{k-1}]
 \end{aligned}$$

$$\Rightarrow \max_{k \leq n} \left\{ \frac{\sigma_k^2}{s_n^2} \right\} \leq \varepsilon^2 + \frac{1}{s_n^2} \sum_{k=1}^n \mathbb{E}[\Delta_k^2 \mathbb{1}_{|\Delta_k| > \varepsilon s_n} \mid \mathcal{F}_{k-1}] \xrightarrow{\text{Lindeberg}} \varepsilon^2 \rightarrow 0$$

$$\Rightarrow \min_{k \leq n} \left\{ \frac{s_n}{\sigma_k} \right\} \rightarrow \infty$$

$$\Rightarrow \left\{ |y| > \varepsilon \min_{k \leq n} \left\{ \frac{s_n}{\sigma_k} \right\} \right\} \rightarrow \emptyset$$

$\Rightarrow$  mit dominierter Konvergenz folgt (\*\*)

□

# Anhang

# Literaturverzeichnis

- [1] BAUER, H. Wahrscheinlichkeitstheorie, 5 ed. De Gruyter, 2002.
- [2] DEHLING, H., AND HAUPT, B. Einführung in die Wahrscheinlichkeitstheorie und Statistik. Springer, 2003.
- [3] GEORGI, H.-O. Stochastik: Einführung in die Wahrscheinlichkeitstheorie und Statistik, 5 ed. De Gruyter, 2015.
- [4] KRENGEL, U. Einführung in die Wahrscheinlichkeitstheorie und Statistik:. Vieweg, 2005.
- [5] SCHILLING, R. L. Wahrscheinlichkeit: eine Einführung für Bachelor-Studenten, 1 ed. De Gruyter, 2017.

# Index

- $\mathbb{P}$  f.s. Konvergenz, 77
- $\mathbb{P}$ -fast sicher, 77
- $k$ -te Moment, 41
- (absolut) stetig (bzgl. denn Lebesgue-Maß), 6
- (diskrete) Gleichverteilung, 7, 12
- (kumulative) Verteilungsfunktion von  $\mathbb{P}$ , 9
- (stetige) Gleichverteilung, 7
- (stochastisch) unabhängig bezüglich  $\mathbb{P}$ , 22
- (wiederholtes) Bernoulliexperiment, 14
- DIRAC-Maß, 5
- DIRAC-Verteilung, 5
- KOLMOGOROVsche Axiome, 4
- LINDEBERG-Bedingung, 96
- POLYA-Verteilung, 20
- TSCHEBYSCHEFF-Ungleichung, 43
  
- Baumdiagramm, 19
- bedingte Dichte, 52
- bedingte Erwartung, 54
- bedingte Erwartung von  $X$  gegeben  $\mathcal{G}$ , 58
- bedingte Erwartung von  $X$  gegeben  $Y$ , 57
- bedingte Varianz von  $X$  gegeben  $\mathcal{G}$ , 62
- bedingte Wahrscheinlichkeit, 50
- bedingte Wahrscheinlichkeit von  $A$  gegeben  $\mathcal{G}$ , 58
- bedingte Wahrscheinlichkeit von  $A$  gegeben  $B$ , 18
- bedingte Wahrscheinlichkeit von  $A$  gegeben  $Y$ , 57
- bedingten Erwartungswert, 48, 54
- Bernoulli-Verteilung, 15
- Binomialverteilung, 15
  
- charakteristische Funktion von  $\mathbb{P}$ , 68
- charakteristische Funktion von  $X$ , 68
  
- Dichte, 6
- Dichtefunktion, 6
  
- empirische Verteilungsfunktion, 82
- Ereignisraum, 3
- Erfolgswahrscheinlichkeit, 15
- Ergebnisraum, 3
  
- Erwartungswert von  $X$ , 37
- Exponentialverteilung, 6, 35
  
- Faltung, 30
- Formel von BIENAYMÉ, 43
  
- Gammafunktion, 35
- Gammaverteilung, 35
- gedächtnislos, 36
- geometrische Verteilung, 34
  
- Hypergeometrische Verteilung, 15
  
- identisch verteilt, 9
- in Wahrscheinlichkeit, 74
  
- konvergiert, 84
- Korrelation, 42
- Kovarianz, 42
  
- Martingal, 99
- messbar, 3
- messbarer Raum, 3
- momenterzeugende Funktion, 66
- momenterzeugende Funktionen, 35
- Multinomialkoeffizient, 14
- Multinomialverteilung, 14
  
- negative Binomialverteilung, 34
- Normalverteilung mit Parametern  $\mu$  und  $\sigma^2$ , 64
  
- Poissonverteilung, 16
- Produktdichten, 13
  
- Quantilfunktion, 11
  
- Randdichten, 52
- reelle Zufallsvariablen, 9
- regulär, 51
  
- schwache Konvergenz, 86
- Standardabweichung, 42
- Standardnormalverteilung, 64
- stochastischer Prozess, 82
- stochastisch, 74
- stochastische Konvergenz, 74
- Streuung, 42

Stufenexperimente, [19](#)  
Super-/Submartingal, [99](#)

unabhängig, [24](#)  
unabhängig bezüglich  $\mathbb{P}$ , [23](#)  
unkorreliert, [42](#)

Varianz, [42](#)  
verallgemeinerte Inverse, [11](#)

Wahrscheinlichkeitsdichte, [6](#)

Wahrscheinlichkeitserzeugende Funktion, [44](#)  
Wahrscheinlichkeitsmaß, [4](#)  
Wahrscheinlichkeitsraum, [7](#)  
Wahrscheinlichkeitsverteilung, [4](#)  
Wahrscheinlichkeitsverteilung von  $X$  unter  $\mathbb{P}$ , [8](#)

Zähldichte, [6](#)  
Zufallselement, [8](#)  
Zufallsproben, [82](#)  
Zufallsvariable, [8](#)